

ALBINO MILESKI JUNIOR

**ANÁLISE DE MÉTODOS DE PREVISÃO DE
DEMANDA BASEADOS EM SÉRIES
TEMPORAIS EM UMA EMPRESA DO SETOR
DE PERFUMES E COSMÉTICOS**

Dissertação apresentada ao Programa de Pós-
Graduação em Engenharia de Produção e Sistemas
da Pontifícia Universidade Católica do Paraná como
requisito parcial para obtenção do título de Mestre
em Engenharia de Produção e Sistemas.

CURITIBA

2007

Livros Grátis

<http://www.livrosgratis.com.br>

Milhares de livros grátis para download.

ALBINO MILESKI JUNIOR

**ANÁLISE DE MÉTODOS DE PREVISÃO DE
DEMANDA BASEADOS EM SÉRIES
TEMPORAIS EM UMA EMPRESA DO SETOR
DE PERFUMES E COSMÉTICOS**

Dissertação apresentada ao Programa de Pós-
Graduação em Engenharia de Produção e Sistemas
da Universidade Católica do Paraná como requisito
parcial para obtenção do título de Mestre em
Engenharia de Produção e Sistemas.

Área de Concentração: Gerência de Produção e
Logística

Orientador: Prof. Dr. Guilherme Ernani Vieira

CURITIBA

2007

M637a Mileski Junior, Albino
2007 Análise de métodos de previsão de demanda baseados em séries temporais em uma empresa do setor de perfumes e cosméticos / Albino Mileski Junior; [orientador], Guilherme Ernani Vieira. -- 2007.
100 f.: il.; 30 cm

Dissertação (mestrado) – Pontifícia Universidade Católica do Paraná, Curitiba, 2007
Bibliografia: f. 87-96

1. Administração de materiais. 2. Controle de estoque. 3. Análise de séries temporais. 4. Variações sazonais (Economia). 5. Administração de empresas. 6. Perfumes – Indústria. 7. Cosméticos – Indústria. I. Vieira, Guilherme Ernani. II. Pontifícia Universidade Católica do Paraná. Programa de Pós-Graduação em Engenharia de Produção e Sistemas. III. Título.

CDD 20. ed. – 658.7

TERMO DE APROVAÇÃO

ALBINO MILESKI JUNIOR

ANÁLISE DE MÉTODOS DE PREVISÃO DE DEMANDA BASEADOS EM SÉRIES TEMPORAIS EM UMA EMPRESA DO SETOR DE PERFUMES E COSMÉTICOS

Dissertação aprovada como requisito parcial para obtenção do grau de Mestre no Curso de Mestrado em Engenharia de Produção e Sistemas, Programa de Pós-Graduação em Engenharia de Produção e Sistemas, do Centro de Ciências Exatas e de Tecnologia da Pontifícia Universidade Católica do Paraná, pela seguinte banca examinadora:

Prof. Dr. Guilherme Ernani Vieira (PUCPR)
Orientador

Prof. Dr. Fábio Favaretto (PUCPR)
Membro Interno

Prof. Dr. Roberto Max Protil (PUCPR)
Membro Externo

Prof. Dr. Joel Maurício Corrêa da Rosa (UFPR)
Membro Externo

Curitiba, 26 de Setembro de 2007.

A minha esposa Rosane.

Aos nossos filhos Lucas, Rebeca, Raquel e Filipe.

Pelo amor e compreensão durante a realização deste empreendimento.

Agradecimentos

Ao Prof. Dr. Guilherme Ernani Vieira, pela orientação, apoio, paciência e ensinamentos úteis no desenvolvimento deste trabalho.

A PUC-PR e a CAPES, pelo auxílio financeiro através da bolsa de estudos, sem o qual este projeto não poderia ser desenvolvido.

Aos professores, funcionários e colegas do PPGEPS, pela amizade, apoio, companheirismo e orientações durante o desenvolvimento da pesquisa.

Aos professores Dr. Joel Maurício Corrêa da Rosa, Dr. Darli Rodrigues Vieira, Dr. Leandro dos Santos Coelho, pelos conselhos, idéias e ajuda.

Aos amigos Miguel Letenski e Donald Neumann que apoiaram este projeto, tornando possível a sua realização.

A meus pais, que me ensinaram os princípios de trabalho e perseverança, que foram fundamentais para concluir este projeto.

E finalmente, a minha esposa e filhos, que me apoiaram incondicionalmente, demonstrando paciência e confiança na minha busca pela conclusão deste projeto.

Sumário

Agradecimentos	i
Sumário	ii
Lista de Figuras	iv
Lista de Tabelas	vi
Lista de Símbolos	viii
Lista de Abreviaturas	x
Resumo	xi
Abstract	xii

Capítulo 1

Introdução	1
1.1. Definição do Problema da Pesquisa	3
1.2. Objetivos da Pesquisa	3
1.3. Estrutura do Trabalho	4

Capítulo 2

Procedimentos Metodológicos	5
2.1. Metodologia de Pesquisa Adotada	5
2.2. Delineamento do Estudo	6
2.3. Metodologia Adotada	11
2.3.1. Análise Exploratória dos Dados	12
2.3.2. Métodos de Previsão Considerados	14
2.3.3. Critério de Validação	18

Capítulo 3	
Referencial Teórico	21
3.1. Previsão	21
3.2. Séries Temporais	24
3.3. Métodos de Previsão	27
3.3.1. Método de Suavização Exponencial	34
3.3.2. Modelos de Box-Jenkins	38
3.3.3. Redes Neurais	41
3.4. Medidas de Performance Preditiva	50
3.4.1. Soma do Quadrado dos Erros	51
3.4.2. Erro Quadrático Médio	51
3.4.3. Desvio Absoluto Médio	51
3.4.4. Erro Absoluto Médio Percentual	52
3.4.5. Erro Médio Percentual	53
3.4.6. Viés	53
3.4.7. Razão de Viés	53
 Capítulo 4	
Implementação e Análise dos Modelos	55
4.1. Análise Descritiva dos Dados	55
4.1.1. Análise Descritiva Geral	55
4.1.2. Análise Descritiva Particular	59
4.2. Parametrização e Validação dos Modelos Implementados	64
4.3. Análise Comparativa dos Desempenhos dos Modelos	70
 Capítulo 5	
Comentários Finais	83
 Referências Bibliográficas	87
 ANEXO A	97

Lista de Figuras

Figura 2.1	Representação de um sistema de previsão da demanda [FOG03]	7
Figura 2.2	Modelo da tabela dinâmica para separação das categorias	10
Figura 2.3	Esquema do trabalho	11
Figura 2.4	Cenário de previsão da demanda [BAR03]	19
Figura 3.1	Sistema dinâmico [MOR04]	26
Figura 3.2	Métodos quantitativos [SIL02]	28
Figura 3.3	Métodos qualitativos [SIL02]	29
Figura 3.4	Métodos para previsão da demanda [SIL03] e [SIL02]	31
Figura 3.5	Processo previsor de Box-Jenkins [BOX94]	38
Figura 3.6	Modelo de um neurônio artificial [HAY01a]	42
Figura 3.7	Rede <i>feedforward</i> [EST03]	43
Figura 3.8	Representação gráfica de uma RNA [FER95]	47
Figura 3.9	Ajuste de mínimos quadrados não-lineares [FER95]	48
Figura 4.1	Histórico de demanda da categoria de produtos 1	56
Figura 4.2	Histórico de demanda da categoria de produtos 2	57
Figura 4.3	Histórico de demanda do produto P13 da Categoria 1	60
Figura 4.4	Histórico de demanda do produto P8 da Categoria 2	61
Figura 4.5	Decomposição da série temporal do produto P13 da Categoria 1	61
Figura 4.6	Decomposição da série temporal do produto P8 da Categoria 2	62
Figura 4.7	Autocorrelação da série temporal do produto P13 da Categoria 1	63
Figura 4.8	Autocorrelação da série temporal do produto P8 da Categoria 2	63
Figura 4.9	Gráfico dos resíduos do produto P13 da Categoria 1	65
Figura 4.10	Gráfico dos resíduos do produto P8 da Categoria 2	66
Figura 4.11	Autocorrelação dos resíduos do produto P13 da Categoria 1	67
Figura 4.12	Autocorrelação dos resíduos do produto P8 da Categoria 2	67

Figura 4.13	Interseção dos intervalos de confiança para os produtos da Categoria 1	77
Figura 4.14	Interseção dos intervalos de confiança para os produtos da Categoria 2	78
Figura 4.15	Box plot da Categoria 1	80
Figura 4.16	Box plot da Categoria 2	81

Lista de Tabelas

Tabela 3.1	Descrição dos métodos quantitativos [SIL02]	30
Tabela 3.2	Esquema de classificação [PEG69]	35
Tabela 3.3	Dicionário de redes neurais-econometria [FER95]	43
Tabela 4.1	Histórico de demanda por categorias	56
Tabela 4.2	Estatísticas descritivas para a Categoria 1	57
Tabela 4.3	Estatísticas descritivas para a Categoria 2	58
Tabela 4.4	Histórico de demanda dos produtos da Categoria 1	58
Tabela 4.5	Histórico de demanda dos produtos da Categoria 2	59
Tabela 4.6	Estatísticas descritivas para o produto P13 da Categoria 1	59
Tabela 4.7	Estatísticas descritivas para o produto P8 da Categoria 2	60
Tabela 4.8	Parâmetros Holt-Winters para os produtos P13 e P8	64
Tabela 4.9	Parâmetros Box-Jenkins para os produtos P13 e P8	68
Tabela 4.10	Parâmetros Redes Neurais Artificiais para os produtos P13 e P8	69
Tabela 4.11	Previsões pelo Método Atual e Holt-Winters para a Categoria 1	70
Tabela 4.12	Previsões por Box-Jenkins e Rede Neural Artificial para a Categoria 1	71
Tabela 4.13	Previsões pelo Método Atual e Holt-Winters para a Categoria 2	71
Tabela 4.14	Previsões por Box-Jenkins e Rede Neural Artificial para a Categoria 2	72
Tabela 4.15	EAMP entre os métodos de previsão para a Categoria 1	73
Tabela 4.16	EAMP entre os métodos de previsão para a Categoria 2	73
Tabela 4.17	Análise comparativa entre os métodos de previsão	74
Tabela 4.18	Análise comparativa entre os métodos de previsão	75
Tabela 4.19	Análise comparativa dos métodos de previsão por produto	76
Tabela 4.20	Análise comparativa dos métodos de previsão por produto	76
Tabela 4.21	Análise de variância (ANOVA)	79
Tabela 4.22	Análise de variância por categoria	80

Lista de Símbolos

$E_{(t)}$	Erro entre o valor real e o valor previsto
ε_t	Termo aleatório
$\hat{Y}_{(t)}$	Valor previsto por um modelo
Δw	Variação do peso sináptico a cada iteração durante o treinamento
n	Número de períodos observados de determinados fenômeno
R^2	Coeficiente de determinação
$Z(t)$	Representação de uma série temporal com t elementos
θp	<i>Bias</i> (viés) de um neurônio p
$v(t)$	Função de transferência
T_t	Tendência
S_t	Sazonalidade
b_k	Coeficiente de regressão parcial
S_k	Desvio padrão
α, β, γ	Constantes de suavização
ψ_K	Filtro linear
$\varphi(B)$	Operador auto-regressivo não sazonal
$\theta(B)$	Operador de médias móveis não sazonal
r_k	Autocorrelação
σ_d	Desvio padrão da demanda
a_t	Ruído branco
Ψ_K	Função de transferência ou filtro linear definido como $\theta_q(B)/\varphi_p(B)$
B	Operador de retardo que representa um atraso de um período de tempo
$\varphi(B)$	Operador auto-regressivo não sazonal
$\nabla^d = (1 - B)^d$	Operador de diferença não sazonal de ordem d

$\Phi(B^S)$	Operador auto-regressivo sazonal
$\nabla_s^D = (1 - B^S)^D$	Operador de diferença sazonal de ordem D
$\theta(B)$	Operador de médias móveis não sazonal
$\Theta(B^S)$	Operador de médias móveis sazonal

Lista de Abreviaturas

ACF	Função de Autocorrelação
AIC	<i>Akaike Information Criterion</i>
AR	<i>Autoregressive</i>
ARCH	<i>Autoregressive Conditional Heteroscedasticity</i>
ARMA	<i>Autoregressive Moving Average</i>
ARIMA	<i>Autoregressive Integrated Moving Average</i>
DAM	Desvio padrão absoluto médio
EAMP	Erro absoluto médio percentual
EQM	Erro quadrático médio
GARCH	<i>Generalized Autoregressive Conditional Heteroscedasticity</i>
MA	<i>Moving Average</i>
PACF	Função de Autocorrelação Parcial
RN(s)	Rede Neural/Redes Neurais
RNA(s)	Rede Neural Artificial/Redes Neurais Artificiais
SARIMA	<i>Seasonal Autoregressive Integrated Moving Average</i>
SQE	Soma do quadrado dos erros
TS	<i>Tracking Signal</i>

Resumo

A previsão da demanda é um dos principais fatores que contribui para a eficiência na cadeia produtiva das empresas que operam com ênfase no conceito de produção para estoque e é fundamental para o planejamento da produção, e por extensão, para o início do processo de suprimento. Neste contexto, quanto maior a acuracidade da previsão da demanda melhor será o desempenho da empresa. Em sentido contrário, o nível das variações pode levar ao não atendimento da demanda, atraso neste atendimento e/ou excesso de estoques. Certamente, estas condições aumentam os custos do produto e afetam a lucratividade do negócio. O objetivo desta pesquisa é identificar o melhor método de previsão para produtos de uma empresa do setor de perfumes e cosméticos. Esta pesquisa analisou métodos de previsão, baseados em séries temporais para produtos com comportamento sazonal. Três métodos foram considerados: suavização exponencial, Box-Jenkins (SARIMA) e as redes neurais artificiais. Estes métodos foram implementados no pacote estatístico R e em Excel, e um estudo comparativo foi feito a partir das previsões realizadas (pelo método atual), a demanda real verificada e as previsões feitas com os métodos considerados. A eficiência de cada método analisado foi definida pelo erro absoluto médio percentual (EAMP) e o sinal de rastreabilidade (TS). Os principais resultados obtidos indicam que o método atualmente utilizado pela empresa é adequado. Entretanto, os outros métodos de previsão analisados seriam igualmente aplicáveis. Alguns deles apresentaram melhores resultados (previsões mais exatas, erros menores), como é o caso dos métodos de previsão de rede neural artificial (o melhor entre os três métodos analisados).

Palavras-Chave: Cadeia de Suprimento, Previsão de Demanda, Séries Temporais, Sazonalidade.

Abstract

The demand forecast is one of the main factors that contribute for the efficiency in the productive chain of companies who operate with emphasis in the concept of “make to stock” and is essential for the production planning, and consequently, for the beginning of the supply process. In this context, the more accurate the demand forecast is the better the performance of the company will be. In opposite direction, forecasting inaccuracies can lead to inventory shortages, backlogs and/or over stocks. Certainly, these conditions increase production costs and jeopardize business profitability. The objective of this research is to identify the best forecasting method for products of a company in the perfumes and cosmetics sector. This research evaluates forecast methods based on time series for products with seasonal behavior. Three methods were considered: exponential smoothing, Box-Jenkins (SARIMA) and the artificial neural networks. These methods have been implemented in the statistical package R and Excel, and a comparative study was made from the realized forecasts (under the current method), the real demand occurred and the forecasts made with the considered methods. The efficiency of each analyzed method was defined by the mean absolute percentual error (EAMP) and the tracking signal (TS). The main results obtained indicated that the method currently used by the company is adequate. However, the other forecasting methods analyzed would also be applicable. Some of them would even present better results (more accurate forecasts, less errors) as is the case for artificial neural networks forecasting methods (the best among the three methods analyzed).

Key words: Supply Chain, Forecasting, Time Series, Seasonality.

Capítulo 1

Introdução

A competição entre as empresas cresceu significativamente nas últimas duas décadas como consequência do processo de globalização. Neste contexto, muitas empresas, em várias partes do mundo, inclusive aquelas localizadas em países em processo de industrialização, têm enfrentado mercados altamente desafiadores, com novos e crescentes critérios para concorrer e garantir a própria sobrevivência.

Este ambiente dinâmico e de mudanças rápidas exige das empresas a obtenção de melhor desempenho em relação a indicadores de qualidade, rapidez, confiabilidade, flexibilidade e custo. Desta forma, a cadeia de suprimento recebeu maior atenção das empresas como uma alternativa estratégica para enfrentar as mudanças e desafios de suas operações neste novo cenário.

A eficiência do gerenciamento da cadeia de suprimento, que visa à satisfação dos clientes, é uma das formas que contribui fortemente para o sucesso das empresas. É influenciada por diversos fatores como: gerenciamento dos níveis de estoque, planejamento da capacidade produtiva, custos de produção, concepção de métodos eficientes de programação, estratégias de distribuição do produto e demanda do consumidor.

A previsão da demanda é, portanto, um dos principais fatores que contribui para a eficiência na cadeia produtiva das empresas. Ela é fundamental para o planejamento da demanda, e por extensão, para o início do processo de suprimento. Neste sentido, quanto maior a acuracidade da previsão da demanda menor serão os impactos no nível de atendimento e custos na cadeia de suprimento. O não atendimento destas condições aumenta os custos do produto e afeta a lucratividade do negócio.

Em cadeias de suprimento que possuem uma grande quantidade de produtos, com

ciclos de vida curtos, produção para estoques, com grandes *lead times* de entrega, lotes padrões de compra e de produção elevados, demanda sazonal de produtos e insumos importados, exige-se uma organização responsiva da cadeia. Esta responsividade da cadeia de suprimento, segundo [CHO03], é a habilidade da cadeia de suprimento de responder a amplos escopos de quantidades exigidas, atender com *lead times* curtos, manejar uma grande variedade de produtos, produzir produtos altamente inovadores e atender a um nível de serviço muito alto.

O negócio que possui uma cadeia de suprimento com estas características, ou seja, com todas essas variáveis, necessita de um elevado nível de precisão na previsão da demanda para se evitar o desbalanceamento dos estoques ao longo da cadeia e, conseqüentemente, dos gastos desnecessários. Este é o caso da área de perfumaria e cosméticos, onde a previsão da demanda é um desafio. Os dados históricos disponíveis para a previsão da demanda nesta área, na maioria das vezes, apresentam sazonalidade e comportamento variante no tempo, isto é, a presença de fatores relacionados à ruptura de modelo de previsão.

Neste contexto, um dos problemas principais abordados por métodos numéricos é a previsão baseada em dados históricos. Uma vez que as pesquisas sobre séries temporais¹ visam providenciar uma previsão quando o modelo matemático de um fenômeno é complexo, desconhecido ou incompleto. A utilização, então, de modelos estocásticos de previsão de séries temporais para produtos com demanda sazonal, na área de perfumaria e cosméticos, pode ser uma alternativa viável para o gerenciamento eficiente da produção e distribuição de cada produto no mercado.

Neste sentido, esta pesquisa, portanto, analisa os seguintes métodos de previsão, para séries temporais, de produtos com comportamento sazonal: o método de suavização exponencial, o método de Box-Jenkins e as redes neurais artificiais. Os métodos de suavização exponencial e de Box-Jenkins estão dentro dos métodos tradicionais de estatística, sendo amplamente difundidos, inclusive em áreas de economia e administração, facilitando assim, uma possível implantação dos mesmos por parte da empresa [BAR03]. As redes neurais artificiais estão dentro da área de inteligência artificial, a qual disponibilizou outras ferramentas de previsão além dos métodos tradicionais de estatística.

Estes métodos foram implementados, com o uso do software R (pacote estatístico)

¹ Uma série temporal consiste de medidas ou observações previamente obtidas de um fenômeno que são realizadas sequencialmente sob um intervalo de tempo. Se estas observações consecutivas são dependentes uma da outra, então é possível conseguir-se uma previsão do comportamento dinâmico do sistema analisado.

para gerar, analisar e selecionar modelos de previsão baseados em dados históricos de uma empresa de perfumaria e cosméticos, para duas categorias de produtos que têm impacto significativo nos seus custos e investimentos. Um estudo comparativo foi realizado com a previsão realizada pelo método atual e a demanda real para verificação da sua eficiência e a identificação do método de previsão mais adequado aos dados fornecidos.

1.1 Definição do Problema da Pesquisa

A previsão da demanda futura, segundo [CHO03], é a base para todas as decisões estratégicas e de planejamento em uma cadeia de suprimento. Neste processo, os dados passados são combinados e analisados de uma forma pré-determinada até se obter uma estimativa de um evento futuro. Desta maneira, a previsão visa reduzir o excesso de estoque, reduções desnecessárias de preços ou perda de vendas devido à falta de produtos.

Neste sentido, a intenção desta pesquisa é realizar uma análise comparativa e identificar entre o método de suavização exponencial, o método de Box-Jenkins, as redes neurais artificiais e o método utilizado pela empresa, qual deles e com quais parâmetros é o mais adequado para as categorias de produtos, isto é, qual método gera o menor erro de previsão da demanda possível para cada produto. A questão a ser respondida, portanto, por esta pesquisa é: “Qual é o método de previsão e seus parâmetros são mais adequados para cada produto e categoria de produtos, conseguindo o menor erro possível?”.

Desta forma, a pesquisa visa auxiliar a tomada de decisão e, neste contexto, é possível realizar o planejamento de produção de produtos com um maior grau de acurácia, o que proporcionará para a empresa a diminuição de problemas no nível de atendimento e custos na cadeia de suprimento, principalmente com estoques elevados desnecessários.

1.2 Objetivos da Pesquisa

Esta pesquisa visa identificar o método de previsão² mais adequado para duas categorias de produtos que apresentam comportamento sazonal, em uma empresa de perfumaria e cosméticos, com o objetivo de minimizar os efeitos que os erros de previsões têm gerado nesta empresa.

Os objetivos específicos deste trabalho são:

² Esta pesquisa trata apenas de métodos quantitativos de previsão da demanda.

- Identificação das categorias de produtos e caracterização de nível, tendência e sazonalidade dos históricos de demanda dos produtos usando métodos estatísticos;
- Identificação do método de previsão utilizado pela empresa e os parâmetros para análise de cada grupo de produtos;
- Análise e seleção de métodos de previsão baseados em séries temporais mais adequados em lidar com os produtos em análise;
- Estudo comparativo e verificação da eficiência dos métodos de previsão em relação ao utilizado pela empresa.

1.3 Estrutura do Trabalho

Este trabalho está dividido em 5 capítulos. No Capítulo 1 é realizada a introdução do trabalho, discutindo a sua origem, o problema da pesquisa, os objetivos gerais e específicos, e a metodologia. O Capítulo 2 demonstra a aplicação do ferramental adotado dentro dos objetivos da pesquisa, detalhando os passos básicos na realização da análise comparativa para identificar dentre certos métodos de previsão da demanda, qual deles e com quais parâmetros, é o mais adequado aos dados históricos fornecidos para os produtos (e suas categorias) considerados. O Capítulo 3 apresenta o referencial teórico, que aborda o atual estado da arte dos assuntos diretamente relacionados à dissertação, que são: conceitos de previsão com base em séries temporais e métodos de previsão. O Capítulo 4 apresenta e discute os resultados obtidos dentro da pesquisa realizada com a utilização das ferramentas selecionadas e a aplicação dessas ferramentas na identificação do método de previsão mais adequado. No Capítulo 5 são tratadas as conclusões e recomendações deste trabalho para trabalhos futuros.

Capítulo 2

Procedimentos Metodológicos

Este capítulo demonstra a aplicação do ferramental adotado dentro dos objetivos da pesquisa, detalhando os passos básicos na realização da análise comparativa para identificar dentre certos métodos de previsão da demanda, qual deles e com quais parâmetros, é o mais adequado aos dados históricos fornecidos para os produtos (e suas categorias) considerados.

2.1 Metodologia de Pesquisa Adotada

A abordagem metodológica define e classifica a pesquisa dentro de padrões determinados. Esta classificação varia em detalhes e complexidade. A abordagem metodológica, os métodos de pesquisa e os instrumentos utilizados para a coleta de dados, portanto, devem ser escolhidos e organizados de acordo com o propósito de cada investigação [BER98] e [SIL01]. Neste sentido, no desenvolvimento do presente estudo, descreve-se na sequência as possíveis classificações.

De acordo com [GIL02], uma pesquisa pode ser classificada com base em seus objetivos e procedimentos técnicos utilizados (delineamento). Em relação aos seus objetivos, por procurar descobrir, com a precisão possível, a frequência com que um fenômeno ocorre, sua relação e conexão com outros, sua natureza e características, sem manipulá-los, a pesquisa pode ser definida como uma pesquisa descritiva [CER02], [GIL02] e [EAS03].

A pesquisa pode ser classificada como uma pesquisa bibliográfica e quantitativa, em relação aos seus procedimentos técnicos, com propósito de previsão baseado em dados históricos [NAK96]. Quantitativa por ser baseada na coleta, análise e interpretação matemática de dados numéricos coletados ao longo do tempo em um sistema existente.

Os métodos de previsão serão avaliados de acordo com critérios de desempenho

baseados em medidas de erro, isto é desvios entre valores previstos e observados.

Neste contexto das definições citadas, a pesquisa está estruturada em nove etapas, como indicado abaixo:

- Entendimento do negócio: etapa de contextualização do problema e do cenário ou negócio da empresa em questão;
- Conceituação do problema: etapa de explicação do problema e justificação do problema no contexto da empresa;
- Definição de objetivos da pesquisa;
- Organização ou estruturação dos dados relevantes à pesquisa e da forma de tratamento destes;
- Definição dos métodos de previsão a serem analisados;
- Definição dos experimentos de análise a serem realizados;
- Implementação dos métodos em computador;
- Experimentação e análise dos resultados obtidos pelos métodos de previsão escolhidos;
- Conclusões: etapa de apresentação dos resultados finais.

2.2. Delineamento do Estudo

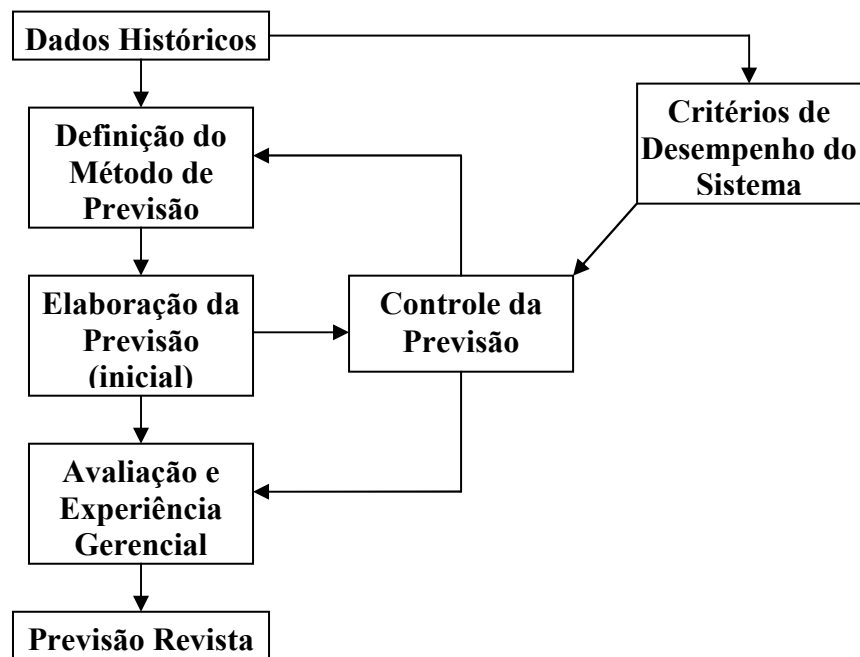
Uma representação simplificada de um sistema de previsão da demanda, segundo [FOG03], está apresentada na Figura 2.1. O sistema é alimentado por dados históricos, normalmente provenientes de arquivos de vendas da empresa. A partir dos dados e assumindo-se que já se tem o método “ideal” para os dados históricos que se deseja analisar, define-se um método de previsão que pode ser quantitativo ou qualitativo que será usado para a elaboração da previsão propriamente dita.

A intenção de um sistema de previsão da demanda é aumentar a eficiência da previsão, reduzindo a incerteza desta previsão, para que as decisões que afetam o futuro da organização sejam tomadas. Segundo [HAN01], as suposições ponderadas sobre o futuro são mais valiosas aos gerentes da organização do que as suposições não ponderadas. Desta forma, quanto maior for o grau de precisão associado às previsões, melhor será o desempenho da organização, ou seja, menores serão os impactos no nível de atendimento e custos na cadeia de suprimento.

Com base neste sistema de previsão da demanda, o passo inicial, segundo [FOG03], na elaboração de uma previsão da demanda é a definição do problema de decisão que será

auxiliado pelo sistema. Este problema definirá o objetivo da previsão, qual o método de previsão a ser adotado, os elementos envolvidos e o nível de precisão desejado.

Com este passo, pretende-se minimizar as causas de erros comuns de previsão que muitas vezes fazem com que as técnicas de previsão sejam consideradas incorretas e inadequadas, e que em muitos casos, na realidade são causados por erros nos dados ou falhas na análise dos resultados, gerando os erros de previsão [GIL06].



Fonte: Adaptado de [FOG03]

Figura 2.1: Representação de um sistema de previsão da demanda.

Nesta pesquisa, conforme descrito na seção 1.2, a questão de interesse é a previsão da demanda de um grupo de produtos com comportamento sazonal. O delineamento deste estudo está baseado em dados históricos de uma empresa de perfumaria e cosméticos, para duas categorias de produtos que têm impacto significativo nos seus custos e investimentos. A realização de um estudo comparativo visa identificar o método de previsão mais adequado, e seus parâmetros, para cada categoria de produtos, conseguindo o menor erro possível.

Como esta previsão baseia-se exclusivamente no comportamento histórico da demanda, sendo tal enfoque chamado de estatístico ou de séries temporais, o modelo é obtido diretamente dos dados disponíveis, sem recorrer a uma possível teoria subjacente, sendo, portanto um método quantitativo.

Os dados históricos utilizados compreendem um período de 2004 a 2007, observados num intervalo mensal, resultando em 39 observações. Estes dados referem-se a número de produtos, ou seja, a quantidade de produtos vendidos (demanda real) e não a valores monetários. As duas categorias de produtos serão identificadas como Categoria 01 e Categoria 02, e são compostas por 28 e 16 produtos respectivamente. Estes dados encontram-se no ANEXO A e compreendem as séries temporais a serem estudadas. Os mesmos foram coletados do sistema ERP (*Enterprise Resource Planning*) da empresa em um formato *Microsoft Office Excel Comma Separated Values File*, sendo necessário à criação de uma tabela dinâmica utilizando o Excel 2003 para isolar as duas categorias a serem estudadas. A disposição dos dados na tabela dinâmica seguiu uma estrutura para facilitar a utilização do pacote estatístico R³.

O R é uma linguagem e ambiente para computação estatística e gráficos. É um projeto GNU (*General Public License* da *Free Software Foundation*) que é similar à linguagem e ambiente S, que foi desenvolvida nos Laboratórios Bell (antiga AT & T, agora *Lucent Technologies*) por Rick Becker, John Chambers e Allan Wilks, e também forma a base dos sistemas S-Plus. O R pode ser considerado como uma aplicação diferente do S. Há algumas diferenças importantes, mas muitos códigos escritos para o S são executados de maneira inalterada pelo R.

O R fornece uma ampla variedade de estatística (modelagem linear e não-linear, testes estatísticos clássicos, análise de séries temporais, testes paramétricos e não-paramétricos, suavização, etc.) e técnicas gráficas, e é altamente extensível. A linguagem S é freqüentemente o veículo de escolha para a pesquisa na metodologia estatística, e o R oferece o código aberto como uma rota para a participação nessa atividade.

Um dos pontos fortes do R é a facilidade com que pode ser produzida a edição, com qualidade, de gráficos, incluindo símbolos e fórmulas matemáticas, quando necessário. Grandes cuidados foram tomados na elaboração dos padrões durante a escolha do projeto gráfico, mas o usuário mantém o controle total.

O R está disponível como software livre, nos termos da GNU na forma de código aberto. Pode ser compilado e “roda” em um grande número de plataformas UNIX e sistemas semelhantes (incluindo FreeBSD e Linux), Windows e MacOS.

O R é um conjunto integrado de facilidades em software para manipulação de dados,

³ R Development Core Team (2007). R: A language and environment for statistical computing. R Foundation for Statistical Computing, Vienna, Austria. ISBN 3-900051-07-0, URL <http://www.R-project.org>.

cálculo e visualização gráfica. Inclui:

- Um eficaz tratamento de dados e facilidade de armazenagem;
- Um conjunto de operadores de cálculos sobre *arrays*, em especial matrizes;
- Uma ampla, coerente e integrada coleção de ferramentas intermediárias para análise dos dados;
- Facilidades gráficas para análise e visualização de dados, quer na tela ou impresso;
- Uma bem desenvolvida, simples e eficaz linguagem de programação que inclui condicionantes, *loops*, funções recursivas definidas pelo usuário e facilidades de entrada e de saída.

O termo "ambiente" destina-se a caracterizá-la como um sistema coerente e totalmente planejado, em vez de um incremento de ferramentas muito específicas e inflexíveis, como é frequentemente o caso com outros softwares de análise de dados. O R, como o S, foi concebido em torno de uma verdadeira linguagem computacional, e ela permite aos usuários acrescentar funcionalidades adicionais através da definição de novas funções. Grande parte do sistema é em si escrita no R por linguagem do S, o que facilita aos usuários identificarem a escolha algorítmica realizada. Para tarefas computacionais intensivas, o C, o C++ e o Fortran podem ser conectados e acessados durante a execução. Os usuários avançados podem escrever códigos C para manipular objetos do R diretamente.

Muitos usuários pensam no R como um sistema estatístico. Contudo, é preferível pensar nele como em um ambiente dentro do qual muitas técnicas clássicas e modernas de estatística são implementadas. Algumas destas estão incorporadas na base do ambiente R, mas muitas são oferecidas como “pacotes”, o que permite ao R ser estendido facilmente. Há cerca de 25 pacotes oferecidos com o R (chamados pacotes "padrão" e "recomendado") e muitos outros estão disponíveis através do CRAN⁴ e noutros locais abrangendo um vasto leque de estatísticas modernas.

A decisão de utilização deste software se deu por ser um software livre, de linguagem simples ou uma linguagem de expressão com uma sintaxe simples, muitas técnicas clássicas e

⁴ *Comprehensive R Archive Network*. É o repositório central de pacotes de software do projeto R. É a partir dele que são feitos os *downloads* automáticos para a instalação de novos pacotes em seu ambiente R. Conta com diversos *mirrors* que "espelham" uma cópia atualizada de seu conteúdo, garantindo disponibilidade ininterrupta. A página oficial do CRAN é <http://cran.r-project.org> e o *mirror* brasileiro, hospedado na Universidade Federal do Paraná – UFPR, podem ser acessado em <http://cran.br.r-project.org>.

modernas de estatística estão implementadas em seu ambiente e por suas facilidades gráficas.

A Figura 2.2 demonstra o modelo da tabela dinâmica elaborada para a separação das categorias.

Mês	P1	P2	P3	P4	P5	P6	P7	P8	P9	P10	P11	P12	P13
05/2004	30278	39341	80326	60282	23261	47681	33354	82256	23200	33789	40735	39136	5783
06/2004	11754	13748	30258	19423	6039	17985	10781	33922	11491	14067	14221	12810	3097
07/2004	11107	16734	32151	18751	5508	18419	11312	42010	13837	11047	14108	12151	3585
08/2004	15350	16127	40567	27561	7013	24843	14192	34953	11456	12299	19410	14782	4147
09/2004	17225	22822	56299					46581	13841	11751	24988	19608	4583
10/2004	26288	35404	82658					87574	22503	21503	39455	32322	7167
11/2004	45833	59492	133127					173751	42183	45886	57446	66696	13598
12/2004	14202	18191	46398					40530	10943	13424	20961	18534	6067
01/2005	9562	10364	31656					15843	6369	8581	15113	9980	4733
02/2005	9097	11021	29777					16531	6235	7750	15271	9038	4640
03/2005	16181	18575	51934					28671	9329	10865	25561	13926	6538
04/2005	28325	29486	92774					67917	20094	27438	43561	27327	8764
05/2005	21111	20608	71381					67104	19358	13262	35019	20512	5344
06/2005	15486	15833	49253					38146	14844	8904	26813	13356	3109
07/2005	12884	15324	36827					31121	7582	7042	20016	12170	2692
08/2005	14162	15315	41680					27336	8893	10214	19899	12603	2780
09/2005	18447	16176	49943					34847	9860	10508	23672	16033	3288
10/2005	21748	24860	74772					74249	18375	18143	36846	25836	6000
11/2005	45136	56959	132027					156827	38501	44262	65036	61029	13770
12/2005	12155	13791	30188					33008	8653	9412	18317	12183	5853
01/2006	6522	5990	18676					19146	4626	5576	10192	5545	2933
02/2006	8478	9323	26995					18542	5101	5842	14335	6773	2418
03/2006	12525	11081	39996	25445	6726	18314	13687	26394	7757	7186	20220	10899	2697
04/2006	23406	20620	86924	57314	15030	41123	27098	68526	17418	16613	43066	24920	6126
05/2006	19250	16949	69371	45527	16936	35906	20829	72634	19324	17380	33384	21829	5736
06/2006	12946	9187	29573	22350	5952	17640	11095	22815	6515	5209	16335	11593	3545
07/2006	15022	14759	39544	28821	6458	24007	13853	33358	9072	6765	22610	14917	4314
08/2006	17926	17110	48791	37994	8587	28390	17152	45193	13317	10696	22736	19916	4839
09/2006	15288	13679	43782	31377	8299	24993	15219	41084	15050	8481	24193	18829	3931

Figura 2.2: Modelo da tabela dinâmica para separação das categorias.

Nesta pesquisa, optou-se pelos métodos tradicionais e de inteligência artificial dentro dos métodos quantitativos de previsão baseados em séries temporais. Dentro dos métodos tradicionais, a pesquisa concentrou-se nos métodos de suavização exponencial e de Box-Jenkins, pois os mesmos são amplamente difundidos, inclusive em áreas de economia e administração, facilitando assim, uma possível implantação dos mesmos por parte da empresa [SIL03] e [BAR03]. Estes métodos têm sido aplicados na engenharia de produção e são referência obrigatória na bibliografia que trabalha com planejamento da produção [HAN01] e [CHO03].

Dentro da inteligência artificial, optou-se pelo método de previsão baseado em redes neurais artificiais, pois este método tem apresentado um crescimento em suas aplicações e mostrado vantagens sobre métodos tradicionais como, por exemplo, regressão linear e regressão múltipla [TRA04] e [BAU04].

2.3 Metodologia Adotada

Com o escopo da pesquisa abordado no delineamento do estudo e baseado nas nove etapas da estrutura da pesquisa, tratadas na seção 2.1, a metodologia adotada contempla as fases de:

- Organização ou estruturação dos dados e tratamento destes;
- Definição dos métodos de previsão a serem analisados;
- Definição dos experimentos de análise a serem realizados;
- Implementação dos métodos em computador;
- Experimentação e análise dos resultados obtidos pelos métodos de previsão escolhidos.

Para isto foi elaborada a estrutura apresentada na Figura 2.3 e esta seção foi dividida em três subseções: Análise Exploratória dos Dados, Análise de Séries Temporais e Critério de Validação.

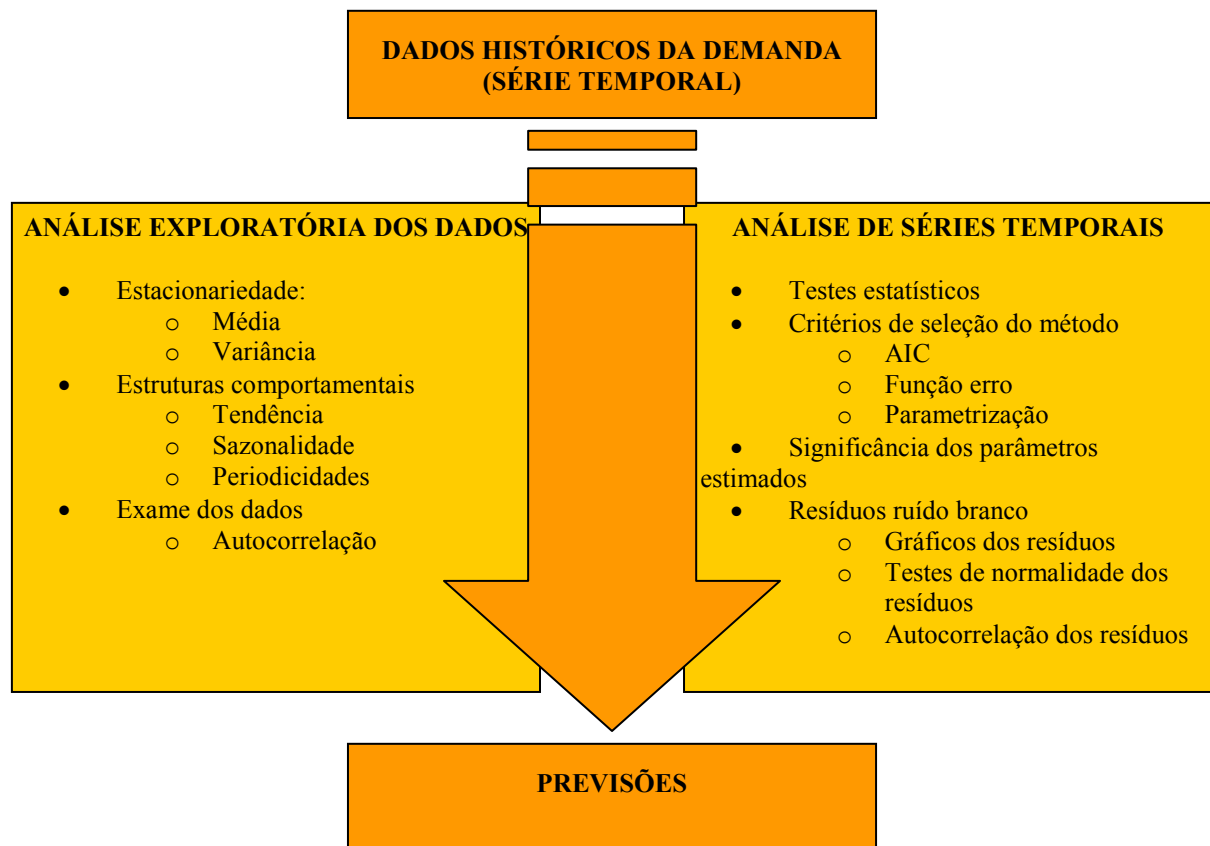


Figura 2.3: Esquema do trabalho.

É importante salientar que na seção 2.3.2 são tratados os critérios relacionados ao processo de escolha dos parâmetros dos métodos utilizados nesta pesquisa visando minimizar a medida de erro destes métodos (desempenho em ajuste), enquanto na seção 2.3.3 são considerados os critérios de validação, ou seja, os critérios para a realização da avaliação entre cada um dos métodos de previsão estudados. Esta avaliação será feita através da comparação entre alguns indicadores de erro, ou medidas de erro, dos resultados da previsão de cada modelo considerando erro como a diferença entre o valor obtido da previsão e o valor real [TRA04], como descrito na seção 3.4 (desempenho em previsão).

Para o tratamento dos dados, conforme explicado nesta seção, serão utilizados os programas computacionais Excel 2003 (planilha eletrônica) e o R (pacote estatístico). O processo de escolha dos parâmetros dos modelos será realizado de forma automática, ou seja, o pacote estatístico R realiza uma otimização das variáveis de maneira a indicar quais são os melhores parâmetros para aquele conjunto de dados em análise, conforme programação. Os resultados serão apresentados, discutidos e considerados no próximo capítulo, bem como, as previsões realizadas para os melhores modelos obtidos.

2.3.1 Análise Exploratória dos Dados

Os dados coletados possuem muitas informações importantes que precisam ser examinadas, para isto, conforme sugere [BOX94], deve-se deixar que os dados falem por si. Este objetivo é alcançado através da análise exploratória dos dados, que permite investigar relações e estruturas comportamentais do conjunto de observações coletadas, ou seja, das duas categorias de produtos em análise, possibilitando a pesquisa de um modelo que projete possíveis valores futuros, previsões, com determinado nível de confiança.

A partir dos dados do ANEXO A serão efetuadas as estatísticas descritivas para a verificação de médias, medianas, desvio padrão e outras estatísticas das séries. O primeiro passo no exame da série temporal é a observação se a mesma é estacionária, isto é, não há tendência presente ou se ela já foi removida anteriormente. A verificação da estacionariedade, nesta pesquisa, se dará através da média e variância (estacionariedade de segunda ordem ou fraca).

Na sequência, a análise será realizada para o reconhecimento das estruturas comportamentais da série. Um primeiro passo, neste momento da análise da série temporal, é a construção de seu gráfico, que revelará características importantes, como tendência,

sazonalidade, variabilidade, observações aberrantes (*outliers*), etc. [MOR87a]. O outro passo é a utilização do processo de decomposição em componentes não-observáveis.

No caso das séries temporais há um tratamento clássico, a decomposição clássica, de suas informações, com vistas à geração de parâmetros para subsequente emprego na previsão da variável sob estudo. Até meados da década de 1970, esse método foi um dos principais instrumentos utilizados pela econometria⁵ de séries temporais. Para ser feita a decomposição, determina-se a série histórica de dados e faz-se a sua decomposição em quatro componentes, quais sejam: tendência (T), ciclo (C), sazonalidade (S) e termo aleatório (ε)⁶.

Conforme [HAN01], [ROC03] e [MOR04], a tendência pode ser entendida como o movimento persistente dos dados em uma dada direção. O ciclo, por sua vez, indica o movimento oscilatório em torno da tendência, podendo este ser verificado por períodos prolongados. A sazonalidade indica o comportamento regular assumido pela série em algum subperíodo. Já o termo aleatório leva em consideração movimentos esporádicos e irregulares presentes na série. A combinação destes componentes pode ser feita mediante a forma aditiva ou multiplicativa.

A decomposição pelo pacote estatístico R se dá utilizando médias móveis. O modelo utilizado pelo R considera a componente sazonal, podendo ser aditivo (que é adequado quando S não depende das outras componentes como T) ou multiplicativo (se as amplitudes sazonais variam com a tendência), bem como, a decomposição sazonal de séries temporais por Loess⁷.

Como última análise desta fase, é verificada a função de autocorrelação (fac). O estudo dos processos estacionários pode ser feito no domínio da frequência ou no domínio do tempo. O estudo no domínio da frequência dá papel de relevo aos conceitos de periodograma e de densidade espectral; o domínio no tempo atribui papel predominante às funções autocovariância e autocorrelação [BEL91].

A autocorrelação é uma medida de dependência entre observações da mesma série separadas por um determinado intervalo chamado retardo. A função de autocorrelação (fac)

⁵ Área da economia voltada à descrição de relações econômicas por meio de modelos matemáticos e à estimação dos parâmetros desses modelos, com uso de dados estatísticos.

⁶ Segundo [MOR87a], era comum incluir no modelo uma componente cíclica, para representar movimentos com períodos longos, geralmente maiores que um ano, mas não há evidência que séries modernas contenham componentes periódicas além da sazonal.

⁷ Para maiores informações ver: CLEVELAND, W. S.; GROSSE, E.; SHYU, W. M. Local Regression Models. In J. M. Chambers and T. Hastie, editors, *Statistical Models in S*, pages 309–376. Chapman and Hall, New York, 1992.

nada mais é do que a representação gráfica do coeficiente de autocorrelação em função dos diversos retardos que podem ser atribuídos aos dados [BOX94].

A função de autocorrelação (fac) permite que se entenda melhor o comportamento da dependência estatística entre os dados e, posteriormente, será útil quando da determinação de qual série temporal utilizar para o ajuste do processo. A função de autocorrelação é definida por:

$$\rho_j = \frac{\gamma_j}{\gamma_0} = \frac{Cov(Z_t, Z_{t+j})}{Var(Z_t)}, \quad (2.1)$$

que é utilizada para a verificação da condição de estacionariedade. O seu gráfico, chamado de correlograma, será apresentado. O correlograma, conforme [MOR87a], pode ser utilizado para se verificar se uma série apresenta periodicidade. Pode-se demonstrar que se Z_t é da forma:

$$Z_t = A \cos(\omega t + \phi) \quad (2.1)$$

ou seja, tem uma periodicidade com frequência ω e período $2\pi/\omega$,

$$\gamma_k = \frac{A^2}{2} \cos k\omega, \quad (2.3)$$

ou seja, o correlograma apresentará uma periodicidade de mesma frequência.

2.3.2 Métodos de Previsão Considerados

Com a realização da análise exploratória dos dados, verificou-se a estrutura comportamental das séries em estudo. Baseado nesta análise e na busca de atender ao objetivo desta pesquisa será utilizado a análise de séries temporais, tendo como base os Métodos de Holt-Winters, Box-Jenkins (SARIMA) e Rede Neural Artificial (RNA) do tipo *Feedforward*, detalhados Capítulo 3.

Para o processo de escolha dos parâmetros dos modelos será utilizado o programa computacional R (pacote estatístico), pois este pacote possibilita implementar a escolha automática do modelo de previsão mais apropriado, de acordo com critérios pré-definidos.

Método de Holt-Winters

O modelo de suavização exponencial de Holt-Winters representa apropriadamente dados de demanda onde se verifica a ocorrência de tendência linear, além de um componente de sazonalidade [SOU03] e [EST03]. O modelo utiliza a idéia de suavização da série visando estimar o nível da série; estimar a taxa de crescimento e/ou decrescimento da série e estimar os fatores sazonais. Em cada um dos componentes estima-se um parâmetro de suavização diferente (α , β e γ). Conforme explicado na seção 3.3.1, [MAK98] e [HAN01] sugerem que se utilizem valores de α , β e γ , que minimizem a medida de erro adotado no estudo.

Uma função-perda que é utilizada frequentemente é o erro quadrático médio. Para a verificação do método que se ajusta melhor à série, utiliza-se uma comparação entre os erros encontrados nestes candidatos. Em geral, procura-se minimizar o erro médio quadrático, escolhendo-se aquele que apresentar menor erro. No caso do método de Holt-Winters os parâmetros são determinados pelo R através da minimização da soma dos erros quadráticos.

Método de Box-Jenkins

Nas séries que tem suas observações anotadas em intervalos de tempos iguais (modelos univariados), encontram-se os processos AR (auto-regressivo), MA (médias móveis), ARMA (auto-regressivo médias móveis), ARIMA (auto-regressivo médias móveis integrado), SARIMA (auto-regressivo médias móveis integrado sazonal) e outras derivações. Estes processos são também conhecidos por metodologia de Box-Jenkins devido às pesquisas e aprimoramentos realizados, e conseqüente popularização dos métodos por estes pesquisadores [BAR03].

Uma condição para os processos AR, MA e ARMA é que a série temporal discreta a ser trabalhada seja estacionária de segunda ordem (estacionariedade fraca) [BAR03]. Uma série estritamente estacionária (estacionariedade forte) é, segundo [KEN76], a que satisfaz os seguintes requisitos:

- i) $E(Y_t) = \mu$;
- ii) $E(Y_t - \mu)^2 = \sigma^2$, sendo σ^2 = variância de Y ;
- iii) $E(Y_t - \mu)(Y_{t+k} - \mu) = \gamma_k$, sendo a k -ésima autocovariância com a autocorrelação correspondente $\rho_k = \rho_{-k} = \gamma_k / \sigma^2$;

ou seja, que a série apresente todos seus momentos constantes. Para uma estacionariedade de

segunda ordem deve-se satisfazer os requisitos i e ii onde a média e a variância apresentam-se constantes [BOX94] e [MAK98].

Entretanto os processos ARIMA e SARIMA aceitam séries temporais discretas não estacionárias, porém homogêneas e em equilíbrio estatístico, entende-se por isso, séries que não contenham grandes saltos, “degraus” ou “explosões” nos valores observados. Para séries com estas características é indicada uma análise de intervenção identificando o efeito da ocorrência de algum evento especial [BOX94]. Os processos ARIMA e SARIMA são os mais utilizados já que na prática, em geral, as séries são não-estacionárias.

[MAK98] acrescenta uma preparação dos dados, como o uso de transformações para estabilização da variância e o uso de diferenças para obtenção de estacionariedade, utilizando para reconhecimento destes comportamentos o correlograma, que é a representação gráfica da função de autocorrelação cujos detalhes podem ser vistos em [MOR87b]. Portanto, têm-se as funções de autocorrelação (fac) e de autocorrelação parcial (facp) como ferramentas auxiliares para verificação de comportamentos da série e observação dos valores de p , P , d , D , q , Q e s .

A parametrização do modelo será feita de acordo com o critério de Akaike (AIC)⁸ o qual é baseado na teoria da decisão, tradicionalmente utilizado em seleção de modelos, considerando o pressuposto de estacionariedade. O critério de AIC utilizado para comparação de modelos leva em conta a variância do erro, o tamanho da amostra T e os valores de p , q , P e Q .

O AIC é uma medida de qualidade de ajuste. Foi desenvolvido para estimar a discrepância entre o modelo gerador de dados e um modelo candidato ajustado através de:

$$AIC = -2l(\theta) + 2p \quad (2.4)$$

onde, l é o \ln da função de verossimilhança do modelo em questão, θ é o vetor de parâmetros e p é a quantidade de parâmetros independentes do modelo. Este critério penaliza o modelo pela quantidade de parâmetros. Segundo [MAK98], por questões computacionais, utiliza-se a aproximação deste critério definido por:

$$AIC \cong n(1 + \log(2\pi)) + n \log \sigma^2 + 2m \quad (2.5)$$

⁸ AIC – Akaike Information Criteria.

onde, m é o número de parâmetros do modelo ($m=p+q+P+Q$), n é o número de observações da série e σ^2 é a variância dos resíduos.

O AIC pode ser empregado para comparar modelos com os mesmos efeitos fixos, mas diferentes estruturas de variância, sendo considerado melhor o modelo com o menor AIC. Para tanto um compromisso satisfatório entre o bom ajuste e o princípio de parcimônia⁹ pode ser alcançado aplicando-se este critério.

Para um bom ajuste do modelo de Box-Jenkins, é necessário utilizar técnicas em que a estrutura residual seja um ruído branco, isto é, que o resíduo seja uma variável aleatória independente e identicamente distribuída, ou seja, o modelo foi tão bem ajustado que somente restou a aleatoriedade dos dados que não pode ser explicada matematicamente. Neste sentido, são utilizados para análise testes estatísticos conhecidos por testes Portmanteau [BAR03].

Redes Neurais Artificiais

A rede neural artificial utilizada nesta pesquisa é do tipo *feedforward*, a qual é bastante conhecida e experimentada, e a mais largamente utilizada atualmente [CAL02]. Em redes do tipo *feedforward* os neurônios são dispostos em camadas, usualmente duas camadas ativas. Os neurônios de uma camada só se conectam com os da camada subsequente. Este modelo de rede está disponível no programa computacional R (pacote estatístico), tendo o algoritmo de retropropagação (algoritmo *backpropagation*) utilizado para o ajuste dos pesos.

Os neurônios da camada escondida ou intermediária necessitam ser definidos. Para muitos autores, segundo [FER95], o número de unidades das camadas escondidas se apresentam como incógnita e o tamanho da camada escondida é escolhido usando o bom senso: se a camada for muito grande, a rede estará memorizando os padrões e com isso perdendo a capacidade de generalização, por outro lado, se a camada for muito pequena, a rede levará muito mais iterações para atingir a precisão desejada.

A memorização no contexto de um modelo de RNAs, é equivalente ao problema econométrico da super-parametrização do modelo. Quando a RNA memoriza um certo conjunto de dados ela vai apresentar pequenos erros de previsão para o período amostral, mas grandes erros para previsões fora da amostra [FER95].

Neste sentido, [CAL02] diz que, em qualquer problema a ser resolvido através do uso de redes neurais, é necessário o uso de pares de entrada-saída já conhecidos. Muitas vezes a

⁹ Representação dos modelos matemáticos, com a menor quantidade de parâmetros possível.

quantidade de pares disponíveis não é muito grande, mesmo assim deve-se separar esses dados em dois conjuntos bem definidos, o conjunto de treinamento e o conjunto de teste. O treinamento da rede é feito utilizando o conjunto de treinamento. É, entretanto, necessário medir a performance da rede, considerando como ela responde a pares entrada-saída não apresentados durante o treinamento, ou seja, o conjunto de teste.

Conforme [CAL02], isto é importante, pois um treinamento prolongado demais gera um problema conhecido como *overtraining*, que pode levar a uma super-especialização da rede (principalmente quando se dispõe de muito poucos dados) e a uma perda da capacidade da rede de responder bem a dados nunca apresentados (perda da capacidade de generalização). A partir de um certo número de passos, a performance do conjunto de teste pára de decair e começa a piorar, mesmo que a do conjunto de treinamento continue decaindo. Inicia-se a super-especialização. É virtualmente aceito que a melhor rede é aquela que fornece o menor erro no conjunto de validação¹⁰ e aquela que fornece o mínimo erro para o conjunto de teste [CAL02]. A busca, portanto, da melhor configuração para a camada escondida da rede é feita de forma a minimizar o número de neurônios nesta camada sem que haja perda de capacidade preditiva [FER95].

2.3.3 Critério de Validação

Depois de identificar os parâmetros dos métodos de previsão mais adequados a cada produto determinado ou sua categoria, conforme detalhado na seção 2.3.2, será necessário realizar uma análise entre os métodos levando em consideração o seu desempenho em relação às previsões. No caso, desta pesquisa, optou-se pela utilização do erro absoluto médio percentual (EAMP) como critério para validar o modelo definido (ajustado), com vistas à realização das previsões, o qual, segundo [HAN01], é útil quando o tamanho ou magnitude da variável de previsão é importante na avaliação da acurácia da previsão.

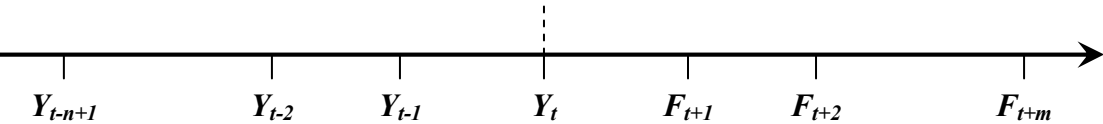
Para a realização da comparação dos métodos de previsão, será utilizado um subconjunto de teste com 36 observações, obtido da série integral que compreende 39 observações, permanecendo assim três observações para comparação das previsões obtidas com os valores das observações realizadas.

Em relação ao número de observações ou número de períodos de tempo necessários

¹⁰ O conjunto de validação ou treinamento corresponde a pares entrada-saída que não são apresentados à rede durante o treinamento e não são parâmetros para encerrar o treinamento, ou seja, representam um conjunto totalmente novo a ser apresentado à rede para avaliação de desempenho [CAL02].

para um estudo em séries temporais, [KEN76] descreve que o número de observações em uma série temporal não é por si uma medida completa de informação. O que pode ser observado é que o acréscimo ou decréscimo do número de observações auxilia no reconhecimento de algum comportamento nos dados.

Baseado no histórico disponível e conforme [MAK98], o cenário para previsão da demanda apresenta-se como demonstrado na Figura 2.4. Onde, Y é a variável de interesse e n o número de observações conhecidas da série, considera-se que numa linha cronológica, a partir de um ponto de referência (Y_t), as observações ocorridas no passado localizam-se à esquerda deste ponto e são denominadas por $Y_{t-1}, Y_{t-2}, \dots, Y_{t-n+1}$. Os valores futuros localizam-se à direita e são denominados por F_{t+1}, \dots, F_{t+m} , onde m é o número de valores estimados para a variável, a partir do ponto de referência.

	
Série Integral	Subconjunto de Teste
<ul style="list-style-type: none"> • $n = 39$ observações • $Y =$ valores observados • $F =$ valores futuros • $t =$ julho/2007 	<ul style="list-style-type: none"> • $n = 36$ observações • $Y =$ valores observados • $F =$ valores futuros • $t =$ abril/2007

Fonte: Adaptado de [BAR03]

Figura 2.4: Cenário de previsão da demanda.

No ANEXO A, encontram-se as 39 observações relativas à demanda real, conforme descrito na seção 2.2, bem como, as previsões para os meses de maio, junho e julho de 2007 realizadas pelo método de previsão utilizado pela empresa. O método de previsão utilizado pela empresa não foi divulgado, apenas que o mesmo é quantitativo e está integrado ao sistema ERP. A previsão para os meses citado acima se deu para os 3 períodos de uma só vez e não período a período.

Com base nas previsões realizadas pelos métodos em análise será observado se a previsão está enviesada, podendo estar subestimada ou superestimada, o que é proporcionado pelo TS, conforme descrito na seção 3.4.7 e serão analisados os erros das previsões, proporcionado pelo EAMP.

Para verificar qual método apresenta o menor erro, ou seja, maior precisão será analisado o intervalo de confiança dos erros de cada categoria, o qual é um método usual de especificação da precisão, de forma a estabelecer um intervalo de valores plausíveis para a realização da comparação do erro entre os métodos.

Neste sentido, para a obtenção do intervalo de confiança, será utilizada a distribuição *t* (*Student*) com $n-1$ graus de liberdade, para coeficiente de confiança $(1 - \alpha)$ desejado de 95%. Uma vez que o comprimento do intervalo de confiança mede a precisão da estimação, a intenção será da obtenção de um intervalo relativamente curto e com alta confiança, considerando-se a média e o desvio-padrão da amostra.

Como análise estatística para a comparação dos erros entre os métodos será realizado um teste de hipóteses de médias, a análise da variância ou ANOVA, o qual é um procedimento muito útil para avaliar se as diferenças observadas entre as médias das amostras são estatisticamente significantes.

Também será aplicado o teste de Tukey, o qual se baseia na diferença mínima significativa, para determinar quais grupos diferem entre si, realizando a comparação múltipla entre médias. Como o teste de Tukey controla o erro tipo I, este é um teste muito utilizado pelos estatísticos. Estes dois testes serão realizados no pacote estatístico R.

Capítulo 3

Referencial Teórico

Este capítulo apresenta o referencial teórico, que aborda o atual estado da arte dos assuntos diretamente relacionados à dissertação, que são: conceitos de previsão com base em séries temporais e métodos de previsão.

3.1. Previsão

Quando se analisa uma série temporal $Z(t_1), \dots, Z(t_N)$, observada nos instantes t_1, \dots, t_N , os objetivos são os mais variados possíveis. Segundo [MOR87a], os objetivos básicos são os seguintes:

- Modelagem do fenômeno sob consideração;
- Obtenção de conclusões em termos estatísticos;
- Avaliação da adequação do modelo em termos de previsão.

Dentre os objetivos da análise de séries temporais mencionados, um deles é a avaliação do modelo em termos de previsibilidade¹¹ de valores futuros da série sob consideração. A previsão de séries temporais é somente o estabelecimento de valores futuros para a série, e é feita com base tanto na informação atual quanto na passada. O horizonte de previsão é o comprimento do tempo, contado a partir de uma origem predeterminada (origem da previsão).

Para [MAK98] ao analisar a ciência da previsão observa que a eficiência da previsão varia de acordo com o horizonte de previsão necessário. Na medida em que o horizonte

¹¹ Prever é o processo de estimar um evento futuro baseado em dados passados (histórico). Estes dados são combinados sistematicamente de uma forma predeterminada até se obter uma estimativa futura [SIL02].

aumenta, os resultados da previsão se tornam mais suscetíveis a erros aumentando a incerteza da previsão. Segundo [GIL06] as causas de erros comuns de previsão que muitas vezes fazem com que as técnicas de previsão sejam consideradas incorretas e inadequadas, em muitos casos, na realidade são causados por erros nos dados ou falhas na análise dos resultados, gerando os erros de previsão.

Em face da inerente falta de acurácia no processo, por que é necessária a previsão? A resposta é que todas as organizações operam em uma atmosfera de incerteza e que, apesar deste fato, as decisões que afetam o futuro da organização devem ser tomadas. As suposições ponderadas sobre o futuro são mais valiosas aos gerentes da organização do que as suposições não ponderadas [HAN01].

Quando os gerentes da organização são confrontados com a necessidade de tomar decisões em uma atmosfera de incerteza, que tipos de previsões estão disponíveis para eles? Os procedimentos de previsão podem primeiramente ser classificados com relação ao prazo, longo ou curto. As previsões de longo prazo são necessárias para ajustar o curso geral de uma organização para o funcionamento de longo alcance, assim, transformam-se no foco particular da alta gerência. As previsões de curto prazo são usadas para estabelecer estratégias imediatas e são usadas pela gerência média e operacional para encontrar as necessidades do futuro imediato [HAN01].

Ainda segundo [HAN01], as previsões podem também ser classificadas nos termos de sua posição em um *continuum* micro-macro, isto é, na extensão em que envolvem detalhes pequenos contra grandes valores concisos. Por exemplo, um gerente de planta pôde estar interessado em prever o número dos trabalhadores necessários para diversos meses seguintes (uma micro previsão), enquanto que o governo federal está prevendo o número total das pessoas empregadas no país inteiro (uma macro previsão). Outra vez, os níveis diferentes da gerência em uma organização tendem a focalizar em níveis diferentes do *continuum* micro-macro. A alta gerência estaria interessada em prever as vendas da companhia inteira, por exemplo, enquanto que os vendedores individualmente estariam muito mais interessados em prever seus próprios volumes de vendas.

Desta forma, percebe-se que há dois enfoques a considerar quando se deseja fazer previsões em alguma área. No primeiro, o analista se baseia na teoria (econômica, física, etc.) para construir um modelo, enquanto no segundo o modelo é obtido diretamente dos dados disponíveis, sem recorrer a uma possível teoria subjacente. Este segundo procedimento é

chamado de estatístico ou de séries temporais, o qual é o enfoque desta pesquisa (previsão baseada em séries temporais).

Existem diversas classificações para formalização de algoritmos de previsão de séries temporais. Uma possibilidade é dividir os métodos matemáticos de previsão em dois grupos:

- Métodos no domínio do tempo:
 - Métodos paramétricos;
 - Métodos não-paramétricos;
- Métodos no domínio da frequência.

Os métodos paramétricos utilizam estruturas matemáticas parametrizadas para descrever o comportamento dinâmico, no domínio do tempo. Os parâmetros destas estruturas matemáticas são determinados através de algoritmos de estimação, a partir dos dados medidos. Os métodos não-paramétricos também obtêm modelos no domínio do tempo e o comportamento dinâmico é determinado através de funções de correlação dos dados disponíveis. Os métodos no domínio da frequência configuram modelos utilizando ferramentas matemáticas, tais como: *wavelets* e transformada de Fourier, para o cálculo da resposta em frequência do sistema sob análise.

Normalmente as séries temporais são analisadas a partir de seus principais movimentos descritos como: tendência, ciclo, sazonalidade e variações aleatórias [MOR04]. As séries temporais podem também apresentar comportamentos cíclicos, variações periódicas. Ou seja, alguma dependência cíclica. É conveniente que se faça a medição da mesma a partir dos dados disponíveis e inclua esse comportamento (por exemplo, a sazonalidade, um caso particular do ciclo) dentro do modelo de previsão. Existem vários procedimentos para estimar a componente sazonal, sendo que os mais usuais são [MOR87a]:

- Método de Regressão (método paramétrico);
- Método de Médias Móveis (método não-paramétrico);
- Método de Diferença Sazonal (sazonalidade determinística).

Uma série sazonal é definida como uma série temporal com um padrão de mudança que se repete ano após ano (sazonalidade trimestral, semestral, etc.). Desenvolver uma técnica de previsão sazonal envolve geralmente selecionar um método de decomposição multiplicativo ou aditivo, e então estimar os índices sazonais do histórico da série. Estes índices são usados então para incluir a sazonalidade nas previsões ou remover tais efeitos dos

valores observados. O último processo é referenciado como ajustamento sazonal dos dados ou desazonalização [HAN01].

As técnicas de previsão da demanda para dados com sazonalidade são usadas sempre que:

- O tempo influencia a variável de interesse. São exemplos o consumo de energia elétrica, as atividades do verão e do inverno (como por exemplo, esportes), e as estações de colheita ou plantio na agricultura.
- O calendário anual influencia a variável de interesse. Os exemplos são vendas de varejo influenciadas por feriados, por fins de semana prolongados, e pelo calendário escolar.

As técnicas que devem ser consideradas ao prever a demanda de uma série sazonal incluem a decomposição clássica, Census X-12, suavização exponencial de Winters, a regressão múltipla de séries temporais e os modelos SARIMA (métodos de Box-Jenkins) [HAN01].

É importante observar que um modelo não conduz necessariamente a uma estimativa de previsão. Será necessário especificar, além do modelo, uma função-perda ou erro, para se chegar a uma estimativa de qual será a previsão da demanda. Uma função-perda, que é utilizada frequentemente é o erro quadrático médio (EQM), embora em algumas ocasiões outros critérios ou funções-perdas sejam mais apropriados [MOR87a] e [MOR04].

3.2. Séries Temporais

Em muitas áreas do conhecimento as observações de interesse são obtidas em instantes sucessivos de tempo (séries temporais discretas) ou registradas por algum equipamento de forma contínua (séries temporais contínuas). Chama-se de série temporal um conjunto de observações ordenadas no tempo. Pode-se, então, definir uma série temporal como sendo um grupo de dados observados (um conjunto de observações de uma variável) durante um determinado intervalo de tempo, sendo esse espaço de tempo entre os dados disponíveis equiespaçados (horários, diário, semanal, mensal, trimestral, anual, e etc.) [MOR87a].

Há, basicamente, dois enfoques usados na análise de séries temporais. Em ambos o objetivo é construir modelos para as séries, com propósitos determinados. No primeiro

enfoque, a análise é feita no domínio do tempo. No segundo, a análise é conduzida no domínio de frequências. Essas duas formas de análise não são alternativas, mas sim complementares. No entanto, sabe-se que a primeira se adequa mais a análise de processos não determinísticos, enquanto a segunda, a processos determinísticos [MOR87b] e [EST03].

Na análise no domínio do tempo considera-se a evolução da série temporal do processo que está sendo estudado, tendo como objetivo a determinação da magnitude de cada evento nos diversos instantes da série. As ferramentas utilizadas para essa análise são duas funções: a função de autocorrelação e a função de autocorrelação parcial. A função de autocorrelação mede a relação entre os eventos em diferentes instantes e as suas magnitudes. A análise é baseada, em geral, por modelos paramétricos [EST03].

Os desenvolvimentos contemporâneos no domínio do tempo foram influenciados pelo importante livro de Box e Jenkins, de 1970, *Time series analysis: forecasting and control* [BOX94]. Estes autores desenvolveram a metodologia do domínio do tempo ordenando alguns de seus temas principais e aplicando-os a funções importantes como a previsão da demanda e o controle. Demonstraram quão amplos torna-se o escopo da análise das séries temporais pela aplicação a problemas tão diversos tais como a previsão da demanda de números de passageiros de uma linha aérea e da análise do processo de combustão em uma fornalha a gás [POL99].

Na análise no domínio da frequência, o interesse está em verificar a frequência que alguns eventos ocorrem em determinado período de tempo. A ferramenta utilizada para essa análise é a análise espectral, nela são estabelecidas às características de um processo estocástico em termos de frequências, podendo, no caso das séries temporais determinarem as periodicidades existentes na mesma. Como o espectro de um processo não é conhecido, ele precisa ser estimado. Em geral, é estimado através do periodograma de janelas espectrais, por possuir boas propriedades estatísticas [EST03].


Nestes dois distintos, contudo equivalentes, modos de análise de séries temporais existem alguns pontos a considerar. Os métodos do domínio do tempo têm sua origem na teoria clássica da correlação. Tais métodos tratam preponderantemente das funções de autocovariância e de covariância cruzada da série, e conduzem inevitavelmente para a construção de modelos estruturais ou paramétricos do tipo média móvel auto-regressivo (ARMA) para uma única série e do tipo função de transferência para duas ou mais séries causalmente relacionadas. Muitos dos métodos que são usados para estimar os parâmetros

destes modelos podem ser vistos como variantes sofisticadas do método da regressão linear [MOR04].

Do outro lado estão os métodos do domínio da frequência, onde se tem a análise espectral, que consiste em decompor a série dada em componentes de frequência. Estes são baseados em uma extensão dos métodos da análise de Fourier que se originaram na idéia de que, sobre um intervalo finito, toda a função analítica pode ser aproximada, ao grau de acurácia desejado, a uma soma de funções seno e co-seno do aumento harmônico das frequências [MOR04].

A série temporal pode ser classificada como determinística ou estocástica (o conjunto de todas as possíveis trajetórias que se poderia observar; trajetória aleatória). Quando os valores da série podem ser escritos através de uma função matemática $y = f(tempo)$, diz-se que a série é determinística. Quando a série envolve além de uma função matemática do tempo também um termo aleatório $y = f(tempo, \varepsilon)$ chama-se a série de estocástica [MOR04].

Muitas situações em ciências físicas, engenharia, ciências biológicas e humanas envolvem o conceito de sistema dinâmico, caracterizado por uma série de entrada $X(t)$, uma série de saída $Z(t)$ e uma função de transferência $v(t)$, como demonstrado na Figura 3.1.



Fonte: [MOR04]

Figura 3.1: Sistema dinâmico.

De particular importância são os sistemas lineares, onde a saída é relacionada com a entrada através de uma função linear envolvendo $v(t)$. Um exemplo típico é:

$$Z(t) = \sum_{\tau=0}^{\infty} v(\tau) X(t-\tau) \quad (3.1)$$

Para que uma determinada série seja tratada com métodos particulares para uma série temporal, é necessário que preencha outro pré-requisito: os dados também devem apresentar uma dependência serial entre eles. Por exemplo: os dados de uma variável aleatória Z no instante t , com t variando de 1 até N , possa, de certa maneira, conter informações necessárias para que seja determinado o valor dessa variável no instante $t+1$. Cabe mencionar, que N representa o número de observações da série temporal em questão. As séries temporais podem ser classificadas, como mencionado, como discretas, contínuas, determinísticas, estocásticas, bem como, multivariadas e multidimensionais [BAR03] e [MOR04].

Um modelo clássico para séries temporais supõe que a série Z_1, \dots, Z_N possa ser escrita como a soma de três componentes: tendência, componente sazonal e um termo aleatório:

$$Z(t) = T_t + S_t + a_t, t = 1, \dots, N. \quad (3.2)$$

3.3 Métodos de Previsão¹²

Os métodos de previsão podem ser agrupados em métodos quantitativos e métodos qualitativos [MAK98] e [HAN01]. Em um extremo, uma técnica puramente qualitativa é uma que não requer nenhuma manipulação de dados. Somente o "julgamento" da previsão é usado. Mesmo aqui, naturalmente, o "julgamento" da previsão é realmente um resultado da manipulação mental de dados históricos passados. No outro extremo, as técnicas puramente quantitativas não necessitam da entrada de julgamento; eles são procedimentos mecânicos que produzem resultados quantitativos. Alguns procedimentos quantitativos requerem uma manipulação muito mais sofisticada dos dados do que outros, naturalmente [HAN01].

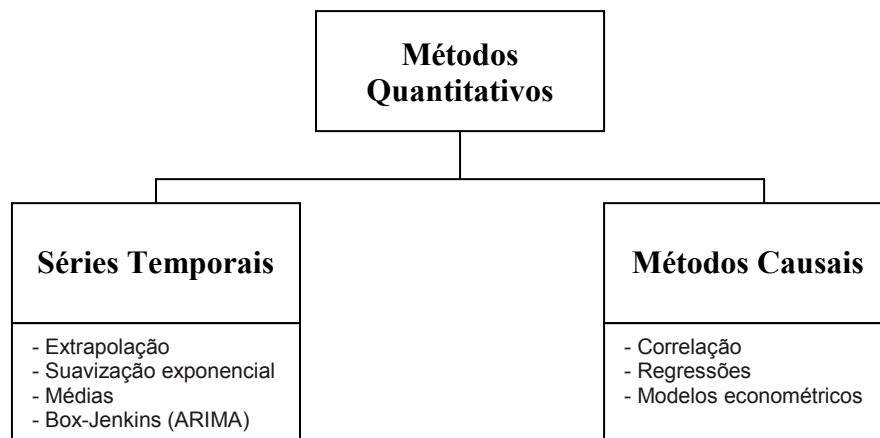
Os métodos qualitativos são métodos analíticos, considerados métodos de predição, baseados no julgamento, intuição, experiência dos envolvidos, entrevista com especialistas, pesquisa de mercado, entre outros, e usados para criar cenários futuros. Os métodos quantitativos são métodos analíticos baseados em um modelo matemático e são considerados métodos de previsão.

¹² Segundo [MOR04], não há algo chamado método de previsão ou algo chamado método de previsão ARMA. Há algo chamado método de previsão de mínimos quadrados, e este, de fato fornece a base para virtualmente todos os estudos teóricos. Além disso, todos os métodos de previsão são simplesmente diferentes procedimentos computacionais para calcular a mesma quantidade, a saber, a previsão de mínimos quadrados de um valor futuro a partir de combinações lineares de valores passados.

Os métodos quantitativos de previsão utilizam o padrão histórico dos dados para extrapolar o seu comportamento futuro. Existem dois grandes grupos de procedimentos quantitativos: a análise de séries temporais e os modelos causais (ou estruturais).

Os modelos causais descrevem a demanda como função de variáveis independentes, ou seja, buscam relacionar as demandas (variável dependente) com outros fatores tais como PIB, inflação, clima, perfil de população, denominados variáveis independentes. Para isso são utilizadas técnicas de regressão linear e não-linear. Dentre os modelos causais mais conhecidos, destacam-se os modelos de regressão simples e múltipla. Os modelos causais aumentam o erro de predição por demandarem predições das variáveis independentes em tempos futuros. Ou seja, para obter previsões de modelos causais acerca de uma variável de interesse, serão necessárias previsões acerca das variáveis independentes utilizadas na construção do modelo [FOG03] e [PAC03].

Na análise de séries temporais são considerados os modelos de suavização exponencial simples, de suavização exponencial dupla (para dados com tendência) e o modelo de Winters, para dados com variação sazonal [FOG03].

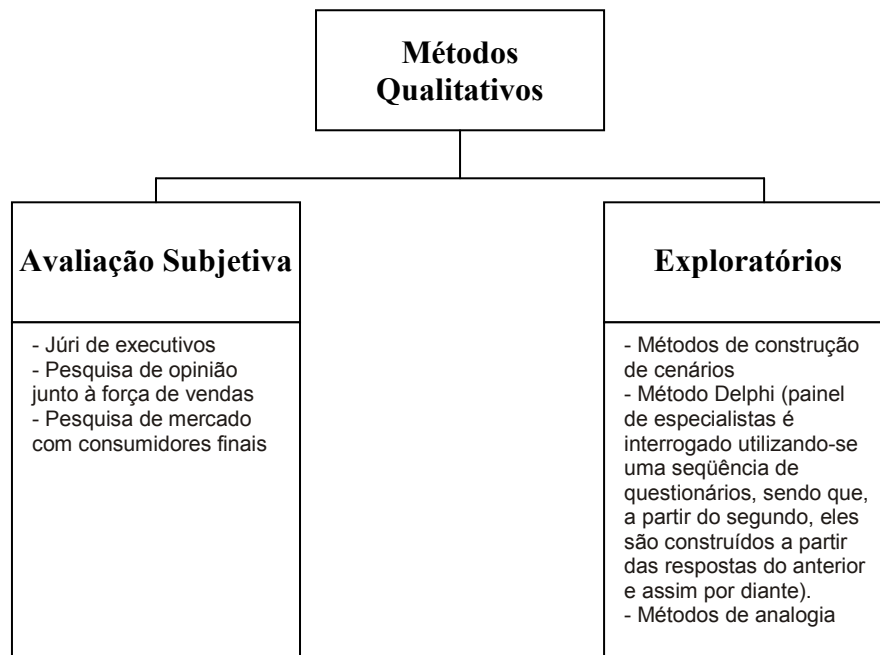


Fonte: Adaptado de [SIL02]

Figura 3.2: Métodos quantitativos.

Os métodos qualitativos são usados quando dados históricos são inexistentes ou escassos. Estes métodos vêm encontrando crescente aplicação prática devido à alta customização dos produtos, o que resulta em séries históricas com poucos dados devido ao rápido ciclo de vida dos produtos, e ao crescente lançamento de novos produtos no mercado.

Os métodos qualitativos são baseados em opiniões de especialistas. Estes analisam situações similares, em conjunto com os dados existentes, para prever valores futuros de demanda. Os métodos difundidos de previsão qualitativa estão associados à pesquisa de mercado, e incluem a utilização de grupos focados e técnicas de consenso. Das técnicas de consenso, a mais difundida é o método Delphi [FOG03].



Fonte: Adaptado de [SIL02]

Figura 3.3: Métodos qualitativos.

A previsão combina dados via um modelo matemático para estimar eventos futuros, já a predição estima eventos futuros com base em considerações subjetivas, sem combinações predeterminadas [SIL03].

Os métodos quantitativos são os mais usados em ferramentas de apoio à decisão. Os modelos são baseados em dados históricos e no comportamento passado de determinado fenômeno. Na Tabela 3.1 é apresentado uma breve descrição dos métodos quantitativos.

As previsões baseadas em informações provenientes de dados históricos, segundo [MOR87b], possuem três componentes básicas que contemplam padrões de comportamento do fenômeno, como:

- Tendências;
- Sazonalidade;

- Variações aleatórias.

Tabela 3.1: Descrição dos métodos quantitativos.

Método Quantitativo	Descrição
Extrapolação	A partir de dados passados de vendas, da análise das sazonalidades e dos ciclos de vendas projeta-se a previsão de vendas.
Suavização Exponencial	Aplicação particular da média ponderada e da média móvel – premissa de que os dados disponíveis para o cálculo da previsão tornam-se cada vez menos relevantes conforme o aumento de sua idade. Há a associação de pesos mais altos aos dados mais recentes.
Média Simples	Previsão é feita a partir da média aritmética das demandas passadas. Considera o mesmo peso para todos os dados históricos.
Média Móvel	Muito útil na suavização de curvas que representam tendências e atenuação de distorções (como sazonalidades). Média dos N dados mais recentes. Atribui o mesmo peso para todos os dados no cálculo da previsão, além de necessitar de uma grande quantidade de dados para a produção de bons resultados.
Box-Jenkins (ARIMA)	Considera-se série histórica de vendas, em ordem cronológica, em que se realizam análises de autocorrelações e autocorrelações parciais, para se identificar o modelo, estimar os parâmetros, minimizando o erro quadrático. O modelo requer o diagnóstico dos resíduos. Ferramenta acurada e custosa, que requer maior tempo para a análise.
Correlação e Regressão	A análise de regressão é muito utilizada para o desenvolvimento da função de demanda (pode envolver fator simples ou múltiplos fatores). A relação de correlação entre os diversos fatores pode ser linear ou não (logarítmica, exponencial, etc.).
Modelos Econométricos	São consideradas variáveis endógenas, como exógenas. São modelos complexos que requerem a utilização de especialistas em estatística e economia.

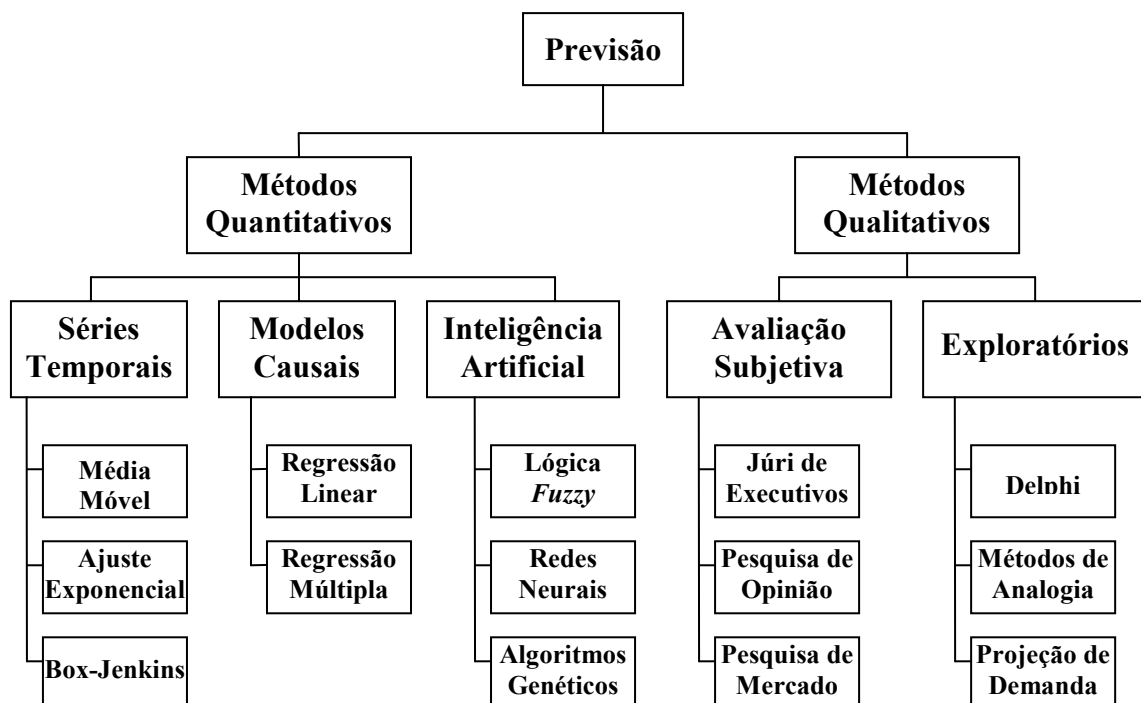
Fonte: Adaptado de [SIL02]

Segundo [SIL03], deve-se ainda considerar três condições básicas para a utilização de dados históricos em modelos de previsão, que são os seguintes:

- A existência de informações históricas;
- As informações históricas podem ser transformadas em dados numéricos;
- Padrões passados podem ser repetidos no futuro.

O objetivo de qualquer modelo de previsão é prever o componente sistemático da demanda e estimar a variabilidade do componente aleatório.

A discussão anterior sugere diversos fatores a serem considerados ao escolher um método de previsão. O nível do detalhe deve ser considerado. São necessários detalhes específicos de previsão (uma micro previsão)? Ou é necessário o *status* futuro de algum fator total ou de um fator conciso (uma macro previsão)? É a previsão necessária para algum ponto no futuro próximo (uma previsão de curto prazo) ou para um ponto no futuro distante (uma previsão de longo prazo)? E em relação aos métodos apropriados são qualitativos (julgamento) e quantitativos (dados manipulados)?



Fonte: Adaptado de [SIL03] e [SIL02]

Figura 3.4: Métodos para previsão da demanda.

A consideração dominante ao escolher um método de previsão é que os resultados devem facilitar o processo de tomada de decisão dos gerentes da organização. A exigência essencial, então, não é que o método de previsão envolva um processo matemático complicado ou que seja o método mais recente em termos de sofisticação. Preferivelmente, o método escolhido deve produzir uma previsão que seja exata, oportuna, e compreendida pela gerência de modo que a previsão possa ajudar a produzir decisões melhores. Também, o uso

do procedimento de previsão deve produzir um benefício que esteja adequado ao custo associado com seu uso (relação custo/benefício) [HAN01].

Todos os procedimentos formais de previsão envolvem estender as experiências do passado para o futuro incerto. Assim, eles envolvem a suposição que as circunstâncias que geraram dados passados são indistinguíveis das condições do futuro à exceção daquelas variáveis reconhecidas explicitamente pelo modelo de previsão. Se alguma previsão for realizada avaliando o desempenho do trabalho dos empregados usando somente o exame da contagem da entrada na empresa como uma predição, por exemplo, está supondo-se que cada avaliação de desempenho do trabalho pessoal está relacionada somente ao exame da contagem de entrada. Até ao ponto em que esta suposição de indistinguível do passado e do futuro não é encontrada totalmente, resultam nas previsões inexatas a menos que elas sejam modificadas pelo julgamento de quem está realizando a previsão.

O reconhecimento que as técnicas de previsão operam sobre a geração de dados por eventos históricos conduz à identificação das seguintes cinco etapas no processo de previsão [HAN01]:

- a. Coleta de dados;
- b. Redução de dados ou condensação (tratamento dos dados);
- c. Construção do modelo e avaliação;
- d. Extrapolação do modelo (a previsão atual, real);
- e. Avaliação da previsão.

Os procedimentos de previsão de séries temporais, de acordo com [MOR87a], podem ser divididos em duas categorias:

- Automáticos, que são aplicados diretamente, com a utilização de programas simples de computador;
- Não-automáticos, que exigem a intervenção de pessoal especializado, para serem aplicados.

É evidente que mesmo aqueles procedimentos incluídos entre os automáticos requerem do usuário um mínimo de conhecimento e prática para serem utilizados. Dentre os procedimentos automáticos podem ser mencionados:

- Modelos de alisamento ou suavização (alisamento exponencial simples, linear

de Brown, biparamétrico de Holt, sazonal de Holt-Winters, etc.);

- Auto-regressão *stepwise*;
- Filtragem adaptativa.

Os métodos de previsão não-automáticos incluem:

- Método Box-Jenkins; método Bayesiano.

Para que sejam estabelecidos valores futuros para a série em estudo, é necessário que, de alguma forma, se possa captar e formular um modelo matemático capaz de representar o comportamento e as características da série temporal que se deseja prever. Essas informações são extraídas dos dados disponíveis. Existe uma grande quantidade de modelos de previsão, na literatura estatística adequados para exercer tal tarefa, e eles são classificados da seguinte forma:

- Modelos univariados: os valores futuros de uma série são explicados somente pelos valores passados dessa mesma série. Os métodos de decomposição, métodos de suavização (amortecimento) exponencial e os modelos Box&Jenkins (ARIMA) estão enquadrados dentro dessa classificação.
- Modelos causais ou modelos de função de transferência: os valores futuros de uma série são explicados não somente pelos valores passados da mesma, mas também por séries que de alguma forma possuam relação com ela.
- Modelos multivariados: são modelos capazes de realizar várias previsões ao mesmo tempo, um modelo único capaz de prever o futuro de diversas séries.

Conforme o objetivo desta pesquisa, descrito na seção 1.2, com base nos conceitos apresentados na seção 3.3 e levando em consideração o comportamento sazonal dos dados fornecidos, na sequência é apresentado o referencial teórico dos métodos utilizados neste estudo para análise dos dados. A seção 3.3.1 apresenta o método de suavização exponencial e a seção 3.3.2 os modelos de Box-Jenkins relacionados aos métodos tradicionais de estatística e a seção 3.3.3 apresenta as redes neurais artificiais relacionado à inteligência artificial.

3.3.1 Método de Suavização Exponencial

Os métodos de suavização exponencial para séries temporais formam uma grande classe de métodos que procuram captar as informações contidas nos próprios valores da série; ou seja, buscam traduzir as influências ocorridas nas observações ao longo do tempo através delas mesmas. Se um fato externo acarreta mudanças de valores da variável em estudo, então a consequência deste fato já está embutida nos valores observados passados que resultarão em respostas futuras [BAR03].

Dentro desta idéia, verifica-se que se as observações de uma determinada série encontram-se em torno de uma média constante, com variância constante, a melhor previsão a longo prazo para esta série seria a própria média. Caso a média altere ao longo do tempo apresentando uma tendência crescente ou decrescente, isto deverá ser considerado e, neste caso, a melhor previsão será a média acrescida de uma constante que traduza a tendência encontrada. O mesmo ocorrerá se uma estrutura sazonal for percebida na série onde será necessário buscar uma maneira de refletir esta sazonalidade [BAR03].

Para tanto, os métodos de suavização exponencial dispõem de equações que consideram o nível, a tendência e a sazonalidade, e que são aplicadas conforme as características encontradas na série, formando conjuntos específicos destas equações. Por exemplo, se a série é somente caracterizada como tendenciosa, o conjunto de equações resultantes a ser utilizado para a previsão desta série será composto de três equações, sendo que uma considerará o nível da série, outra considerará a tendência e por último a equação que efetivamente fornecerá o próximo valor da série; ou seja, uma previsão pontual para o futuro [EST03] e [BAR03].

Para facilitar a escolha do método a ser utilizado devido à estrutura existente nos dados, [PEG69] propôs um resumo apresentado na Tabela 3.2, onde relaciona os métodos e suas equações às características de comportamento dos dados. A série é representada por Y , os componentes estruturais são representados por L para nível, b para tendência e S para sazonalidade, os índices t indicam o instante da observação no tempo, m o número de períodos a frente da última observação realizada, e s para a periodicidade da estrutura sazonal, α, β, γ são constantes de suavização e variam entre 0 e 1, e finalmente, F representa o valor da observação prevista [HYN02], [BIL06] e [BAR03].

Tabela 3.2: Esquema de classificação.

		Componente Sazonal		
		Nenhum 1	Aditivo 2	Multiplicativo 3
Componente Tendência	Nenhum A	$L_t = \alpha Y_t + (1 - \alpha)L_{t-1}$ $F_{t+m} = L_t$	$L_t = \alpha(Y_t - S_{t-s}) + (1 - \alpha)L_{t-1}$ $S_t = \gamma(Y_t L_t) + (1 - \gamma)S_{t-s}$ $F_{t+m} = L_t + S_{t+m-s}$	$L_t = \alpha \frac{Y_t}{S_{t-s}} + (1 - \alpha)L_{t-1}$ $S_t = \gamma \frac{Y_t}{L_t} + (1 - \gamma)S_{t-s}$ $F_{t+m} = L_t S_{t+m-s}$
	Aditivo B	$L_t = \alpha Y_t + (1 - \alpha)(L_{t-1} + b_{t-1})$ $b_t = \beta(L_t - L_{t-1}) + (1 - \beta)b_{t-1}$ $F_{t+m} = L_t + mb_t$	$L_t = \alpha(Y_t - S_{t-s}) + (1 - \alpha)(L_{t-1} + b_{t-1})$ $b_t = \beta(L_t - L_{t-1}) + (1 - \beta)b_{t-1}$ $S_t = \gamma(Y_t - L_t) + (1 - \gamma)S_{t-s}$ $F_{t+m} = L_t + mb_t + S_{t+m-s}$	$L_t = \alpha \frac{Y_t}{S_{t-s}} + (1 - \alpha)(L_{t-1} + b_{t-1})$ $b_t = \beta(L_t - L_{t-1}) + (1 - \beta)b_{t-1}$ $S_t = \gamma \frac{Y_t}{L_t} + (1 - \gamma)S_{t-s}$ $F_{t+m} = (L_t + mb_t)S_{t+m-s}$
	Multiplicativo C	$L_t = \alpha Y_t + (1 - \alpha)(L_{t-1}b_{t-1})$ $b_t = \beta \frac{L_t}{L_{t-1}} + (1 - \beta)b_{t-1}$ $F_{t+m} = L_t b_t^m$	$L_t = \alpha(Y_t - S_{t-s}) + (1 - \alpha)(L_{t-1}b_{t-1})$ $b_t = \beta \frac{L_t}{L_{t-1}} + (1 - \beta)b_{t-1}$ $S_t = \gamma(Y_t - L_t) + (1 - \gamma)S_{t-s}$ $F_{t+m} = L_t b_t^m + S_{t+m-s}$	$L_t = \alpha \frac{Y_t}{S_{t-s}} + (1 - \alpha)(L_{t-1}b_{t-1})$ $b_t = \beta \frac{L_t}{L_{t-1}} + (1 - \beta)b_{t-1}$ $S_t = \gamma \frac{Y_t}{L_t} + (1 - \gamma)S_{t-s}$ $F_{t+m} = L_t b_t^m S_{t+m-s}$

Fonte: [PEG69]

Tem-se que as células da Tabela 3.2: A-1, B-1, B-2 e B-3 são conhecidas como método de alisamento exponencial simples, método de Holt, método de Winters aditivo e método de Winters multiplicativo, respectivamente [HYN02] e [BAR03].

A robustez e a acuracidade dos métodos de suavização exponencial, tem levado a um grande aumento das formas de aplicação e utilização do método. Principalmente, nos casos onde um grande número de séries temporais precisam ser atualizadas através de um procedimento automático, tal como ocorre, por exemplo, no caso do controle de estoques [SOU05]. Entretanto, existe uma variedade de séries temporais que não se ajustam facilmente a modelagem via suavização exponencial tradicional. As séries com variação cíclica ou sazonal se enquadram dentro desse perfil de série.

Para essas séries temporais que apresentam um padrão de comportamento mais complexo, existem outras formas de suavização tais como:

- Método de Holt-Winters;
- Método de suavização exponencial geral (Método de Brown).

O modelo de suavização exponencial de Holt-Winters é um procedimento bastante popular para a previsão de séries temporais que possuem ciclos sazonais. Um fator importante

para a sua popularidade é a sua simplicidade e facilidade de implementação computacional. Além de ser um procedimento heurístico, sendo as suas equações de atualização obtidas de forma intuitiva [SOU05] e [EST03].

Segundo [MAK98], no ano de 1957 Holt expandiu o modelo de suavização exponencial simples para lidar com dados que apresentavam tendência linear e, assim realizar previsões que fossem mais precisas que as realizadas com suavização exponencial simples, por ajustá-las a esta condição. Em 1960, Winters estendeu o modelo de Holt, incluindo uma nova equação que possibilitasse ser acrescentada nas previsões o comportamento da componente sazonal dos dados que se estivessem trabalhando, gerando assim o Método de Holt-Winters [MAK98] e [HAN01].

O método possui, portanto, três equações básicas, uma para ajuste do nível (3.3) e (3.7), outra para ajuste da tendência (3.4) e (3.8) e uma outra para o ajuste da sazonalidade (3.5) e (3.9), as quais podem ser tanto multiplicativas como aditivas. As aditivas (3.10) são empregadas em situações em que não há interação entre tendência e sazonalidade, e as multiplicativas (3.6), em caso contrário, como coloca [MAK98], em situações em que as flutuações sazonais aumentem e diminuam proporcionalmente ao aumento ou decréscimo do nível da série.

No caso de sazonalidade multiplicativa, presente em séries que sofrem a influência das condições econômico-conjunturais, as expressões de cada uma das componentes, assim como a utilizada para se realizar as previsões (3.6), são descritas da seguinte forma:

$$L_t = \alpha \frac{Y_t}{S_{t-s}} + (1 - \alpha)(L_{t-1} + T_{t-1}) \quad (3.3)$$

$$T_t = \beta(L_t - L_{t-1}) + (1 + \beta)T_{t-1} \quad (3.4)$$

$$S_t = \gamma \frac{Y_t}{L_t} + (1 - \gamma)S_{t-s} \quad (3.5)$$

$$\hat{Y}_{t+m} = (L_t + T_t m) S_{t-s+m} \quad (3.6)$$

Conforme [MOR04], o método multiplicativo considera o fator sazonal como sendo multiplicativo e a tendência como aditiva. De acordo com [MAK98], a equação para o ajuste da sazonalidade (3.5) pondera o mais recente fator sazonal. A equação do ajuste da tendência (3.4), ao seu tempo, é igual à equação de tendência do método linear de Holt. Por fim, a equação para o ajuste de nível (3.3) difere-se da equação do método linear de Holt pelo fato

do primeiro termo ser dividido pelo número sazonal. Esse procedimento acontece para eliminar flutuações sazonais de Y_t .

Segundo [MAK98] e [MOR04], as equações referentes ao método de suavização exponencial com sazonalidade e tendência linear, ou seja, a componente sazonal sendo tratada de forma aditiva são as seguintes:

$$L_t = \alpha(Y_t - S_{t-s}) + (1 - \alpha)(L_{t-1} + T_{t-1}) \quad (3.7)$$

$$T_t = \beta(L_t - L_{t-1}) + (1 - \beta)T_{t-1} \quad (3.8)$$

$$S_t = \gamma(Y_t - L_t) + (1 - \gamma)S_{t-s} \quad (3.9)$$

$$\hat{Y}_{t+m} = L_t + T_t m + S_{t-s+m} \quad (3.10)$$

As equações para o ajuste da tendência (3.8) e (3.4) são idênticas. De acordo com [MAK98], a única diferença entre as demais expressões dizem respeito aos índices sazonais. Enquanto no método aditivo, os mesmos são somados e subtraídos, no multiplicativo, são multiplicados e divididos.

Nestas expressões, s representa o intervalo sazonal¹³ e m o número de passos à frente em que se quer prever. Como se observa nas expressões anteriores é necessário que se estime o valor de três constantes de suavização (α , β e γ) que variam entre 0 e 1 e os valores iniciais de L_t , T_t e S_t . É sugerido por [MAK98] e [HAN01] que se utilizem valores de α , β e γ , que minimizem a medida de erro adotado no estudo.

Uma outra questão que merece destaque é o fato de também não existir uma metodologia pré-definida por Winters, para que se estimem os valores iniciais de L_t , T_t e S_t . Pacotes estatísticos realizam este cálculo, assim como os valores de α , β e γ , de forma automática sem, porém, revelar o algoritmo utilizado em seus manuais. Antevendo esta dificuldade, [MAK98] apresentou uma alternativa para que se encontrem tais valores de L_s , T_s e S_s , através da aplicação de equações como as 3.11, 3.12 e 3.13, porém os índices sazonais calculados a partir da decomposição clássica também podem ser utilizados.

$$L_s = \frac{1}{s}(Y_1 + Y_2 + \dots + Y_s) \quad (3.11)$$

¹³ Utilizando 1 se os dados forem anuais, 12 se forem mensais, 365 se forem diários, etc.


$$T_s = \frac{1}{s} \left[\frac{Y_{s+1} - Y_1}{s} + \frac{Y_{s+2} - Y_2}{s} + \dots + \frac{Y_{s+s} - Y_s}{s} \right] \quad (3.12)$$

$$S_1 = \frac{Y_1}{L_s}, S_2 = \frac{Y_2}{L_s}, \dots, S_s = \frac{Y_s}{L_s} \quad (3.13)$$

A aplicação do método de Holt-Winters não exige que os dados originais respeitem uma distribuição normal e/ou estejam estacionados, tratando-se, portanto, de um método determinístico. Esta questão o torna bastante popular no âmbito empresarial tanto público quanto privado. Apesar deste fato ser considerado uma vantagem, entretanto, isto também contribui para que, em algumas situações, torne limitada sua aplicabilidade. A impossibilidade de aplicação surge em situações em que é impossível aumentar o tamanho da amostra considerada. Porque se o modelo apresentar discrepâncias consideradas inaceitáveis, não é possível estudar seus resíduos e com isso melhorar suas previsões de forma que o torne mais aderente aos dados, o que acaba por desqualificá-lo a servir de suporte à tomada de decisões [SOU05].

3.3.2 Modelos de Box-Jenkins

Os modelos de Box-Jenkins interpretam a série temporal como uma realização de um vetor aleatório multivariado, sendo sua dimensão o tamanho da série disponível, seguindo o princípio da parcimônia (representação dos modelos matemáticos, com a menor quantidade de parâmetros possível) e da construção de modelos através de um ciclo iterativo. Estes modelos determinam o processo estocástico adequado para representar uma dada série temporal através da passagem de um ruído branco por um filtro linear [EST03]. A representação do processo utilizado por Box-Jenkins pode ser observado na Figura 3.5.



Fonte: [BOX94]

Figura 3.5: Processo preditor de Box-Jenkins.

Como nem todos os processos são estacionários busca-se um operador de retardo, para que seja permitida a construção de modelos para séries com comportamentos seriais, através da descrição delas por processos estacionários ou processos estacionários homogêneos. O processo não estacionário é transformado em estacionário homogêneo, através de diferenciações sucessivas, feitas, pelo uso do operador de retardo mencionado anteriormente.

$$X_t = \mu + \sum_{k=0}^{\infty} \Psi_K a_{t-k} \quad (3.14)$$

fazendo $\tilde{X} = X_t - \mu$, tem-se que:

$$\tilde{X}_t = \sum_{k=0}^{\infty} \Psi_K a_{t-k} \quad (3.15)$$

onde:

μ - nível de série.

a_t - ruído branco.

Ψ_K - função de transferência ou filtro linear definido como $\theta_q(B)/\varphi_p(B)$.

B - operador de retardo que representa um atraso de um período de tempo.

A equação 3.14 é a formulação geral do modelo Box-Jenkins. Primeiramente foram desenvolvidos os modelos ARMA, com o objetivo de se modelar somente séries estacionárias, como pode ser observado na equação abaixo.

$$\varphi(B)X_t = \theta(B)a_t \quad (3.16)$$

No entanto, sabe-se que no mundo real, a maioria das séries são não estacionárias [MOR04]. Então, os modelos ARIMA foram à forma encontrada para solucionar esse problema, podendo assim modelar também séries não estacionárias homogêneas. Entende-se por séries não estacionárias homogêneas, aquelas que não são estacionárias na média ou no nível, sendo as mesmas transformadas em séries estacionárias através de sucessivas

diferenças. Se mesmo depois de terem sido feitas as sucessivas diferenças, a série não se tornar estacionária, convém fazer a transformação logarítmica da série em questão. Mas é preciso estar atento, pois a introdução de transformações na previsão pode causar tendenciosidade (no caso da transformação logarítmica geram estimadores tendenciosos do anti-log), sendo necessário à aplicação de correções para eliminá-la. Com a inclusão do operador de diferença, a formula geral, é a que segue.

$$\varphi(B)\nabla^d X_t = \theta(B)a_t \quad (3.17)$$

E finalmente, os modelos SARIMA que são uma extensão dos modelos ARIMA para que seja incluída a sazonalidade dentro da modelagem. Ou seja, inclui-se na modelagem a correlação serial dentro e entre períodos sazonais. Os modelos ARIMA exploram a autocorrelação entre os valores da série em instantes sucessivos, mas quando os dados são observados em períodos inferiores a um ano, a série também pode apresentar autocorrelação para uma estação de sazonalidade s . Os modelos SARIMA é que modelam as séries que apresentam autocorrelação sazonal. Os modelos SARIMA contêm uma parte não sazonal, com parâmetros (p,d,q) , e uma sazonal, com parâmetros $(P,D,Q)_s$, onde [HAN01]:

p - é o número de parâmetros auto-regressivos não-sazonal.

d - é o número de diferenças não-sazonal necessário para tornar a série estacionária.

q - é o número de parâmetros médias móveis não-sazonal.

P - é o número de parâmetros auto-regressivos sazonal.

D - é o número de diferenças sazonal necessário para tornar a série estacionária.

Q - é o número de parâmetros médias móveis sazonal.

s - é o tamanho do período sazonal.

dado por:

$$\varphi(B)\Phi(B^s)\nabla_s^D\nabla^d X_t = \theta(B)\Theta(B^s)a_t \quad (3.18)$$

onde:

$\varphi(B)$ - operador auto-regressivo não sazonal.

$\nabla^d = (1 - B)^d$ - operador de diferença não sazonal de ordem d .

$\Phi(B^S)$ - operador auto-regressivo sazonal.

$\nabla_S^D = (1 - B^S)^D$ - operador de diferença sazonal de ordem D .

$\theta(B)$ - operador de médias móveis não sazonal.

$\Theta(B^S)$ - operador de médias móveis sazonal.

A modelagem geral de Box-Jenkins segue na equação acima, que pode ser usada tanto para modelos sazonais (SARIMA(p, d, q)x(P, D, Q) s) quanto para os modelos não sazonais (ARIMA(p, d, q))¹⁴.

A estimação dos parâmetros do modelo é feita por máxima verossimilhança. No entanto, existem dois problemas na estimação da máxima verossimilhança: o primeiro problema seria o estabelecimento dos valores iniciais do modelo, e o segundo a minimização da soma dos quadrados dos resíduos, que seria o equivalente a maximizar a verossimilhança, pode talvez não conduzir a uma função linear dos parâmetros.

3.3.3 Redes Neurais

As Redes Neurais e/ou Redes Neurais Artificiais (RNAs) são sistemas inspirados na estrutura de funcionamento do cérebro e dos neurônios biológicos. As RNAs funcionam conceitualmente de forma similar ao cérebro humano, tentando reconhecer regularidades e padrões de dados. Esse interesse foi principalmente motivado pela observação da facilidade e eficácia com o que o cérebro realiza tarefas difíceis e complexas. As redes neurais resolvem problemas onde é difícil criar modelos adequados à realidade ou, então, situações que mudam muito (problemas não lineares), sem a necessidade de se definir regras ou modelos explícitos. As RNAs são capazes de aprender com a experiência e fazer generalizações baseadas no seu conhecimento previamente acumulado. Embora biologicamente inspiradas, as RNAs encontraram aplicações em diferentes áreas científicas [EST03].

Devido à similaridade de uma rede neural com a estrutura de um cérebro, elas,

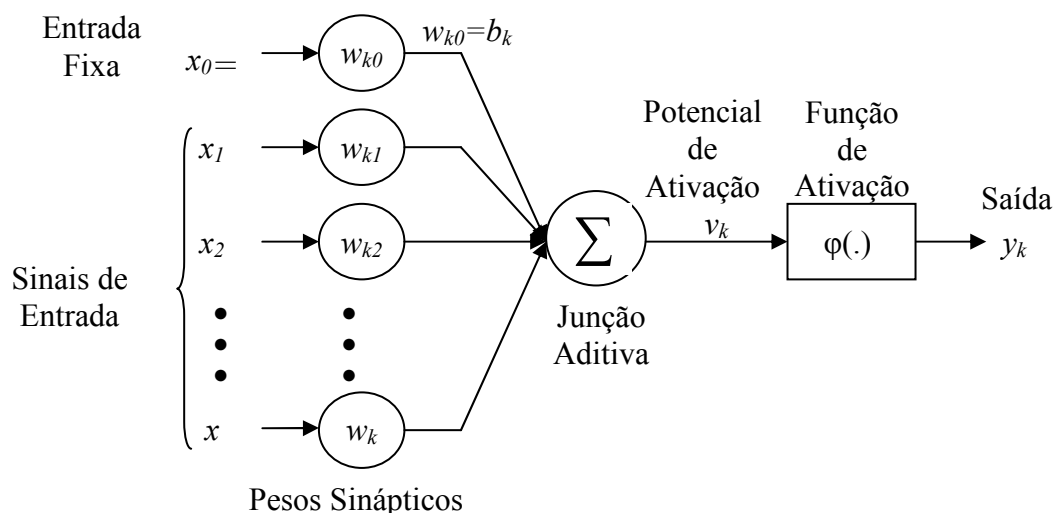
¹⁴ De acordo com [BAR03], é importante salientar que, na aplicação destes processos (ARIMA e SARIMA) à série, a parte “autoregressiva” (AR) do modelo final é o resultado da análise da função de autocorrelação parcial (facp) que identifica o valor de p e P ; a parte “médias móveis” (MA) é o resultado da análise da função de autocorrelação (fac) que identifica o valor de q e Q . O número de diferenças necessárias à estacionariedade da série resulta d e/ou D , no caso de diferenças sazonais, e o número de observações do ciclo sazonal resulta em s . Assim, p , P , q e Q determinam o número de parâmetros necessários ao modelo e d , D e s identificam as observações passadas influentes nos valores a serem previstos.

também, acabam por exibir características semelhantes, tais como:

- Aprendizado: aprende-se por experiência;
- Associação: faz associações entre padrões diferentes;
- Generalização: são capazes de generalizar o conhecimento adquirido a partir de experiências passadas.
- Abstração: extrai a essência de um conjunto de informações, retirando os ruídos.

Segundo [HAY01a], as unidades básicas da rede são os neurônios artificiais. Os neurônios se agrupam em camadas. Existem três categorias de camadas: a camada de entrada, a intermediária que pode também conter mais de uma camada e a camada de saída. Os neurônios entre as camadas são conectados por sinapses ou pesos (pesos sinápticos), os quais refletem a importância relativa de cada entrada com o neurônio. A camada de entrada é responsável pelas variáveis de entrada do modelo; a camada de saída contém um ou mais nós, representando os resultados finais do processamento e as camadas intermediárias, ou camadas ocultas (escondidas), que podem existir uma ou mais que irão tornar o processamento mais refinado e não-linear.

A Figura 3.6, apresenta o modelo de um neurônio, que forma a base para o projeto de redes neurais artificiais.



Fonte: [HAY01a]

Figura 3.6: Modelo de um neurônio artificial.


Conforme [FER95], as RNAs têm vários pontos de contato com os modelos estatísticos e econométricos tradicionais. Como estas ligações acabam embotadas pelo uso de jargões técnicos distintos, [FER95] apresenta um dicionário reduzido, com o objetivo de facilitar a comunicação entre economistas e connexionistas¹⁵, apresentado na Tabela 3.3.

Tabela 3.3: Dicionário de redes neurais-econometria.

Redes Neurais	Estatística
Pesos	Parâmetros
Conjunto de treinamento	Amostra
Entradas	Variáveis exógenas
Saídas	Variáveis endógenas
Retropropagação	Aproximação estocástica
Treinamento ou aprendizado	Estimação
Sinal de entrada	Valor das variáveis exógenas
Sinal de saída	Valor estimado
Alvo	Valor das variáveis endógenas

Fonte: [FER95]

Um bom exemplo da topologia de rede neural encontra-se na Figura 3.7, que, por convenção, é um formato de rede bastante usado, a rede *feedforward* [HAY99]. Nela, podem existir uma ou mais camadas de processamento.



Fonte: [EST03]

Figura 3.7: Rede *feedforward*.

¹⁵ O connexionismo é uma das duas principais linhas de pesquisa da IA e tem por objetivo investigar a possibilidade de simulação de comportamentos inteligentes através de modelos baseados na estrutura e funcionamento do cérebro humano, isto é, de seus neurônios e de suas interligações [BIT08].

Na Figura 3.7, a rede possui 3 camadas: a camada de entrada, a camada escondida, e a camada de saída. A rede neural possui também unidades de processamento da informação. Essas unidades são denominadas neurônios, e são conectadas por pesos sinápticos¹⁶. Vale a pena mencionar que as redes *feedforward* não possuem realimentação.

Existe também um outro tipo de rede, conhecida como rede recorrente. Nesse tipo de topologia existe uma conexão entre os processadores não só de uma mesma camada como também de camadas diferentes, existindo realimentação na rede.

O ajuste pelas redes neurais tem duas fases até que se obtenha o resultado final: (1) a fase de treinamento, onde é retirado o conhecimento do ambiente; (2) a fase de generalização, onde o conhecimento adquirido na fase anterior é testado, para verificar se o que foi aprendido pode ser utilizado para o fim desejado. No entanto, existem, diversas formas importantes de uma rede aprender. O aprendizado pode acontecer de forma supervisionada ou de forma não supervisionada. No primeiro, trabalha-se com conjuntos de pares de entrada e saída, ambos previamente conhecidos e representantes da realidade. Já no aprendizado não supervisionado, não se trabalha com conjuntos previamente conhecidos. Estabelece-se uma medida que represente a qualidade da representação da rede, e os parâmetros são modificados de forma a otimizá-la [CAL02] e [EST03].

No entanto, é preciso ser enfatizado que em se tratando do uso de rede neurais para o tratamento de problemas lineares é fácil ser verificado que a maioria dos métodos estatísticos tradicionais obtém resultados mais eficientes. As redes neurais, tal como a lógica nebulosa, somente oferece resultados mais adequados, em casos onde o investigador lida com a busca de solução para problemas não lineares e quando se tem como objetivo a modelagem de relações complicadas [CAL02] e [EST03].

Conforme [FER95], uma RNA pode ser definida como uma forma de mapear um número de entradas ($x_1, x_2, x_3, \dots, x_r$) em um grupo de saídas ($o_1, o_2, o_3, \dots, o_p$). Imagine-se que existe apenas um neurônio na camada de saída, isto é, $p = 1$, desta forma, em cada neurônio j da camada oculta, a entrada corresponde a uma soma ponderada representada por:

$$\sum_{i=0}^r \gamma_{ji} x_i = \gamma_{j0} + \gamma_{j1} x_1 + \gamma_{j2} x_2 + \dots + \gamma_{jr} x_r \quad (3.19)$$

¹⁶ Pesos sinápticos são forças de conexões entre neurônios que são utilizados para armazenar o conhecimento adquirido [HAY01a].

Desta forma, o primeiro elemento da soma é visto como o viés, o qual aparece em função da existência de um neurônio ligado a todos os demais neurônios da rede cujo sinal de saída é sempre igual à unidade ($x_0 = 1$). Assim, segundo [FER95], após a aplicação da função de ativação G tem-se a saída de cada neurônio j da camada oculta dada por:

$$h_j = G\left(\sum_{i=1}^r \gamma_{ji} x_i\right) \quad (3.20)$$

Assumindo-se a existência de q neurônios na camada oculta e fazendo $h_0 = 1$, tem-se então a entrada do neurônio da camada de saída representada por [FER95]:

$$\sum_{j=0}^q \beta_j h_j = \beta_0 + \beta_1 h_1 + \beta_2 h_2 + \dots + \beta_q h_q \quad (3.21)$$

Neste sentido, o sinal de saída da RNA pode ser obtido como:

$$O = G\left(\sum_{j=0}^q \beta_j h_j\right) \quad (3.22)$$

ou, simplesmente

$$O = G\left[\sum_{j=0}^q \beta_j \cdot G\left(\sum_{i=1}^r \gamma_{ji} x_i\right)\right] = f(x, \theta) \quad (3.23)$$

Na equação (3.23) tem-se a saída da rede como uma função das entradas da rede e dos diversos pesos. Pode-se escrever resumidamente $f = (x, \theta)$, onde x representa o vetor de entradas e θ é o vetor que representa os pesos γ e β . A função f pode ser chamada de função de saída da rede, e sua forma precisa vai depender da arquitetura usada na rede. Neste sentido, pode-se dizer que a procura por uma arquitetura ótima para uma RNA resume-se a procura da forma funcional f apropriada. Existem então duas questões a serem resolvidas: a escolha da forma funcional f , que está associada à arquitetura da rede, isto é, ao número de camadas da rede e ao número de neurônios em cada camada, e a estimação do vetor de parâmetros θ , que é feita pela utilização do método de retropropagação [CAL02] e [FER95].

Este método de retropropagação de erro (algoritmo) é responsável pelo treinamento realizado na arquitetura *feedforward*. Este algoritmo requer a propagação direta do sinal de entrada através da rede, e a retropropagação do sinal de erro [SAN01]. Segundo [NEV08], ele é um modelo de treinamento mais robusto e com álgebra mais elaborada, atualmente o mais utilizado em redes neurais de múltiplas camadas, uma vez que se demonstrou muito eficiente na maioria das aplicações convencionais.

Este algoritmo utiliza o conceito de minimização do gradiente descendente e o limiar da função sigmóide, considerado uma generalização da Regra Delta¹⁷ para redes de alimentação para frente com mais de duas camadas. A Regra Delta Generalizada, mais conhecida como Algoritmo de Correção de Erros de Retropropagação procura minimizar o erro obtido pela rede por meio do método do gradiente descendente. O objetivo deste gradiente é buscar um mínimo global. Sendo que, o mínimo global é considerado como uma solução teórica ótima, pois apresenta o menor erro possível [SAN01].

Como o algoritmo de retropropagação requer o cálculo do gradiente do vetor de erro, é interessante que a função de ativação seja derivável em todos os pontos. A função f , utilizada para obter a saída do neurônio, é chamada de função de ativação. As funções de ativação mais utilizadas são funções do tipo sigmoidal (com forma de S). A maior vantagem desta função é sua derivada, facilmente encontrada. A derivada da função de ativação é necessária no processo de treinamento da rede neural. Isto explica o sucesso da função sigmóide ou função logística como função de ativação, pois ela apresenta esta propriedade [BIT08] e [SAN01].

A Regra Delta utiliza um conjunto de treinamento com o qual se pretende uma aproximação linear, de tal forma que se obtenha a melhor aproximação possível no sentido do erro quadrático. A retropropagação é um algoritmo de treinamento supervisionado (necessita de um conjunto de dados para treinamento, ou seja, uma série de pares de entradas e saídas desejadas). Seu funcionamento pode ser descrito da seguinte forma, segundo [BIT08]: (1) apresenta-se um exemplo à rede e obtém-se a saída correspondente, (2) calcula-se o vetor de erro que consiste na diferença entre a saída obtida e a esperada, (3) calcula-se o gradiente do vetor de erro e atualizam-se, utilizando a Regra Delta, os pesos da camada de saída e, finalmente, (4) propaga-se para trás os valores desejados de modo a atualizar os pesos das


¹⁷ A Regra Delta de aprendizado que é baseada no método do gradiente para minimizar o erro na saída de um neurônio com resposta linear foi proposta por Widrow e Hoff em 1960. Para maiores informações ver: WIDROW, B.; HOFF, M. E. *Adaptive switching circuits*. In: WESCON, 1960, New York. Proceedings... New York: WESCON, 1960.

demais camadas.

De acordo com [SAN01], durante o treinamento com este algoritmo, a rede opera em uma sequência de dois passos. No primeiro passo, um padrão é apresentado à camada de entrada da rede. A atividade resultante flui através da rede, camada por camada, até que a resposta seja produzida pela camada de saída. No segundo passo, a saída obtida é comparada à saída desejada para esse padrão particular e o erro será calculado. O erro é propagado a partir da camada de saída até a camada de entrada, e os pesos das conexões das unidades das camadas internas vão sendo modificados conforme o erro é retropropagado.

Nesse tipo de aprendizado, os cálculos necessários para minimizar o erro são importantes e estão atrelados ao algoritmo utilizado. Onde são considerados parâmetros como o tempo por iteração, o número de iterações por padrão de entrada para o erro alcançar um valor mínimo no treinamento, a ocorrência de um mínimo local ou global e a capacidade da rede escapar desses mínimos locais.


Na Figura 3.8 tem-se a representação gráfica de uma rede neural *feedforward* com quatro neurônios na camada de entrada, sendo o viés representado pelo triângulo, três neurônios na camada escondida ou intermediária e um neurônio na camada de saída. O vetor de pesos γ estabelece as ligações entre as camadas de entrada e oculta, enquanto o vetor β estabelece as ligações entre as camadas oculta e de saída [CAL02] e [FER95].



Fonte: Adaptado de [HAY99]

Figura 3.8: Representação gráfica de uma RNA.

Considerando [FER95], no problema usual de estimar-se uma regressão não-linear, tem-se, para esta regressão a expressão $f = (x, \theta)$, onde x é o vetor de variáveis exógenas e θ o vetor de parâmetros, que representa uma família de curvas cuja forma funcional é definida *a priori*, e o problema consiste em obter-se o estimador $\hat{\theta}$ ótimo, isto é, aquele que minimiza a soma do quadrado dos resíduos. Em outras palavras, o problema consiste em obter um membro específico desta família de curvas, $f = (x, \hat{\theta})$ que apresenta o melhor ajuste aos dados.



Fonte: [FER95]

Figura 3.9: Ajuste de mínimos quadrados não-lineares.

Em White *apud* [FER95] é mostrado que o estimador de mínimos quadrados não-lineares ($\hat{\theta}$) tende assintoticamente para os pesos ótimos aprendidos pela RNA (θ^*). É neste sentido que pode se afirmar que a grande novidade introduzida pelas RNAs consiste em focalizar a atenção na forma funcional f .

Segundo a literatura consultada, as redes neurais artificiais têm sido utilizadas com grande sucesso na resolução de problemas envolvendo reconhecimento de padrões, classificação, previsão, etc., pois elas possuem a propriedade de serem aproximadores universais. É interessante observar que um único neurônio não é capaz de resolver nenhum problema prático. Porém, muitos neurônios adequadamente conectados e com os pesos das conexões devidamente ajustados são capazes de resolver complexos problemas não-determinísticos. Quanto maior a complexidade do problema a ser resolvido, maior será o

número de neurônios utilizados.

Segundo [FER95], uma RNA, com um número suficiente de neurônios na camada oculta e uma função de ativação tipo logística consegue aproximar, com o grau de precisão desejado, qualquer mapa de um espaço dimensional finito em um outro espaço dimensional finito qualquer. Já os procedimentos de aprendizagem utilizados para obter os pesos consistem em um processo de estimação usual em estatística. O algoritmo de retropropagação é utilizado simplesmente para determinar o mínimo local da superfície de erros.

Robbins e Monro *apud* [FER95] propuseram um procedimento para estimar o vetor $\hat{\theta}$ que resolve a equação $E(m(Z_t, \theta)) = 0$, onde E representa a esperança matemática, θ é um vetor de parâmetros e $m(Z_t, \theta)$ é uma quantidade aleatória, cuja aleatoriedade advém da presença da variável aleatória Z_t . A única informação conhecida para estimar-se $\hat{\theta}$ é uma única realização da variável aleatória Z_t , para $t=1, 2, \dots, n$. A proposta para estimar θ de forma recursiva pela equação (3.24) para $t=1, 2, \dots, n$:

$$\theta_t = \theta_{t-1} + \eta_t \cdot m(Z_t, \theta_{t-1}) \quad (3.24)$$

onde θ_0 é escolhido aleatoriamente. Fazendo-se:

$$\eta_t = \eta \quad (3.25)$$

$$m(Z_t, \theta_{t-1}) = \nabla f(x_t, \theta_{t-1})(y_t - f(x_t, \theta_{t-1})) \quad (3.26)$$

$$Z_t = (x_t, y_t) \quad (3.27)$$

obtem-se:

$$\theta_t = \theta_{t-1} + \eta \cdot \nabla f(x_t, \theta_{t-1})(y_t - f(x_t, \theta_{t-1})) \quad (3.28)$$

que é, na verdade, uma forma genérica de escrever o algoritmo de retropropagação [FER95].

3.4 Medidas de Performance Preditiva

Toda demanda possui um componente aleatório. Segundo [CHO03] um bom modelo de previsão deve captar o componente sistemático da demanda, mas não o componente aleatório. Este componente aleatório se manifesta na forma de um erro de previsão, o qual possui informações importantes que devem ser analisadas com critério.

Diversos métodos foram desenvolvidos para resumir os erros gerados por uma técnica de previsão particular. A maioria destas medidas envolve o cálculo da média de alguma função da diferença entre um valor real e o valor predito. Estas diferenças entre valores observados e valores previstos são freqüentemente referenciadas como resíduos. Um resíduo é, portanto, a diferença entre um valor real e seu valor previsto [HAN01].

Na tomada de decisão, conforme indica [CHO03], deve se fazer uma análise completa dos erros em uma previsão por dois motivos:

- Utilizar as análises de erros para determinar se o modelo de previsão adotado está prevendo detalhadamente o componente sistemático da demanda.
- Estimar o erro da previsão porque qualquer plano de contingência deve ser responsável por tal erro.

Parte da decisão para usar uma técnica de previsão em particular envolve a determinação se a técnica produzirá os erros da previsão que são julgados ser suficientemente pequenos. É certamente realístico esperar que uma técnica produza erros relativamente pequenos de previsão em uma base consistente [HAN01].

Se os erros observados estiverem dentro das estimativas históricas de erros, as empresas geralmente podem continuar adotando seu modelo atual de previsão. Contudo, se for observado que um erro está muito além das estimativas históricas, isto pode indicar que o modelo de previsão adotado deixou de ser adequado. Também é possível que todas as previsões costumem superestimar ou subestimar a demanda, o que será um sinal para alterar o modelo de previsão [CHO03] e [HAN01].

O erro de previsão para o período t é dado por E_t , e representado pela expressão abaixo, onde F_t é a previsão de demanda e D_t é a demanda real observada [CHO03].

$$E_t = F_t - D_t \quad (3.29)$$

A avaliação e a comparação entre os modelos de previsão são realizadas através de estatísticas que medem o “grau de ajustamento” do modelo aos dados. Dentre estas estatísticas, freqüentemente utilizadas estão as descritas abaixo [CHO03] e [HAN01].

- Soma do quadrado dos erros (*Sum Squared Error – SSE*);
- Erro quadrático médio (*Mean Square Error – MSE*);
- Desvio padrão absoluto médio (*Mean Absolute Deviation – MAD*);
- Erro absoluto médio percentual (*Mean Absolute Percentual Error – MAPE*);
- Erro médio percentual (*Mean Percentual Error – MPE*);
- Viés, desvio ou *bias*;
- Razão de viés ou verificação da variação de sinal do erro (*Tracking Signal – TS*).

3.4.1 Soma do Quadrado dos Erros (SQE)

O SQE é a simples soma dos erros ao quadrado, para o qual se aplica a expressão [CHO03]:

$$SQE = \sum_{t=1}^n E_t^2 \quad (3.30)$$

3.4.2 Erro Quadrático Médio (EQM)

O EQM estima a variação do erro de previsão. O EQM é utilizado quando a simples soma dos erros ao quadrado apresenta valores muito grandes que podem dificultar a interpretação. Para o qual se aplica a expressão [CHO03]:

$$EQM_n = \frac{1}{n} \sum_{t=1}^n E_t^2 \quad (3.31)$$

3.4.3 Desvio Absoluto Médio (DAM)

Um método para avaliar técnicas de previsão usa a soma dos erros absolutos. O desvio padrão absoluto (DAM) mede a acurácia da previsão pela média das magnitudes dos erros das previsões (valores absolutos de cada erro). O DAM é mais utilizado quando o analista quer medir o erro da previsão na mesma unidade que a série original [HAN01].

A definição do desvio absoluto no período t , A_t , como sendo o valor absoluto do erro no período t , ou seja:

$$A_t = |E_t| \quad (3.32)$$

O desvio absoluto médio (DAM) é definido como sendo a média do desvio absoluto em todos os períodos, expresso da seguinte maneira:

$$DAM_n = \frac{1}{n} \sum_{t=1}^n A_t \quad (3.33)$$

O DAM pode ser usado para estimar o desvio-padrão do componente aleatório, supondo que o componente aleatório seja distribuído normalmente [CHO03]. Nesse caso o desvio-padrão do componente aleatório é:

$$\sigma = 1,25 DAM \quad (3.34)$$

Estima-se a partir daí que a média do componente aleatório é 0 e que o desvio-padrão do componente aleatório da demanda é σ .

3.4.4 Erro Absoluto Médio Percentual (EAMP)

Algumas vezes é mais útil calcular os erros de previsão em termos dos valores percentuais do que dos valores absolutos. O erro absoluto médio percentual (EAMP) é calculado encontrando o erro absoluto em cada período, dividindo este pelo valor atual observado para esse período, e então calculando a média desses erros absolutos percentuais. O EAMP fornece uma indicação de quão grandes os erros de previsão estão na comparação com os valores atuais das séries. A técnica é especialmente útil quando os valores F_t são grandes. O EAMP pode também ser usado para comparar a acurácia da mesma técnica ou diferentes técnicas em duas séries inteiramente diferentes [HAN01].

É o erro absoluto médio como porcentagem de demanda e se expressa assim:

$$EAMP_n = \frac{\sum_{t=1}^n \left| \frac{E_t}{D_t} \right| 100}{n} \quad (3.35)$$

3.4.5 Erro Médio Percentual (EMP)

Às vezes é necessário determinar se um método de previsão fornece uma previsão consistentemente alta ou baixa. O erro médio da porcentagem (EMP) é usado nestes casos. É calculado encontrando o erro em cada período, dividindo este pelo valor atual para esse período, e então calculando a média destes erros percentuais. Se a aproximação não for consistentemente alta ou baixa, a Equação 3.32 produzirá uma porcentagem que chegará perto de zero. Se o resultado for uma porcentagem negativa grande, o método de previsão é consistentemente superestimado. Se o resultado for uma porcentagem positiva grande, o método de previsão é consistentemente subestimado [HAN01].

$$EMP_n = \frac{1}{n} \sum_{t=1}^n \frac{E_t}{D_t} \quad (3.36)$$

3.4.6 Viés

Para se determinar se o modelo de previsão consistentemente superestima ou subestima a demanda, pode-se utilizar a soma dos erros de previsão para avaliar o viés da previsão, que é expresso como segue [CHO03]:

$$viés_n = \sum_{t=1}^n E_t \quad (3.37)$$

O viés da previsão (VP) oscilará em torno de 0 se o erro for verdadeiramente aleatório e não enviesado de uma forma ou de outra. O ideal é, ao se plotar todos os erros num gráfico de erro pelo tempo, que a inclinação da reta estimada seja 0.

3.4.7 Razão de Viés (TS)

A razão de viés ou sinal de rastreabilidade (TS – *tracking signal*) é a razão entre o viés da previsão e o DAM e é formulada pela seguinte expressão:

$$TS_t = \frac{viés_t}{DAM_t} \quad (3.38)$$

Se o TS em qualquer período estiver fora da faixa de ± 6 , isso significa que a previsão está enviesada e que pode estar subestimada (razão de viés abaixo de -6) ou superestimada (razão de viés acima de +6). Nesse caso, a empresa deve optar pela escolha de um novo modelo de previsão [CHO03] e [HAN01].

Capítulo 4

Implementação e Análise dos Modelos

Este capítulo apresenta e discute os resultados obtidos dentro da pesquisa realizada com a utilização das ferramentas selecionadas e a aplicação dessas ferramentas na identificação do método de previsão mais adequado.

4.1. Análise Descritiva dos Dados

Nesta seção serão apresentados os resultados obtidos da análise exploratória dos dados, conforme indicados na seção 3.2.1. Os resultados foram obtidos através da utilização dos programas computacionais Excel 2003 (planilha eletrônica) e o R (pacote estatístico). O processo de análise foi iniciado com a elaboração de um *script* para a programação no R. Os passos seguidos na elaboração do *script* estão baseados na estrutura da pesquisa e na metodologia adotada contemplando as fases de:

- Organização ou estruturação dos dados e tratamento destes;
- Definição dos métodos de previsão a serem analisados;
- Definição dos experimentos de análise a serem realizados.

4.1.1 Análise Descritiva Geral

Os dados históricos completos, que formam as séries temporais a serem utilizadas, estão apresentados no ANEXO A. Na Tabela 4.1 são demonstrados os resumos das Categorias 1 e 2, considerando o subconjunto de teste com 36 observações, tratado na seção 3.2.3, sendo que a Categoria 1 é composta de 28 produtos e a Categoria 2 de 16 produtos, conforme descrito na seção 3.1.

Tabela 4.1: Histórico de demanda por categorias.

	2004	2005	2006	2007	Total Geral
Categoria 1	6.482.418,00	8.210.655,00	7.439.343,00	2.145.434,00	24.277.850,00
Categoria 2	4.672.684,00	5.626.559,00	4.780.695,00	1.170.377,00	16.250.315,00
Total Geral	11.155.102,00	13.837.214,00	12.220.038,00	3.315.811,00	40.528.165,00

Ao analisar a Tabela 4.1, é necessário atentar para o fato de que o subconjunto de teste do histórico fornecido tem o seu início no mês de maio de 2004, bem como, o seu término no mês de abril de 2007. Percebe-se, entretanto, que o volume de produtos de ambas as categorias são bem elevados. Nota-se, contudo, um decréscimo nos valores históricos fornecido entre o ano de 2005 e 2006 em ambas as categorias.

As Figuras 4.1 e 4.2 apresentam os gráficos dos dados históricos de demanda para a Categoria 1 e Categoria 2. Estes gráficos demonstram a relação das quantidades totais de produtos em função do período de observação, que é mensal. Percebe-se um padrão cíclico nos dados para as duas categorias, que atingem altas quantidades de produtos nos meses de novembro caindo imediatamente nos meses de dezembro atingindo as quantidades mais baixas em fevereiro, ano após ano, caracterizando um comportamento sazonal, bem como, uma tendência negativa (indicada em vermelho) ao se verificar que os valores dos meses decrescem ao longo do tempo.




Figura 4.1: Histórico de demanda da categoria de produtos 1.




Figura 4.2: Histórico de demanda da categoria de produtos 2.

A tendência negativa é confirmada para as duas séries temporais, ao se observar a média anual da quantidade de produtos que decresce ao longo do período em estudo, como pode ser visto na Tabela 4.2 e 4.3. Este fato pode estar associado com o ciclo de vida dos produtos¹⁸. Indicando algum evento especial em relação às fases deste ciclo, que ocasionou este comportamento na série em análise.

Tabela 4.2: Estatísticas descritivas para a Categoria 1.

	2004	2005	2006	2007	Total
Média	810.302,25	684.221,25	619.945,25	536.358,50	674.384,72
Mediana	597.060,50	551.686,50	504.056,00	444.386,50	532.019,50
Desvio padrão	480.151,73	398.439,40	384.124,06	285.826,58	396.015,39
Curtose	2,00	5,09	4,78	1,78	2,64
Assimetria	1,51	2,14	2,00	1,45	1,73
Mínimo	425.944,00	354.473,00	272.853,00	314.109,00	272.853,00
Máximo	1.811.284,00	1.775.095,00	1.661.166,00	942.552,00	1.811.284,00
Soma	6.482.418,00	8.210.655,00	7.439.343,00	2.145.434,00	24.277.850,00
Contagem	8	12	12	4	36

¹⁸ O ciclo de vida do produto representa estágios distintos na história das vendas do produto. Estes diferentes estágios incluem, mas não se resumem, as fases referentes ao desenvolvimento do produto. Correspondentes a estes estágios estão diferentes oportunidades e problemas com respeito a várias estratégias mercadológicas, operacionais e financeiras. Estas fases são quatro: introdução no mercado, crescimento de volume, maturidade e declínio. Nas quais deve ser verificada uma correlação entre características encontradas nos produtos e mercados servidos ao longo do ciclo de vida do produto e características do processo a cargo de fazer os produtos ao longo das fases do ciclo [COR04].

Tabela 4.3: Estatísticas descritivas para a Categoria 2.

	2004	2005	2006	2007	Total
Média	584.085,50	468.879,92	398.391,25	292.594,25	451.397,64
Mediana	528.830,00	423.668,50	356.640,00	266.873,00	420.640,50
Desvio padrão	271.326,27	240.886,43	221.796,97	119.052,08	240.022,26
Curtose	4,40	7,19	5,53	-0,95	3,83
Assimetria	1,92	2,40	2,03	0,86	1,85
Mínimo	322.645,00	214.166,00	147.340,00	187.857,00	147.340,00
Máximo	1.196.625,00	1.163.929,00	1.010.410,00	448.774,00	1.196.625,00
Soma	4.672.684,00	5.626.559,00	4.780.695,00	1.170.377,00	16.250.315,00
Contagem	8	12	12	4	36

Ao se analisar, agora, a quantidade anual por produtos das Categorias 1 e 2, observa-se a redução entre 2005 e 2006, como ocorreu na Tabela 4.1. A exceção apresenta-se para os produtos P8, P14, P22 e P27 da Categoria 1, como pode ser visto na Tabela 4.4 e 4.5.

Tabela 4.4: Histórico de demanda dos produtos da Categoria 1.

Produto	Período				Total
	2004	2005	2006	2007	
P1	172.037,00	224.294,00	214.537,00	64.435,00	675.303,00
P2	221.859,00	248.312,00	209.967,00	63.583,00	743.721,00
P3	501.724,00	692.212,00	676.704,00	215.373,00	2.086.013,00
P4	340.245,00	508.351,00	487.149,00	128.910,00	1.464.655,00
P5	121.228,00	152.751,00	133.870,00	40.990,00	448.839,00
P6	272.435,00	366.474,00	352.463,00	107.546,00	1.098.918,00
P7	184.290,00	243.048,00	228.014,00	65.004,00	720.356,00
P8	541.577,00	591.600,00	595.902,00	191.611,00	1.920.690,00
P9	149.454,00	168.093,00	152.850,00	50.261,00	520.658,00
P10	163.766,00	176.381,00	136.257,00	41.582,00	517.986,00
P11	231.324,00	345.124,00	337.899,00	117.898,00	1.032.245,00
P12	216.039,00	233.993,00	229.994,00	67.642,00	747.668,00
P13	48.027,00	67.511,00	61.762,00	14.552,00	191.852,00
P14	173.038,00	177.224,00	181.055,00	62.422,00	593.739,00
P15	186.003,00	261.831,00	228.222,00	56.017,00	732.073,00
P16	527.065,00	710.942,00	605.229,00	161.550,00	2.004.786,00
P17	233.093,00	323.005,00	306.622,00	72.710,00	935.430,00
P18	191.906,00	230.074,00	178.440,00	40.441,00	640.861,00
P19	207.136,00	232.696,00	207.249,00	59.976,00	707.057,00
P20	363.887,00	471.487,00	375.119,00	91.555,00	1.302.048,00
P21	219.762,00	305.310,00	274.511,00	76.493,00	876.076,00
P22	155.964,00	222.759,00	223.393,00	71.346,00	673.462,00
P23	305.282,00	432.638,00	355.271,00	90.508,00	1.183.699,00
P24	129.772,00	138.437,00	92.557,00	27.292,00	388.058,00
P25	65.900,00	85.268,00	81.716,00	19.148,00	252.032,00
P26	247.794,00	208.282,00	121.028,00	36.518,00	613.622,00
P27	243.058,00	302.672,00	315.207,00	93.081,00	954.018,00
P28	68.753,00	89.886,00	76.356,00	16.990,00	251.985,00

Tabela 4.5: Histórico de demanda dos produtos da Categoria 2.

Produto	Período				
	2004	2005	2006	2007	Total
P1	344.228,00	384.742,00	305.678,00	81.083,00	1.115.731,00
P2	407.559,00	505.383,00	418.677,00	104.177,00	1.435.796,00
P3	231.751,00	278.239,00	217.261,00	60.481,00	787.732,00
P4	464.456,00	624.407,00	477.115,00	117.197,00	1.683.175,00
P5	293.288,00	315.853,00	280.950,00	60.792,00	950.883,00
P6	454.249,00	546.853,00	461.269,00	118.103,00	1.580.474,00
P7	214.191,00	252.422,00	245.801,00	66.116,00	778.530,00
P8	60.139,00	68.801,00	44.862,00	10.243,00	184.045,00
P9	335.012,00	373.838,00	269.089,00	54.740,00	1.032.679,00
P10	227.027,00	240.567,00	222.376,00	55.482,00	745.452,00
P11	165.732,00	185.094,00	146.263,00	29.401,00	526.490,00
P12	263.689,00	367.043,00	345.430,00	99.919,00	1.076.081,00
P13	295.712,00	328.652,00	295.492,00	78.877,00	998.733,00
P14	75.965,00	77.050,00	69.050,00	16.079,00	238.144,00
P15	475.410,00	617.743,00	587.420,00	129.188,00	1.809.761,00
P16	364.276,00	459.872,00	393.962,00	88.499,00	1.306.609,00

Na sequência será apresentada a análise descritiva específica, a qual, devido a grande quantidade de informações obtidas para cada produto de cada categoria, em termos de tabelas e gráficos, optou-se por demonstrar os procedimentos metodológicos realizado para toda a série apenas para um produto de cada categoria. O critério de escolha baseou-se apenas na quantidade total de produtos, sendo o produto com a menor quantidade a opção escolhida.

4.1.2 Análise Descritiva Específica

Observando-se a sequência da análise exploratória dos dados, conforme indicados na seção 3.2.1, foram realizadas as estatísticas descritivas do produto P13 da Categoria 1 e P8 da Categoria 2 que estão apresentados nas Tabelas 4.6 e 4.7.

Tabela 4.6: Estatísticas descritivas para o produto P13 da Categoria 1.

	2004	2005	2006	2007	Total
Média	6.003,38	5.625,92	5.146,83	3.638,00	5.329,22
Mediana	5.183,00	5.038,50	4.576,50	3.395,50	4.686,50
Desvio padrão	3.356,11	3.126,92	2.971,01	1.499,76	2.960,57
Curtose	4,42	3,73	6,55	1,84	3,37
Assimetria	1,97	1,76	2,30	0,93	1,86
Mínimo	3.097,00	2.692,00	2.418,00	2.081,00	2.081,00
Máximo	13.598,00	13.770,00	13.600,00	5.680,00	13.770,00
Soma	48.027,00	67.511,00	61.762,00	14.552,00	191.852,00
Contagem	8	12	12	4	36

Tabela 4.7: Estatísticas descritivas para o produto P8 da Categoria 2.

	2004	2005	2006	2007	Total
Média	7.517,38	5.733,42	3.738,50	2.560,75	5.112,36
Mediana	6.554,50	4.485,00	3.643,50	2.300,00	4.179,50
Desvio padrão	3.629,16	3.374,83	2.280,52	1.076,79	3.285,30
Curtose	2,73	3,22	3,79	-0,58	2,61
Assimetria	1,57	1,74	1,70	0,96	1,58
Mínimo	4.281,00	2.626,00	1.244,00	1.649,00	1.244,00
Máximo	15.281,00	14.392,00	9.692,00	3.994,00	15.281,00
Soma	60.139,00	68.801,00	44.862,00	10.243,00	184.045,00
Contagem	8	12	12	4	36

Percebe-se que o padrão cíclico dos dados observados para as duas categorias, conforme realizado na análise descritiva geral, se repete nos produtos destas categorias. O que caracteriza um comportamento sazonal. Novamente é identificada uma tendência negativa ao verificar-se que os valores dos meses decrescem ao longo do tempo.

Nas Figuras 4.3 e 4.4, esta tendência negativa percebida é demonstrado nos gráficos. A construção destes gráficos, neste estudo, permitiu observar as características importantes das séries, como um apoio aos demais procedimentos utilizados.

Com a utilização do R analisou-se a condição de estacionariedade das séries do produto P13 da Categoria 1 e P8 da categoria 8, conforme determinados na seção anterior, por meio da média e da variância. Em ambos os casos, a condição foi de “estacionário na média” e “estacionário na variância”. O processo desta análise se deu com a elaboração de um *script* para a programação no R.




Figura 4.3: Histórico de demanda do produto P13 da Categoria 1.




Figura 4.4: Histórico de demanda do produto P8 da Categoria 2.

Na sequência da análise, para que um reconhecimento das estruturas comportamentais das séries fosse comprovado, empregou-se o processo de decomposição em componentes não-observáveis. A decomposição pelo pacote estatístico R se dá utilizando médias móveis. As Figuras 4.5 e 4.6 apresentam a decomposição realizada.




Figura 4.5: Decomposição da série temporal do produto P13 da Categoria 1.




Figura 4.6: Decomposição da série temporal do produto P8 da Categoria 2.

Na análise dos gráficos de decomposição¹⁹ apresentados para as séries temporais observa-se a componente sazonal bem definida. Entretanto, devido ao número de observações obtidas, verifica-se um comportamento diferente para a componente tendência. Percebe-se que existe uma tendência negativa durante um período de tempo, mas em um determinado momento o mesmo tende a crescer. Não se sabe se o comportamento reflete alguma ação da empresa que levou a um crescimento da demanda, pois não foram fornecidas outras informações além do histórico. Este ponto merece uma análise mais criteriosa, a qual poderia ser objeto de um futuro trabalho para estas categorias de produtos.

Como última análise desta fase verificou-se a estrutura de dependência das séries temporais pelo gráfico da função de autocorrelação apresentados nas Figuras 4.7 e 4.8. O que se percebe a respeito da análise destes gráficos é que há uma estrutura de dependência, caracterizado pelo alto valor da autocorrelação no retardo de 12 períodos (intervalos de tempo), isto indica a presença da componente sazonal para a série temporal.

¹⁹ A decomposição adotada para verificar a estrutura da série foi a aditiva devido ao histórico disponível ser pequeno para uma decomposição multiplicativa.




Figura 4.7: Autocorrelação do histórico de demanda do produto P13 da Categoria 1.




Figura 4.8: Autocorrelação do histórico de demanda do produto P8 da Categoria 2.

4.2. Parametrização e Validação dos Modelos Implementados

Nesta seção são apresentados os resultados discutidos na seção 3.2.2, relacionadas à análise dos dados históricos, onde se indicam os parâmetros obtidos, para os modelos dos métodos de previsão utilizados nesta pesquisa, mais adequados a cada produto determinado ou sua categoria. Como ocorreu na seção anterior, o processo de análise foi realizado com a utilização do R, sendo necessário à elaboração de um *script* para a sua programação.

Como verificado na análise das estruturas comportamentais, através da decomposição e da autocorrelação, as séries temporais em análise apresentam sazonalidade anual. Desta forma, confirmando que as séries temporais são homogêneas em certo equilíbrio estatístico, com tendência negativa, porém não significativa do ponto de vista estatístico direcionando a aplicação dos modelos sazonais.

Método de Holt-Winters

Em geral, procura-se minimizar o erro médio quadrático, escolhendo-se aquele modelo que apresentar menor erro. No caso do método Holt-Winters os parâmetros são determinados pelo R através da minimização da soma dos erros quadráticos. No caso das séries temporais para os produtos P13 da Categoria 1 e P8 da Categoria 2, foram obtidos os parâmetros indicados na Tabela 4.8.

Tabela 4.8: Parâmetros Holt-Winters para os produtos P13 e P8.

	P13	P8
Parâmetros:		
alfa	0,90	0,17
beta	0,00	0,38
gama	0,03	1,00
Coefficientes:		
a	4.430,18	3.938,31
b	-42,59	83,73
s1	127,13	2.270,43
s2	-2.106,55	-932,17
s3	-2.436,27	334,61
s4	-2.183,54	410,92
s5	-1.430,23	-1.644,59
s6	1.554,18	522,16
s7	9.419,64	6.354,14
s8	1.469,61	575,42
s9	-1.532,25	-1.979,16
s10	-2.204,64	-1.890,52
s11	-2.032,53	-1.077,88
s12	1.353,77	55,69

Os coeficientes a , b e s (s_1, \dots, s_n) são valores estimados para os componentes: nível (a), tendência (b) e sazonalidade (s). No R, para modelos sazonais, os valores iniciais para a , b e s são identificados pela realização de uma decomposição simples nas componentes tendência e sazonalidade usando a média móvel sobre os primeiros períodos (uma regressão linear simples sobre a componente tendência é usada para iniciar o nível e a tendência).

Método de Box-Jenkins

No processo de definição dos parâmetros para o SARIMA, o passo inicial se deu pela criação de um *script*, para a escolha dos valores ótimos dos parâmetros (p, d, q) (P, D, Q), conforme o valor do critério de Akaike (AIC). Como explicado no capítulo anterior, este critério é uma medida de qualidade de ajuste, o qual penaliza o modelo pela quantidade de parâmetros. Desta forma, o modelo mais apropriado será o com menor AIC.

As Figuras 4.9 e 4.10 apresentam os gráficos dos resíduos²⁰. Realizou-se um teste de normalidade (o pacote R utiliza o teste de normalidade Shapiro-Wilk²¹) e uma autocorrelação dos resíduos visando verificar se o modelo escolhido se ajustava bem aos dados disponíveis.




Figura 4.9: Gráfico dos resíduos do produto P13 da Categoria 1.

²⁰ Resíduo ou erro de previsão. Um resíduo é a diferença entre um valor atual e seu valor previsto [HAN01].

²¹ Para maiores informações ver: ROYSTON, Patrick. *Remark AS R94: A remark on Algorithm AS 181: The W test for normality*. Applied Statistics, v. 44, n. 4, p. 547-551, out./dez. 1995.




Figura 4.10: Gráfico dos resíduos do produto P8 da Categoria 2.

Os testes paramétricos exigem que a variável dependente possua distribuição normal e que as variâncias populacionais sejam homogêneas, caso se esteja a comparar duas ou mais populações. Para testar a normalidade os testes mais utilizados são o de Kolmogorov-Smirnov e Shapiro-Wilk. O teste de normalidade, utilizado nesta pesquisa, é o Shapiro-Wilk, o qual é o mais apropriado para séries temporais com menos de 50 observações [EST03] e [KEN76].

Dentro do processo de definição dos parâmetros, o diagnóstico focaliza as análises sobre os resíduos resultantes do modelo, para a verificação se estes resultam em “ruído branco”, ou seja, o modelo foi tão bem ajustado que somente restou a aleatoriedade dos dados que não pode ser explicada matematicamente. Neste sentido, testes estatísticos são utilizados pelo R para esta análise, conforme descritos na seção 3.2.2.

As Figuras 4.11 e 4.12 apresentam a autocorrelação das medidas de dependência entre observações dos resíduos para as séries em análise, mostrando que não restou nenhuma estrutura temporal fora aquelas contempladas pelo modelo (a autocorrelação pode surgir por especificação incorreta do modelo da regressão, por causa de erros na forma do modelo ou por exclusão de variáveis independentes importantes para a análise).




Figura 4.11: Autocorrelação dos resíduos do produto P13 da Categoria 1.




Figura 4.12: Autocorrelação dos resíduos do produto P8 da Categoria 2.

Os parâmetros obtidos para os produtos P13 da Categoria 1 e P8 da Categoria 2, são:

Tabela 4.9: Parâmetros Box-Jenkins para os produtos P13 e P8.

	P13	P8
Coefficientes:		
ma1	0,85	-0,83
ma2	0,55	
ma3	0,36	
sar1	0,44	0,86
sar2	0,54	
intercept	5.265,87	
sigma estimado	554.167,00	2.527.350,00
log likelihood	-308,84	-316,26
AIC	631,68	638,52
AICc	634,57	638,89
BIC	641,18	641,69

Os parâmetros²² apresentados acima indicam que o modelo SARIMA (0,0,3) (2,0,0)₁₂ para o P13 da Categoria 1 e SARIMA (0,1,1) (1,0,0)₁₂ para o P8 da Categoria 2 apresentam menores valores de AIC e maior probabilidade em rejeitar a hipótese de autocorrelação dos resíduos, portanto, são os mais adequados aos produtos analisados.

Redes Neurais Artificiais

Conforme descrito na seção 3.2.2, a rede neural artificial utilizada nesta pesquisa é do tipo *feedforward*, com o algoritmo *backpropagation* utilizado para o ajuste dos pesos. O passo inicial se deu pela definição do conjunto de treinamento, do conjunto de teste e do conjunto de validação no processo de definição dos parâmetros para a rede neural.

Uma vez que, na seção 3.2.3, estabeleceu-se o subconjunto de teste para a comparação dos métodos de previsão, com 36 observações, obtido da série integral composta de 39 observações, definiu-se este subconjunto como o conjunto de treinamento e teste, e que as três observações restantes que serão utilizadas para comparação das previsões, como o conjunto de validação.

Nesta pesquisa, em cada ano do período de treinamento e teste, foram selecionados randomicamente pelo R os pontos de teste e de treinamento, sem meses pré-determinados

²² Os parâmetros do modelo são representados pelos coeficientes $ar(p)$, $ma(q)$, $sar(P)$ e $sma(Q)$, como os dados são mensais o tamanho do período sazonal (s) é 12. O p -value ou probabilidade significativa com valores baixos (menor que 0,05) evidenciam falta de normalidade, ou seja, a rejeição da hipótese H_0 .

para teste ou treinamento. Isto visa que os conjuntos de teste e treinamento sejam ambos assemelhados ao padrão da série, homogêneos tanto com relação aos meses do ano quanto com os anos utilizados [CAL02]. O R foi utilizado também na determinação dos demais parâmetros para definição da arquitetura da rede a ser utilizada, sendo que apenas os neurônios da camada escondida ou intermediária necessitam ser estabelecidos pelo usuário.

Na determinação do número de neurônios na camada intermediária realizaram-se algumas experimentações. Em cada experiência procurou-se a melhor configuração, ou seja, testar diversos números de neurônios na camada intermediária, descartando os piores resultados com base na comparação das previsões realizadas, o que se deu pela utilização do EAMP, como critério de desempenho em ajuste.

Como observado na seção 3.2.2, a melhor configuração para a camada escondida da rede é feita de forma a minimizar o número de neurônios nesta camada sem que haja perda de capacidade preditiva. A utilização de poucos neurônios proporciona uma capacidade de generalização maior, mas pode simplificar muito o modelo, no sentido contrário, pode introduzir uma complexidade que o problema não possui, e fazer com que a rede fique muito restrita, e propensa a *overtraining* [CAL02]. A configuração que proporcionará a melhor rede é aquela que fornecer o menor erro no conjunto de validação e o mínimo erro para o conjunto de teste.

Neste sentido, as configurações 3-9-1 para o produto P13 e 3-8-1 para o produto P8 proporcionaram a melhor rede. Os parâmetros obtidos para estes produtos, são:

Tabela 4.10: Parâmetros Redes Neurais Artificiais para os produtos P13 e P8.

	P13	P8
Camada de Entrada	3,00	3,00
Camada Escondida	9,00	8,00
Camada de Saída	1,00	1,00
Pesos	46,00	41,00
Valor Inicial	1.224.267.734,81	1.121.632.638,20
Iteração 10 (valor)	171.919.969,20	287.141.323,41
Iteração 20 (valor)	159.363.941,80	217.213.249,25
Iteração 30 (valor)	135.268.316,25	189.438.670,04
Iteração 40 (valor)	102.475.326,11	180.421.843,54
Iteração 50 (valor)	72.472.101,99	128.113.243,06
Iteração 60 (valor)	45.153.979,66	125.876.554,52
Iteração 70 (valor)	43.082.704,65	125.875.086,75
Iteração 80 (valor)	42.751.529,29	
Iteração 90 (valor)	33.776.532,31	
Iteração 100 (valor)	32.813.793,84	
Valor Final	32.813.793,84	125.875.073,86

4.3 Análise Comparativa dos Desempenhos dos Modelos

Nesta seção será tratada a análise comparativa entre os métodos levando em consideração o seu desempenho em relação às previsões, conforme descrito na seção 3.2.3. Depois da parametrização dos modelos de previsão de demanda, descrito na seção anterior, realizou-se a previsão para os meses de maio, junho e julho de 2007, pelos referidos métodos. Esta previsão foi comparada entre o método utilizado pela empresa e os métodos identificados nesta pesquisa, com base na demanda real do período, tendo o erro absoluto médio percentual (EAMP) como critério de validação.

É importante salientar que a empresa forneceu a demanda real (D_t) e a previsão realizada (F_t) pelo método atual para os meses de maio, junho e julho de 2007, conforme se encontra no ANEXO A, para todos os produtos das duas categorias em análise. As Tabelas 4.11, 4.12, 4.13 e 4.14 apresentam a demanda real e as previsões realizadas pelo método atual, Holt-Winters, Box-Jenkins e Rede Neural Artificial (RNA) para as duas categorias.

Tabela 4.11: Previsões pelo Método Atual e Holt-Winters para a Categoria 1.

Produtos	Demanda Real (D_t)			Método Atual (F_t)				Holt-Winters			
	05/2007	06/2007	07/2007	05/2007	06/2007	07/2007	TS_t	05/2007	06/2007	07/2007	TS_t
P1	23.081	13.140	14	21.967	13.548	0	-1,41	23.827	18.877	17.050	3,00
P2	23.291	12.781	16.788	20.242	12.187	19.578	-0,40	21.953	18.397	19.188	2,14
P3	73.341	47.266	39.135	65.511	40.587	50.959	-0,31	73.553	52.133	40.935	3,00
P4	49.856	31.134	23.470	51.246	30.410	33.200	2,63	44.537	34.846	27.784	0,61
P5	16.149	7.981	7.920	16.278	7.526	0	-2,91	20.309	10.267	11.637	3,00
P6	38.122	21.973	19.028	39.651	20.318	29.166	2,25	40.763	30.894	26.680	3,00
P7	23.842	13.804	13.699	23.882	13.562	15.834	2,40	21.982	17.922	15.356	1,54
P8	59.938	36.240	15.902	60.738	40.385	0	-1,58	77.582	29.644	39.627	2,17
P9	16	1718	0	0	0	0	-3,00	19438	12728	8493,9	3,00
P10	14.456	9.757	1.456	16.077	7.377	0	-1,22	9.198	4.534	2.862	-2,29
P11	38.229	27.720	21.607	39.323	22.051	29.683	0,71	44.301	37.211	32.060	3,00
P12	23.144	13.313	13.428	29.403	14.970	0	-0,77	21.664	14.827	14.266	0,68
P13	4.693	2.037	2.720	5.600	3.081	3.245	3,00	4.515	2.238	1.866	-2,02
P14	23.847	12.440	9.368	27.662	13.389	0	-0,98	23.376	16.006	15.253	2,72
P15	22.665	11.824	11.124	23.812	11.373	0	-2,46	19.291	9.797	6.556	-3,00
P16	46.000	28.819	32.062	50.841	25.806	0	-2,27	51.324	32.379	28.614	1,32
P17	26.140	13.578	11.389	31.084	14.181	0	-1,03	25.153	11.624	17.589	1,07
P18	14.929	9.426	11.967	14.374	12.309	14.546	2,45	12.133	6.964	6.140	-3,00
P19	20.771	12.372	14.289	23.942	13.455	15.132	3,00	17.788	9.638	11.478	-3,00
P20	36.842	24.826	22.243	35.330	16.324	19.788	-3,00	31.288	17.924	13.488	-3,00
P21	24.629	15.549	3.140	26.029	13.818	0	-1,66	22.484	16.645	14.204	2,10
P22	25.269	17.079	13.674	24.053	20.012	15.337	1,74	25.526	24.464	16.940	3,00
P23	32.807	16.936	14.671	32.027	21.548	19.231	2,53	28.302	13.449	12.936	-3,00
P24	9.307	5.474	3.485	15.443	6.558	3.950	3,00	5.167	840	968	-3,00
P25	6.812	2.932	4.203	6.790	4.217	5.359	2,95	6.216	4.104	3.958	0,49
P26	15.001	9.712	7.177	11.027	5.968	6.363	-3,00	12.735	3.837	1.853	-3,00
P27	31.547	23.000	21.770	34.458	19.757	26.126	1,15	35.604	26.760	22.815	3,00
P28	5.743	2.262	2.738	6.667	4.043	4.693	3,00	6.023	3.000	3.385	3,00

Tabela 4.12: Previsões por Box-Jenkins e Rede Neural Artificial para a Categoria 1.

Produtos	Demanda Real (D_t)			Box-Jenkins				Rede Neural Artificial			
	05/2007	06/2007	07/2007	05/2007	06/2007	07/2007	TS_t	05/2007	06/2007	07/2007	TS_t
P1	23.081	13.140	14	20.068	14.277	14.189	2,01	25.519	12.348	16.800	2,76
P2	23.291	12.781	16.788	19.740	11.348	15.821	-3,00	24.782	9.969	15.284	-1,46
P3	73.341	47.266	39.135	68.977	45.338	39.276	-2,87	78.339	48.974	43.052	3,00
P4	49.856	31.134	23.470	42.042	22.800	29.642	-1,34	51.177	31.132	20.001	-1,35
P5	16.149	7.981	7.920	17.349	8.975	7.497	2,03	17.166	7.715	7.818	1,40
P6	38.122	21.973	19.028	37.699	24.574	23.056	2,64	36.891	21.880	20.259	-0,11
P7	23.842	13.804	13.699	20.804	11.579	14.193	-2,49	22.851	12.926	11.426	-3,00
P8	59.938	36.240	15.902	69.849	24.365	34.403	1,23	59.136	35.081	16.591	-1,44
P9	16	1718	0	19.362	7.647	9.862	3,00	15.220	6.673	4.626	3,00
P10	14.456	9.757	1.456	17.475	7.096	8.283	1,72	14.967	9.434	3.881	2,41
P11	38.229	27.720	21.607	38.545	23.632	21.056	-2,62	39.246	36.623	22.988	3,00
P12	23.144	13.313	13.428	23.435	12.461	15.512	1,42	23.488	14.116	14.093	3,00
P13	4.693	2.037	2.720	4.166	2.738	3.032	0,95	4.777	2.109	2.599	0,38
P14	23.847	12.440	9.368	17.826	9.160	7.947	-3,00	22.143	12.885	9.291	-1,80
P15	22.665	11.824	11.124	21.918	8.382	9.496	-3,00	22.968	12.249	11.351	3,00
P16	46.000	28.819	32.062	60.512	29.118	33.382	3,00	51.656	27.333	33.278	1,93
P17	26.140	13.578	11.389	26.178	13.011	18.824	2,58	26.314	15.197	11.619	3,00
P18	14.929	9.426	11.967	12.655	5.327	7.223	-3,00	14.605	9.815	12.691	1,65
P19	20.771	12.372	14.289	19.824	11.925	13.488	-3,00	20.079	12.405	14.004	-2,80
P20	36.842	24.826	22.243	35.506	15.868	15.816	-3,00	36.169	23.811	23.608	-0,32
P21	24.629	15.549	3.140	26.225	12.698	15.383	1,98	24.837	17.208	15.104	3,00
P22	25.269	17.079	13.674	22.294	16.516	12.748	-3,00	26.479	16.340	13.711	0,77
P23	32.807	16.936	14.671	30.977	17.346	18.629	1,23	31.374	17.366	13.711	-2,09
P24	9.307	5.474	3.485	9.482	5.323	5.783	2,65	9.399	6.859	4.070	3,00
P25	6.812	2.932	4.203	6.506	4.487	4.943	2,29	7.231	3.445	5.379	3,00
P26	15.001	9.712	7.177	18.919	15.490	20.811	3,00	16.944	9.136	7.161	1,60
P27	31.547	23.000	21.770	31.120	19.062	20.434	-3,00	29.472	24.234	22.496	-0,09
P28	5.743	2.262	2.738	5.504	3.375	4.471	2,54	5.234	1.882	1.945	-3,00

Tabela 4.13: Previsões pelo Método Atual e Holt-Winters para a Categoria 2.

Produtos	Demanda Real (D_t)			Método Atual (F_t)				Holt-Winters			
	05/2007	06/2007	07/2007	05/2007	06/2007	07/2007	TS_t	05/2007	06/2007	07/2007	TS_t
P1	30.327	22.301	7.226	36.730	22.101	0	-0,22	23.827	18.877	17.050	3,00
P2	35.659	20.683	41.617	44.091	31.009	48.195	3,00	21.953	18.397	19.188	3,00
P3	29.108	19.773	24.962	30.115	22.813	28.981	3,00	73.553	52.133	40.935	3,00
P4	45.495	41.001	57.665	49.497	31.798	54.658	-1,52	44.537	34.846	27.784	3,00
P5	19.841	15.852	13.015	24.231	7.509	0	-1,98	20.309	10.267	11.637	0,25
P6	51.959	41.239	50.003	51.362	32.225	52.268	-1,86	40.763	30.894	26.680	3,00
P7	23.148	22.733	27.754	27.104	17.695	22.545	-1,33	21.982	17.922	15.356	1,51
P8	2.105	3.790	4.239	6.084	2.309	3.528	0,87	77.582	29.644	39.627	2,27
P9	19.021	17.314	11.785	22.724	11.717	0	-1,95	19438	12728	8493,9	2,14
P10	23	0	0	0	0	0	-3,00	9.198	4.534	2.862	3,00
P11	12.611	10.282	2.047	10.108	4.453	0	-3,00	44.301	37.211	32.060	-0,19
P12	32.254	25.567	35.181	34.004	26.759	38.932	3,00	21.664	14.827	14.266	3,00
P13	29.442	23.112	33.175	31.341	23.288	30.545	-0,35	4.515	2.238	1.866	-1,15
P14	5.045	5.371	7.565	4.982	4.280	8.912	0,23	23.376	16.006	15.253	-2,78
P15	57.357	42.324	51.652	56.171	43.066	52.958	0,80	19.291	9.797	6.556	-0,78
P16	33.300	25.128	2.709	33.733	20.887	0	-2,65	51.324	32.379	28.614	3,00

Tabela 4.14: Previsões por Box-Jenkins e Rede Neural Artificial para a Categoria 2.

Produtos	Demanda Real (D_t)			Box-Jenkins				Rede Neural Artificial			
	05/2007	06/2007	07/2007	05/2007	06/2007	07/2007	TS _t	05/2007	06/2007	07/2007	TS _t
P1	30.327	22.301	7.226	30.520	29.813	27.368	3,00	30.500	19.294	6.805	-2,71
P2	35.659	20.683	41.617	48.237	33.090	41.685	3,00	33.611	23.750	39.990	-0,27
P3	29.108	19.773	24.962	26.857	17.438	19.710	-3,00	26.181	20.372	24.433	-2,11
P4	45.495	41.001	57.665	53.348	35.521	46.089	-1,11	47.463	38.828	62.679	1,58
P5	19.841	15.852	13.015	21.981	14.102	24.211	2,30	20.636	15.840	11.862	-0,57
P6	51.959	41.239	50.003	53.162	31.509	42.256	-2,61	53.429	43.501	48.526	1,30
P7	23.148	22.733	27.754	23.877	16.231	20.552	-2,70	24.114	22.809	28.228	3,00
P8	2.105	3.790	4.239	4.904	1.955	3.159	-0,06	1.750	3.008	4.357	-2,44
P9	19.021	17.314	11.785	24.873	16.277	25.408	2,70	25.814	22.356	20.849	3,00
P10	23	0	0	23.454	18.465	21.095	3,00	21.800	17.860	144.235	3,00
P11	12.611	10.282	2.047	18.772	10.669	13.141	3,00	14.403	10.483	7.157	3,00
P12	32.254	25.567	35.181	34.527	25.358	27.761	-1,62	32.905	27.266	37.829	3,00
P13	29.442	23.112	33.175	31.542	24.992	29.138	-0,02	28.421	23.355	33.174	-1,85
P14	5.045	5.371	7.565	6.272	4.427	5.550	-1,24	5.085	2.629	6.943	-2,93
P15	57.357	42.324	51.652	55.027	39.901	46.402	-3,00	54.724	26.025	47.956	-3,00
P16	33.300	25.128	2.709	39.870	26.030	35.031	3,00	36.947	23.287	30.001	2,66

Pode-se verificar nas tabelas acima que as previsões realizadas com o método atualmente utilizado pela empresa, bem como, os métodos contemplados nesta pesquisa não apresentam nenhum viés significativo, ou seja, conforme descrito na seção 2.4.7, observa-se que o TS_t em todos os períodos está dentro da faixa de ± 6 , significando que as previsões não estão enviesadas (subestimada – razão de viés abaixo de -6; superestimada – razão de viés acima de +6). O que indica que os métodos de previsão utilizados nesta análise estão adequados aos seus propósitos [CHO03] e [HAN01].

Segundo [CHO03], se o TS estiver fora da faixa descrita acima, há a necessidade de se optar pela escolha de um novo modelo de previsão. Por exemplo, numa situação em que o resultado é uma grande razão de viés negativa, o que ocorre quando a demanda tem uma tendência de crescimento e a opção de utilização de um modelo de previsão se dá pela média móvel. Uma vez que a tendência não está incluída, a média da demanda histórica será sempre menor que a demanda futura. A razão de viés negativa detectará que o modelo de previsão está consistentemente subestimando a demanda, servindo como um alerta [CHO03].

Na sequência do processo da análise comparativa do desempenho, com base nas previsões realizadas, conforme apresentadas acima, são agrupados os dados relativos ao erro absoluto médio percentual (EAMP) dos métodos de previsão utilizados, os quais são demonstrados nas Tabelas 4.15 e 4.16.

Tabela 4.15: EAMP entre os métodos de previsão para a Categoria 1.

Produtos	Demanda Real (D_t)			Método Atual	Holt-Winters	Box-Jenkins	RNA
	05/2007	06/2007	07/2007	EAMP _t	EAMP _t	EAMP _t	EAMP _t
P1	23.081	13.140	14	36	40.578	33.757	39.972
P2	23.291	12.781	16.788	11	21	11	12
P3	73.341	47.266	39.135	18	5	3	7
P4	49.856	31.134	23.470	16	14	23	6
P5	16.149	7.981	7.920	35	34	8	4
P6	38.122	21.973	19.028	22	29	11	3
P7	23.842	13.804	13.699	6	17	11	9
P8	59.938	36.240	15.902	38	66	55	3
P9	16	1718	0	67	40.676	40.419	31.771
P10	14.456	9.757	1.456	45	62	172	58
P11	38.229	27.720	21.607	20	33	6	14
P12	23.144	13.313	13.428	46	8	8	4
P13	4.693	2.037	2.720	30	15	19	3
P14	23.847	12.440	9.368	41	31	22	4
P15	22.665	11.824	11.124	36	24	16	2
P16	46.000	28.819	32.062	40	12	12	7
P17	26.140	13.578	11.389	41	24	23	5
P18	14.929	9.426	11.967	19	31	33	4
P19	20.771	12.372	14.289	10	19	5	2
P20	36.842	24.826	22.243	16	27	23	4
P21	24.629	15.549	3.140	39	123	138	131
P22	25.269	17.079	13.674	11	23	7	3
P23	32.807	16.936	14.671	20	15	12	4
P24	9.307	5.474	3.485	33	67	24	14
P25	6.812	2.932	4.203	24	18	25	17
P26	15.001	9.712	7.177	25	50	92	6
P27	31.547	23.000	21.770	14	11	8	5
P28	5.743	2.262	2.738	55	20	39	18

Tabela 4.16: EAMP entre os métodos de previsão para a Categoria 2.

Produtos	Demanda Real (D_t)			Método Atual	Holt-Winters	Box-Jenkins	RNA
	05/2007	06/2007	07/2007	EAMP _t	EAMP _t	EAMP _t	EAMP _t
P1	23.081	13.140	14	41	117	104	7
P2	23.291	12.781	16.788	30	80	32	8
P3	73.341	47.266	39.135	12	30	14	5
P4	49.856	31.134	23.470	12	20	17	6
P5	16.149	7.981	7.920	58	25	36	4
P6	38.122	21.973	19.028	9	31	14	4
P7	23.842	13.804	13.699	19	10	19	2
P8	59.938	36.240	15.902	82	74	69	13
P9	16	1718	0	17	13	12	22
P10	14.456	9.757	1.456	33	38.062	33.958	31.561
P11	38.229	27.720	21.607	59	133	198	89
P12	23.144	13.313	13.428	7	25	10	5
P13	4.693	2.037	2.720	5	13	9	2
P14	23.847	12.440	9.368	13	15	23	20
P15	22.665	11.824	11.124	2	13	7	17
P16	46.000	28.819	32.062	39	436	405	342

Com base nos erros descritos nas tabelas acima se realizou a comparação entre os métodos de previsão por categoria, para verificar qual método apresentou o menor erro, ou seja, maior precisão. Para esta análise procurou-se encontrar um intervalo de confiança, o qual é um método usual de especificar a precisão, que proporcionasse um intervalo de valores plausíveis para a comparação do erro entre os métodos.

Neste sentido, para a obtenção do intervalo de confiança, onde ℓ_1 e ℓ_2 são, respectivamente, os limites inferior e superior do intervalo de confiança, calculou-se a média (\bar{X}) e o desvio-padrão da amostra (s). Determinou-se como tamanho da amostra (n) todo o conjunto de erros obtidos, ou seja, para a Categoria 1 com 28 produtos, n igual a 28, para a Categoria 2 com 16 produtos, n igual a 16. Nesse caso, utilizou-se a distribuição t (*Student*) com $n-1$ graus de liberdade, para coeficiente de confiança $(1 - \alpha)$ desejado de 95% ($1 - \alpha$ para 95%, portanto, $\alpha = 0,05$).

Os resultados obtidos desta análise encontram-se na Tabela 4.17. Uma vez que o comprimento do intervalo de confiança mede a precisão da estimação, pode-se observar que a precisão é inversamente relacionada com o nível de confiança. A intenção, portanto, é a obtenção de um intervalo relativamente curto e com alta confiança. Neste caso, percebe-se que os produtos P1 e P9 da Categoria 1 e P10 e P16 da Categoria 2, não proporcionam um intervalo curto para os métodos utilizados nesta pesquisa, devido aos valores dos erros serem elevados para os mesmos.

Tabela 4.17: Análise comparativa dos métodos de previsão por categoria.

Dados	Categoria 1				Categoria 2			
	Método Atual	Holt-Winters	Box-Jenkins	RNA	Método Atual	Holt-Winters	Box-Jenkins	RNA
\bar{X}	29,07	2.930,46	2.677,93	2.574,80	27,38	2.443,56	2.182,94	2.006,64
s	14,88	10.647,03	9.761,04	9.470,39	23,15	9.498,83	8.473,98	7.881,60
$1-\alpha$	0,05	0,05	0,05	0,05	0,05	0,05	0,05	0,05
ℓ_1	23,30	-1.199,54	-1.108,39	-1.098,79	15,04	-2.616,94	-2.331,58	-2.192,28
ℓ_2	34,84	7.060,46	6.464,25	6.248,38	39,71	7.504,07	6.697,45	6.205,56

Não seria possível afirmar qual método é o mais adequado para as Categorias 1 e 2, pois o comprimento do intervalo de confiança do método de Holt-Winters abrange os intervalos dos demais métodos comprometendo a precisão e a confiança numa tomada de decisão.

Devido ao problema do comprimento do intervalo de confiança dificultar a

identificação do método adequado, ocasionado pelos valores elevados dos produtos identificados acima, uma alternativa elaborada foi a de excluir os produtos que distorcem os resultados dos métodos analisados e refazer os cálculos, os quais são, então, apresentados na Tabela 4.18.

Tabela 4.18: Análise comparativa dos métodos de previsão por categoria.

Dados	Categoria 1				Categoria 2			
	Método Atual	Holt-Winters	Box-Jenkins	RNA	Método Atual	Holt-Winters	Box-Jenkins	RNA
X	29,07	30,73	31,00	13,49	27,38	42,79	40,29	14,53
s	14,88	25,30	41,28	26,35	23,15	41,11	52,86	22,30
1-α	0,05	0,05	0,05	0,05	0,05	0,05	0,05	0,05
ℓ_1	23,30	20,51	14,33	2,85	15,04	19,04	9,76	1,65
ℓ_2	34,84	40,95	47,67	24,14	39,71	66,53	70,81	27,41

Com os novos dados, observou-se que há, ainda, uma sobreposição dos intervalos de confiança entre os métodos, sendo que nesta análise, o comprimento do intervalo de confiança do método de Box-Jenkins abrange o intervalo do método atual, do método Holt-Winters e do limite superior da Rede Neural.

Ao considerar-se a média, o desvio-padrão da amostra e os limites do intervalo de confiança, a Rede Neural apresenta os melhores resultados, indicando ser o método mais adequado para as Categorias 1 e 2, devido ao critério do menor erro. Diz-se que há 95% de confiança de que a média do erro do método adequado para a Categoria 1 está entre um intervalo de $2,85 \leq \mu \leq 24,14$ e para a Categoria 2 está entre um intervalo de $1,65 \leq \mu \leq 27,41$. A Rede Neural proporciona um intervalo relativamente curto com alta confiança.

Entretanto, percebe-se que a nível de produtos existe um desempenho melhor por parte de outros métodos, ou seja, alguns métodos apresentam um erro menor para determinado produto em relação aos demais. Isto indica a necessidade de uma outra avaliação para comparar os resultados a nível de produto também, pois como exposto acima, considerou-se na análise a média da categoria, sendo que alguns resultados que estavam elevados comprometeram a avaliação dos métodos. Desta forma, para se ter uma análise mais criteriosa ou uma análise complementar, optou-se pela comparação entre os produtos.

As Tabelas 4.19 e 4.20 apresentam os dados desta comparação, os quais seguem o mesmo processo de avaliação utilizado para as categorias, ou seja, o intervalo de confiança.

Tabela 4.19: Análise comparativa dos métodos de previsão por produto.

Produtos	Método Atual (F_t)			Holt-Winters			Box-Jenkins			Rede Neural Artificial		
	X	ℓ_1	ℓ_2	X	ℓ_1	ℓ_2	X	ℓ_1	ℓ_2	X	ℓ_1	ℓ_2
P1	15	-6	36	13.535	-12.999	40.069	11.260	-10.813	33.333	13.330	-29.107	55.768
P2	11	9	14	17	6	29	13	11	16	11	3	19
P3	14	9	18	4	0	7	5	3	6	6	5	8
P4	7	-1	15	12	10	14	20	16	24	3	-1	8
P5	13	-9	35	29	24	34	9	7	10	5	2	7
P6	10	-1	21	20	7	33	6	1	12	3	1	4
P7	2	-1	6	14	8	21	13	11	15	6	1	11
P8	15	-7	37	40	14	65	32	9	55	2	1	4
P9	89	67	111	74.359	26.800	121.917	73.987	26.543	121.430	58.151	-2.375	118.677
P10	25	4	45	48	33	63	72	-26	170	22	-36	79
P11	12	2	21	25	15	34	5	1	9	11	-3	25
P12	31	15	47	8	6	9	4	1	8	3	0	6
P13	28	19	37	9	2	15	18	11	24	3	1	4
P14	23	5	41	16	0	33	24	22	27	5	2	8
P15	15	-5	36	18	13	24	12	3	20	2	1	3
P16	20	1	40	12	11	12	20	8	32	9	4	14
P17	24	7	41	12	0	24	9	-6	23	4	-1	9
P18	13	4	22	24	17	31	26	15	36	3	1	5
P19	12	9	15	17	14	20	4	4	5	2	1	4
P20	13	4	22	21	14	28	15	4	27	3	1	5
P21	18	-3	39	46	-28	121	52	-32	137	46	-90	181
P22	9	5	13	15	1	29	9	6	12	4	3	6
P23	12	2	23	15	13	17	7	2	12	4	3	5
P24	47	28	66	59	45	73	9	-5	23	10	-4	23
P25	15	1	30	17	8	26	19	5	34	12	2	22
P26	28	24	32	34	14	54	54	15	92	10	4	16
P27	12	9	15	13	11	15	6	1	11	6	5	7
P28	40	16	63	15	5	24	23	3	43	13	5	22

Tabela 4.20: Análise comparativa dos métodos de previsão por produto.

Produtos	Método Atual (F_t)			Holt-Winters			Box-Jenkins			Rede Neural Artificial		
	X	ℓ_1	ℓ_2	X	ℓ_1	ℓ_2	X	ℓ_1	ℓ_2	X	ℓ_1	ℓ_2
P1	24	7	41	46	-25	116	41	-22	104	5	-2	11
P2	30	23	38	74	49	100	38	29	48	8	4	12
P3	8	3	13	19	3	35	10	7	14	7	3	12
P4	12	8	16	21	20	21	16	15	18	5	3	7
P5	39	19	60	20	13	26	19	3	36	3	1	6
P6	7	1	13	26	22	31	10	2	17	4	2	5
P7	19	17	20	15	8	22	13	3	22	3	1	5
P8	128	66	191	127	54	200	98	61	134	16	11	21
P9	21	16	26	18	12	24	20	10	31	30	16	43
P10	61	22	100	69.781	24.897	11.4665	62.256	22.213	102.300	57.862	-2.559	11.8282
P11	39	17	61	65	-2	131	91	-15	197	37	-45	119
P12	6	5	7	28	24	32	7	4	10	4	1	7
P13	5	3	7	9	6	13	8	7	9	2	1	4
P14	8	1	16	8	0	15	23	21	25	16	-9	40
P15	2	2	2	10	7	14	5	4	7	14	-2	30
P16	17	-6	39	153	-124	431	146	-109	401	121	-232	473

A média e o desvio-padrão da amostra foram obtidos da previsão realizada para os meses de maio, junho e julho de 2007 de cada produto, portanto, o n (tamanho da amostra) é igual a 3.

Percebe-se na Tabela 4.19 que o método atual obteve um melhor desempenho para os produtos P1, P2, P7, P9, P10 e P21, enquanto, o método de Box-Jenkins se destacou para os produtos P3 e P11, e os demais foram atendidos pela Rede Neural. Na Tabela 4.20, o método atual apresentou um desempenho melhor para os produtos P12, P14, P15 e P16, sendo que nos demais produtos a Rede Neural obteve melhor desempenho.

Novamente observaram-se sobreposições ou interseções entre os intervalos de confiança, indicando alguns valores em comum. Construíram-se gráficos com esses intervalos, para os dois conjuntos de produtos, contra um eixo comum para verificar esta interseção, como apresentados nas Figuras 4.13 e 4.14. Se não houvesse sobreposição dos intervalos, então seria possível afirmar ter-se, pelo menos, 95% de confiança de que as verdadeiras médias não são iguais.




Figura 4.13: Interseção dos intervalos de confiança para os produtos da Categoria 1.




Figura 4.14: Interseção dos intervalos de confiança para os produtos da Categoria 2.

As sobreposições nas medidas obtidas do intervalo de confiança indicam que não há diferença significativa entre as medidas de alguns produtos. O que indica que os métodos de previsão atendem de forma adequada o processo de previsão para os produtos, contudo ao considerar-se a média, o desvio-padrão da amostra e os limites do intervalo de confiança, a Rede Neural apresenta os melhores resultados para a maioria dos produtos das duas categorias, devido ao critério do menor erro, conforme indicando nas Tabelas 4.19 e 4.20.

Como análise estatística para a comparação dos erros entre os métodos, com base nas Tabelas 4.15 e 4.16, mantendo a exclusão dos produtos que distorcem os resultados dos métodos analisados, foi realizado um teste de hipóteses de médias através da análise de variância (ANOVA) e da comparação múltipla entre médias (Tukey).

A ANOVA é um procedimento utilizado para comparar três ou mais tratamentos, a qual se baseia na decomposição da variação total da variável resposta em partes que podem ser atribuídas aos tratamentos (variância entre) e ao erro experimental ou resíduo (variância dentro). Essa variação pode ser medida por meio das somas de quadrados definidas para cada um dos componentes, as quais podem ser organizadas em uma tabela, como apresentado na Tabela 4.21.

A utilização da ANOVA pode ser sintetizada por três procedimentos:

- Formulação das hipóteses;
- Estabelecimento do nível de significância;
- Validação da hipótese.

Tabela 4.21: Análise de variância (ANOVA).

Fonte de Variação	Soma dos Quadrados	Graus de Liberdade	Média dos Quadrados	Teste F	Pr (> F); valor-p
Entre Grupos	SQG	k-1	MQG	MQG/MQR	
Dentro dos Grupos	SQR	n-k	MQR		
Total	SQT	n-1			

As hipóteses formuladas para esta análise foram baseadas no EAMP entre os métodos de previsão, onde:

- $H_0: E_{M1}=E_{M2}=E_{M3}=E_{M4}$
- H_1 : há alguma diferença

No teste de hipótese pode-se deparar com dois tipos de erros:

- Erro tipo I – consiste em rejeitar H_0 , sendo que H_0 é verdadeira;
- Erro tipo II – consiste em aceitar H_0 , sendo que H_0 é falso.

A probabilidade da ocorrência do erro tipo I é denominada, no teste de hipótese, como nível de significância (α). O nível de significância determinado para esta análise é de 5%, o que consiste em dizer que existe uma probabilidade de 5% dos dados possuírem H_0 e serem considerados como H_1 .

A decisão de rejeitar a hipótese H_0 consiste numa comparação do valor F calculado com o F crítico correspondente ao nível de significância (α) adotado. Também podem ser comparados o *p-value* do F calculado e o nível de significância (α). Convém lembrar que esse teste é válido se os pressupostos assumidos para os erros do modelo estiverem satisfeitos.

Nas Tabelas 4.22 e 4.23 são apresentados os resultados da análise de variância, obtidos por meio da utilização do pacote estatístico R, para as duas categorias em estudo. Como o F calculado é maior que o F crítico, para as duas categorias, o teste é significativo, ou seja, a hipótese H_0 é rejeitada a favor da hipótese alternativa ao risco de 5%.

Tabela 4.22: Análise de variância por categoria.

Categoria 1					
Fonte de Variação	Soma dos Quadrados	Graus de Liberdade	Média dos Quadrados	Teste F	Pr (> F); valor-p
Entre Grupos	28,565	3	9,522	13,789	1,35E-07
Dentro dos Grupos	69,052	100	0.691		
Total	97,617	103			
Categoria 2					
Fonte de Variação	Soma dos Quadrados	Graus de Liberdade	Média dos Quadrados	Teste F	Pr (> F); valor-p
Entre Grupos	13,448	3	4,483	3,1998	3,01E-02
Dentro dos Grupos	78,454	56	1,401		
Total	91,902	59			

Como há diferenças significativas entre os grupos, ou seja, observa-se que a MQG é maior do que a MQR, o que indica uma forte variância entre os grupos, da mesma forma, rejeita-se a hipótese nula. Para verificar e entender a diferença entre as médias foi elaborado o gráfico *box plot*, no qual a comparação entre os traços centrais das “caixas”, que representam o valor mediano do método, possibilitam visualizar onde estão localizadas as diferenças.




Figura 4.15: Box plot da Categoria 1.




Figura 4.15: Box plot da Categoria 2.

Como pode ser observado na Tabela 4.22 e nas Figuras 4.14 e 4.15²³, houve diferença significativa dos erros em relação aos métodos, o que exige a aplicação de um teste complementar para verificar quais grupos são diferentes, neste caso o teste de Tukey. O procedimento é o de comparar as médias dos grupos para identificar qual ou quais grupos é ou são diferente(s).

O teste de Tukey permite testar qualquer contraste, sempre, entre duas médias de tratamentos, ou seja, não permite comparar grupos entre si. O teste baseia-se na Diferença Mínima Significativa (DMS). O nível de significância (α) para o teste será de 5%.

Como o teste de Tukey é de certa forma, independente do teste F, é possível que, mesmo sendo significativo o valor de F calculado, não se encontre diferenças significativas entre contrastes de médias. Se o contraste for maior do que a Diferença Mínima Significativa (DMS), então as médias diferem ao nível de significância (α).

As Tabelas 4.24 e 4.25 apresentam os resultados do teste de Tukey, implementados no pacote estatístico R.

²³ Devido à sobreposição dos dados ocorrida durante a análise do intervalo de confiança, utilizou-se para as Figuras 4.14 e 4.15 uma escala logarítmica, visando proporcionar uma melhor visualização dos dados.

Tabela 4.23: Comparação múltipla entre médias por categoria.

Categoria 1				
Métodos	Diferença	Limite Superior	Limite Inferior	<i>p</i> Ajustado
M2-M1	0,005438	-0,596728	0,607603	0,999995
M3-M1	-0,279309	-0,881474	0,322857	0,620789
M4-M1	-1,272031	-1,874196	-0,669865	0,000002
M3-M2	-0,284747	-0,886912	0,317419	0,605900
M4-M2	-1,277469	-1,879634	-0,675303	0,000001
M4-M3	-0,992722	-1,594887	-0,390557	0,000224
Categoria 2				
Métodos	Diferença	Limite Superior	Limite Inferior	<i>p</i> Ajustado
M2-M1	0,687283	-0,457132	1,831698	0,392414
M3-M1	0,484042	-0,660373	1,628457	0,678873
M4-M1	-0,538527	-1,682943	0,605888	0,600635
M3-M2	-0,203241	-1,347656	0,941174	0,965285
M4-M2	-1,22581	-2,370226	-0,081395	0,031306
M4-M3	-1,022569	-2,166985	0,121846	0,095655

As colunas métodos, das tabelas acima, representam modelos de previsão analisados nesta pesquisa, ou seja, método atual da empresa (M1), Holt-Winters (M2), Box-Jenkins (M3) e Rede Neural Artificial (M4). O teste de Tukey indicou que para a Categoria 1 e 2 a Rede Neural Artificial apresentou diferença significativa, ou seja, rejeita a hipótese H_0 em comparação com todos os outros métodos utilizados.

Após a realização deste teste e analisando, novamente as Figuras 4.14 e 4.15, que fornecem uma visualização clara e rápida da variabilidade dos erros dos métodos e da distribuição de seus dados, comparando-os entre si, percebe-se que o método M4 (Rede Neural Artificial) possui um desempenho melhor, o que foi verificado quando da análise realizada com base na média, no desvio-padrão da amostra e nos limites do intervalo de confiança.

Desta forma, os principais resultados obtidos indicam que o método atualmente utilizado pela empresa é adequado. Entretanto, os outros métodos de previsão analisados seriam igualmente aplicáveis. Alguns deles apresentaram melhores resultados (previsões mais exatas, erros menores), como é o caso dos métodos de previsão de rede neural artificial (o melhor entre os três métodos analisados).

Capítulo 5

Comentários Finais

Esta pesquisa analisou três métodos de previsão para identificar os modelos mais adequados para produtos de uma empresa do setor de perfumes e cosméticos. O método de suavização exponencial, o método de Box-Jenkins e as redes neurais artificiais foram implementados para definir, analisar e selecionar modelos de previsão. Através de um estudo comparativo, a partir das previsões realizadas pelo método atual, da demanda real da empresa e das previsões realizadas com os métodos considerados foi verificada a eficiência de cada método definida pelo erro absoluto médio percentual (EAMP) e o sinal de rastreabilidade (TS).

As duas categorias de produtos utilizadas têm um impacto significativo nos custos e investimentos da empresa em questão. O comportamento sazonal apresentado por estas categorias, dificulta a previsão da demanda, afetando a eficiência da cadeia produtiva da empresa, uma vez que a previsão é fundamental para o planejamento da produção e para o início do processo de suprimento. Os efeitos que os erros ocasionam na previsão podem levar ao não atendimento da demanda, atraso neste atendimento e/ou excesso de estoques. Estas condições aumentam os custos do produto e afetam a lucratividade do negócio.

A busca pelo método mais adequado, teve o objetivo de minimizar tais efeitos que os erros de previsões têm gerado na empresa. Desta forma, quanto maior a acuracidade da previsão da demanda menor serão os impactos no nível de atendimento e custos na cadeia de suprimento. Como tratado no desenvolvimento desta pesquisa, o não atendimento destas condições aumentam os custos do produto e afetam a lucratividade do negócio.

Os resultados obtidos indicam que o procedimento metodológico utilizado mostrou-se adequado a proposta deste estudo. O processo de identificação dos métodos mais adequados,

de maneira geral, possibilitou a obtenção de modelos que não apresentavam nenhum viés significativo, ou seja, as previsões não foram subestimada ou superestimada e os erros de previsão ficaram muito próximos do método utilizado pela empresa e da demanda real.

Os métodos utilizados, tanto os tradicionais como o de inteligência artificial, tiveram um bom desempenho em termos de previsão, pois os resultados, na sua maioria, ficaram muito próximos e a avaliação do desempenho, devido às sobreposições das medidas, levam a afirmar que não há diferença significativa entre estas medidas. O que indica que os métodos de previsão, considerados nesta pesquisa, atendem de forma adequada o processo de previsão para os produtos.

Contudo, a sobreposição das medidas tornou-se um problema que levou a realização de um critério de desempate que foi baseado no intervalo de confiança, considerando a média e desvio-padrão da amostra, para a análise da categoria onde a Rede Neural teve um desempenho melhor, ou seja, o menor erro proporcionado. E a análise por produto possibilitou verificar que a utilização de métodos de previsão estocásticos, tal como o método Box-Jenkins e os métodos de previsão determinísticos, como o Holt-Winters, informaram estimativas aproximadas da realidade, podendo ser utilizados para determinados produtos.

Como a previsão de demanda é uma atividade importante no apoio à determinação dos recursos necessários para o gerenciamento logístico da empresa em estudo. Esta análise permitiu avaliar o método de previsão atual e os possíveis pontos, ou melhor, produtos em que os modelos estimados podem auxiliar na melhoria do processo de previsão. A sobreposição verificada pode ser à base de trabalhos futuros, onde uma metodologia de pesquisa diferente possa trabalhar com este “fenômeno”.

Como este trabalho baseou-se exclusivamente no comportamento histórico da demanda, muitos eventos especiais que podiam incidir futuramente sobre o processo gerador dos dados foram desconsiderados. Uma pesquisa explicativa, com método experimental, pode ser a continuação deste estudo, devido à possibilidade de manipulação das variáveis que este tipo de pesquisa oferece, proporcionando o entendimento entre as causas e efeitos destes eventos.

Seria oportuno, também, incorporar métodos que contemplem a avaliação e experiência dos participantes do sistema, de forma a corrigir a previsão para atender a eventos que não venham ocorrendo. Neste sentido, percebe-se que a existência de um setor de análises estatísticas que poderia estar relacionado diretamente ao sistema integrado de gestão

empresarial é um fator importante no tratamento destes dados.

É importante salientar que este trabalho não tem a pretensão de estabelecer que as redes neurais artificiais, apresentam-se como o melhor método de realização de previsão de valores futuros de série temporais. Entretanto, pelos resultados apresentados, pode-se dizer com certa confiança que elas são uma ferramenta poderosa para a realização de previsão de séries temporais, capazes de realizar previsões com o mesmo nível de precisão ou, em alguns casos, até maior que os modelos de séries temporais clássicos considerados nesta pesquisa. Este fato é evidenciado nos casos em que métodos clássicos de previsão não conseguem resultados bons devido a não linearidades, então, as redes neurais artificiais podem obter um desempenho mais significativo em termos de previsão.

O que se percebe é que a principal dificuldade na utilização de redes neurais artificiais para a previsão de séries temporais, ainda é a determinação da arquitetura ótima da rede. Nos vários trabalhos consultados durante a pesquisa bibliográfica, observa-se que ainda não se dispõe de uma metodologia consistente que apresente a melhor configuração da rede para cada série proposta, em especial, em relação à determinação do número de neurônios da camada intermediária.

Como os sistemas de previsão da demanda são utilizados para reduzir o risco inerente a processos decisórios. O risco será tanto menor quanto maior for o grau de precisão associado às previsões. Este aumento na acurácia da previsão acarreta na diminuição das perdas financeiras resultantes da incerteza no processo decisório. Desta maneira, como sugestão para trabalhos futuros, pode-se destacar:

- Utilização de outras metodologias de séries temporais, tais como: à metodologia estrutural de Harvey ou a metodologia Bayesiana de West e Harrison.
- A abordagem de modelos dinâmicos, pois se verificou que os dados necessitam incorporar outras informações como o conhecimento qualitativo de outros agentes envolvidos no processo de previsão, fornecendo um conhecimento a priori mais apurado e com um horizonte de tempo menor.
 - A utilização de métodos híbridos para o processo de previsão.
 - A combinação de redes neurais com outros métodos de previsão, visando uma cooperação com o objetivo de proporcionar uma previsão mais acurada;
 - Uma análise de como o ciclo de vida do produto afeta no processo de previsão de empresas com produtos sazonais. Associado com a manutenção de estoque e o custo de

produção, onde poderiam ser analisadas as questões de tempo do ciclo de vida do produto, tamanho do lote de compra e produção e o seu custo de produção. Realizando uma avaliação se seria viável a continuidade da produção a partir de um determinado ponto do ciclo de vida do produto, antes de criar um estoque de insumos que eventualmente não seriam totalmente utilizados, acarretando um custo adicional ao processo produtivo da empresa em estudo.

Torna-se necessário salientar que o cálculo e acompanhamento dos erros de previsão são necessários para o processo de manutenção e monitoramento das previsões geradas. Desta forma, existe a necessidade de acompanhamento do desempenho do modelo de previsão para que se possa confirmar sua validade e mantê-lo atualizado. Desta maneira, torna-se evidente que se deve priorizar a utilização de modelos de previsão que gerem o menor erro no tempo. Esse procedimento assegura maior segurança na seleção de modelos com fins preditivos que possuam maior grau de acurácia.

Como observação final, é importante salientar que o R como um conjunto integrado de facilidades em software para manipulação de dados e análises estatísticas, apresentou-se adequado, pois a utilização do mesmo se deu em todo o processo de análise e comparação dos métodos de previsão. As técnicas clássicas de análise estatística estão incorporadas na base do ambiente R, e novas técnicas são oferecidas como “pacotes”, o que permite a este software ser estendido facilmente, abrangendo um vasto leque de estatísticas modernas, bem como, ter-se acesso às atualizações mais recentes.

Referências Bibliográficas

- [AGU04] AGUIRRE, L. A. *Introdução à identificação de sistemas: técnicas lineares e não-lineares aplicadas a sistemas reais*. 2. ed. Belo Horizonte: Editora UFMG, 2004.
- [ASH02] ASHBY, M. *How to write a paper*. Cambridge: Engineering Department, University of Cambridge, 2002, v. 5, 38 f.
- [AZE99] AZEVEDO, F. M. *Redes neurais e suas aplicações*. In: ESCOLA DE REDES NEURAIAS. CONSELHO NACIONAL DE REDES NEURAIAS, 5, São José dos Campos, 1999. Anais. São José dos Campos: ITA, 1999.
- [BAL01] BALLOU, Ronald H. *Gerenciamento da cadeia de suprimentos: planejamento, organização e logística empresarial*. 4. ed. Porto Alegre: Bookman, 2001.
- [BAR03] BARBIERO, Claudia C. M. *Séries Temporais: um estudo de previsão para a receita operacional da ECT – Empresa Brasileira de Correios e Telégrafos*. Dissertação de Mestrado em Engenharia de Produção – Faculdade de Engenharia de Produção, Universidade Federal de Santa Catarina, Florianópolis, 2003.
- [BAU04] BAUCHSPIESS, Adolfo. *Introdução aos sistemas inteligentes: aplicações em engenharia de redes neurais artificiais, lógica fuzzy e sistemas neuro-fuzzy*. Disponível em: < <http://www.ene.unb.br/adolfo/ISI> >. Acesso em: 20 julho 2006.
- [BIT08] BITTENCOURT, Guilherme. *Inteligência computacional*. Disponível em: < <http://www.das.ufsc.br/gia/softcomp/softcomp.html> >. Acesso em: 10 abril 2008.
- [BEA99] BEAMON, B. *Measuring supply chain performance*. University of Washington: International Journal of Operations and Production Management. v. 19, n. 3, p. 275-292, 1999.

- [BEL91] BELTRÃO, K. I. *Séries temporais no domínio da frequência: uma introdução*. 4ª Escola de Séries Temporais e Econometria, UFRJ. 1991.
- [BER98] BERTO, R.; NAKANO, D. *Metodologia da pesquisa e a engenharia de produção*. In: ENCONTRO NACIONAL DE ENGENHARIA DE PRODUÇÃO, 18., Niterói, 1998. **Anais...** Niterói: UFF/ABEPRO, 1998.
- [BER02] BERTRAND, J.; FRANSOO, J. *Operations management research methodologies using quantitative modeling*. International Journal of Operations and Production Management. v. 22, n. 2, p. 241-264, 2002.
- [BIL06] BILLAH, B.; KING, M.; SNYDER, R.; KOEHLER, A. *Exponential smoothing model selection for forecasting*. Amsterdam: International Journal of Forecasting. v. 22, n. 2, p. 239-247, abr./jun. 2006.
- [BOU95] BOUMA, G.; ATKINSON, G. *A handbook of social science research: a comprehensive and practical guide for students*. New York: Oxford, 1995.
- [BOW01] BOWERSOX, Donald J.; CLOSS, David J. *Logística empresarial: o processo de integração da cadeia de suprimento*. São Paulo: Atlas, 2001.
- [BOX94] BOX, George E.; JENKINS, Gwilym M.; REINSEL, Gregory C. *Time series analysis: forecasting and control*. 3. ed. Englewood Cliffs: Prentice Hall, 1994.
- [BRI01] BRILLINGER, David R. *Time series: data analysis and theory*. Philadelphia: Siam, 2001.
- [BRY89] BRYMAN, A. *Research methods and organization studies*. London: Unwin Hyman, 1989.
- [CAL01] CALEGARE, Álvaro José de Almeida. *Introdução ao delineamento de experimentos*. São Paulo: Edgard Blücher, 2001.

- [CAL02] CALÔBA, Guilherme M.; CALÔBA, Luiz P.; SALIBY, Eduardo. *Cooperação entre redes neurais artificiais e técnicas “clássicas” para previsão de demanda de uma série de vendas de cerveja na Austrália*. Pesquisa Operacional, Rio de Janeiro, v. 22, n. 3, p. 345-358, abr./dez. 2002.
- [CER02] CERVO, L. A.; BERVIAN, P. A. *Metodologia científica*. 5. ed. São Paulo: Pearson Prentice Hall, 2002.
- [CHA03] CHAN, T. S.; QI, H. J.; LAU, C. W.; IP, W. L. *A conceptual model of performance measurement for supply chains*. Management Decision. v. 41, n. 7, p. 635-642, 2003.
- [CHO03] CHOPRA, Sunil; MEINDL, Peter. *Gerenciamento da cadeia de suprimentos: estratégia, planejamento e operações*. São Paulo: Prentice Hall, 2003.
- [COE03a] COELHO, L. S.; TRAUTWEIN JR., B.; VIEIRA, G. E. *Avaliação de redes neurais e ajustamento exponencial aplicados à previsão de consumo de água a curtíssimo prazo*. In: CONGRESSO BRASILEIRO DE REDES NEURAI, 7, São Paulo, 2003. **Anais...** São Paulo: Congresso Brasileiro de Redes Neurais, 2003.
- [COR04] CORRÊA, Henrique L. *Administração de produção e operações: manufatura e serviços: uma abordagem estratégica*. São Paulo: Atlas, 2004.
- [COR05] CORRÊA, Henrique L. *Supply chain management in Latin America: the Brazilian pharmaceutical industry case*. Disponível em: < <http://www.celog.fgvsp.br/artigos.asp> >. Acesso em: 1 dezembro 2005.
- [COS05] COSTA, Sérgio E. G. *Definições metodológicas e métodos de pesquisa*. Disponível em: < <http://www.pucpr.br/eureka> >. Acesso em: 1 julho 2005.
- [DAV01] DAVIS, Mark M.; AQUILANO, Nicholas J.; CHASE, Richard B. *Fundamentos da administração da produção*. 3. ed. Porto Alegre: Bookman, 2001.

- [DOR00] DORNIER, Philippe-Pierre, *et al.* *Logística e operações globais: textos e casos*. São Paulo: Atlas, 2000.
- [DOW99] DOWNING, Douglas; CLARK, Jeffrey. *Estatística aplicada*. São Paulo: Saraiva, 1999.
- [EAS91] EASTERBY-SMITH, M.; THORPE, R.; LOWE, M. *Management research: an introduction*. London: Sage, 1991.
- [EHL05] EHLERS, Ricardo S. *Análise de séries temporais*. Disponível em: < <http://www.est.ufpr.br/~ehlers/notas> >. Acesso em: 20 julho 2006.
- [EST03] ESTEVES, Gheisa R. T. *Modelos de previsão de carga de curto prazo*. Dissertação de Mestrado em Engenharia de Elétrica – Faculdade de Engenharia de Elétrica, Pontifícia Universidade Católica do Rio de Janeiro, Rio de Janeiro, 2003.
- [FAC03] FACHIN, Odília. *Fundamentos de metodologia*. 4. ed. São Paulo: Saraiva, 2003.
- [FER95] FERNADES, L. G.; PORTUGAL, M. S.; NAVAUX, P. O. *Previsão de séries de tempo: redes neurais artificiais e modelos estruturais*. Pesquisa e Planejamento Econômico, Rio de Janeiro, v. 26, n. 2, p. 253-276, ago. 1996.
- [FOG03] FOGLIATTO, Flávio Sanson. *Previsão da demanda*. DEPROT, UFRGS, p. 01-62, 2003. Disponível em: < <http://www.producao.ufrgs.br> >. Acesso em: 14 julho 2006.
- [GIL02] GIL, Antônio C. *Como elaborar projetos de pesquisa*. 4. ed. São Paulo: Atlas, 2002.
- [GIL06] GILLILAND, M. *Is forecasting a waste of time*. Disponível em: < <http://www.manufacturing.net/scm> >. Acesso em: 14 julho 2006.
- [GOM00] GOMES, Frederico Pimentel. *Curso de estatística experimental*. 14. ed. Piracicaba: ESALQ, 2000.

- [HAN01] HANKE, John E.; WICHERN, Dean W.; REITSCH, Arthur G. *Business forecasting*. 7. ed. New York: Prentice Hall, 2001.
- [HAR05] HARVILL, J.; RAY, B. *A note on multi-step forecasting with functional coefficient autoregressive models*. Amsterdam: International Journal of Forecasting. v. 21, n. 4, p. 717-727, out./dez. 2005.
- [HAY99] HAYKIN, Simon. *Neural networks: a comprehensive foundation*. 2. ed. Englewood Cliffs, New Jersey: Prentice Hall, 1999.
- [HAY01a] HAYKIN, Simon. *Redes neurais: princípios e prática*. 2. ed. Porto Alegre: Bookman, 2001.
- [HAY01b] HAYKIN, Simon; VEEN, Barry Van. *Sinais e sistemas*. Porto Alegre: Bookman, 2001.
- [HYN02] HYNDMAN, R. J.; KOEHLER, A. B.; SNYDER, R. D.; GROSE, S. *A state space framework for automatic forecasting using exponential smoothing methods*. International Journal of Forecasting. v. 18, n. 3, p. 439-454, jul./set. 2002.
- [JUN06] JUNG, R.; TREMAYNE, A. *Coherent forecasting in integer time series models*. Amsterdam: International Journal of Forecasting. v. 22, n. 2, p. 223-238, abr./jun. 2006.
- [KAZ04] KAZMIER, Leonard J. *Estatística aplicada á economia e administração*. São Paulo: Pearson Makron Books, 2004.
- [KEN76] KENDALL, M. *Time series*. 2. ed. London: Charles Griffin e Co. Ltd., 1976.
- [KUH70] KUHN, T. *The structure of scientific revolutions*. 2. ed. Chicago: University of Chicago, 1970.

- [LAK91] LAKATOS, E.; MARCONI, M. *Metodologia científica*. 2. ed. São Paulo: Atlas, 1991.
- [LEV00] LEVINE, M. D.; BERENSON, M. L.; STEPHAN, D. *Estatística: teoria e aplicações – usando Microsoft Excel*. Rio de Janeiro: Editora LTC, 2000.
- [LIM04] LIMA, Fabiano Guasti. *Um método de análise e previsão de sucessões cronológicas unidimensionais lineares e não-lineares*. Tese de Doutorado em Administração – Faculdade de Economia, Administração e Contabilidade, Universidade de São Paulo, São Paulo, 2004.
- [LOP04] LOPES, Luiz A. *Previsão da demanda com planilha eletrônica*. Revista Tecnológica, São Paulo, v. 9, n. 101, p. 79-81, abr. 2004.
- [LOP03] LOPES, Ricardo D. *Modelos de previsão para uma série temporal de produção de veículos automotores*. Revista de Administração Nobel, Maringá, n. 1, p. 27-36, jan./jun. 2003.
- [MAK89] MAKRIDAKIS, S. G.; WHEELWRIGHT, S. C. *Forecasting methods for management*. New York: John Wiley & Sons, 1989.
- [MAK90] MAKRIDAKIS, S. G. *Forecasting planning and strategy for the 21st century*. New York: The Free Press, 1990.
- [MAK98] MAKRIDAKIS, S. G.; WHEELWRIGHT, S. C.; HYNDMAN, R. J. *Forecasting methods and applications*. 3. ed. New York: John Wiley & Sons, 1998.
- [MAR04] MARCONI, Marina de Andrade; LAKATOS, Eva Maria. *Metodologia científica*. 4. ed. São Paulo: Atlas, 2004.
- [MON03] MONTGOMERY, Douglas C.; RUNGER, George C. *Estatística aplicada e probabilidade para engenheiros*. 2. ed. Rio de Janeiro: LTC, 2003.

- [MOR81] MORETTIN, Pedro A.; TOLOI, Clélia M. *Modelos para previsão de séries temporais*. Rio de Janeiro: Impa, 1981.
- [MOR87a] MORETTIN, Pedro A.; TOLOI, Clélia M. *Séries temporais*. 2. ed. São Paulo: Atual, 1987.
- [MOR87b] MORETTIN, Pedro A.; TOLOI, Clélia M. *Previsão de séries temporais*. 2. ed. São Paulo: Atual, 1987.
- [MOR04] MORETTIN, Pedro A.; TOLOI, Clélia M. *Análise de séries temporais*. São Paulo: Edgard Blücher, 2004.
- [NAK96] NAKANO, D.; FLEURY, A. *Métodos de pesquisa em engenharia de produção*. In: ENCONTRO NACIONAL DE ENGENHARIA DE PRODUÇÃO, 16., Piracicaba, 1996. **Anais...** Piracicaba: UNIMEP, 1996.
- [NEV08] NEVES, Rogério Perino de Oliveira. *Introdução aos princípios conexionistas*. Disponível em: < <http://cognitio.incubadora.fapesp.br/portal/producao/> >. Acesso em: 1 julho 2005.
- [OLI02] OLIVEIRA, Gilson A. *Sistema de Controle de Estoques Utilizando a Metodologia Box & Jenkins de Series Temporais*. Dissertação de Mestrado em Métodos Numéricos em Engenharia – Universidade Federal do Paraná, Curitiba, 2002.
- [OLI03] OLIVEIRA, Mauri A.; FAVERO, Luiz P. *Uma breve descrição de algumas técnicas para análise de séries temporais: séries de Fourier, wavelets, Arima, modelos estruturais para séries de tempo e redes neurais*. São Paulo: USP, 2003. 13 p. Ensaio.
- [PAC03] PACHECO, Ricardo F.; SILVA, Alisson F. *Aplicação de modelos quantitativos de previsão em uma empresa de transporte ferroviário*. In: ENCONTRO NACIONAL DE ENGENHARIA DE PRODUÇÃO, 23., Ouro Preto, 2003. **Anais...** Ouro Preto: XXIII Encontro Nacional de Engenharia de Produção, 2003.

- [PEG69] PEGELS, C. C. *Exponential forecasting: some new variations*. Management Science, New York, v. 12, n. 5, p. 311-315, jan. 1969.
- [PEL00] PELLEGRINI, Fernando R.; FOGLIATTO, Flávio S. *Estudo comparativo entre os modelos de Winters e de Box-Jenkins para previsão de demanda sazonal*. Produto & Produção, Porto Alegre, v. 4, n. especial, p. 72-85, abr. 2000.
- [POL99] POLLOCK, D. S. G. *A handbook of time-series analysis, signal processing and dynamics*. London: Academic Press, 1999.
- [POP01] POPPER, Karl Raimund. *A lógica da pesquisa científica*. 9. ed. São Paulo: Cultrix, 2001.
- [POR91] PORTER, Michael E. *Estratégia competitiva: técnicas para análise de indústrias e da concorrência*. 5. ed. Rio de Janeiro: Campus, 1991.
- [ROC03] ROCHA, Fábio Guimarães. *Contribuição de Modelos de Séries Temporais para a Previsão da Arrecadação de ISS*. Dissertação de Mestrado em Economia – Instituto de Economia, Universidade Estadual de Campinas, Campinas, 2003.
- [SAN01] SANTOS, Cláudia Cristina dos. *Modelagem de bacias urbanas com redes neurais artificiais*. Dissertação de Mestrado em Engenharia – Escola Politécnica, Universidade de São Paulo, São Paulo, 2001.
- [SCH05] SCHWARTZ, Jay D.; RIVERA, Daniel E.; KEMFT, Karl G. *Towards control-relevant forecasting in supply chain management*. In: AMERICAN CONTROL CONFERENCE, 2005, Portland. **Proceedings...** Portland: American Control Conference, 2005, p.202-207.
- [SIL01] SILVA, Edna Lúcia da. *Metodologia da pesquisa e elaboração de dissertação*. 3. ed. rev. atual. Florianópolis: Laboratório de Ensino a Distância da UFSC, 2001.

- [SIL03] SILVA, C. S. *Previsão multivariada da demanda horária de água em sistemas urbanos de abastecimento*. Tese de Doutorado em Administração – Faculdade de Economia, Administração e Contabilidade, Universidade de São Paulo, São Paulo, 2003.
- [SIL02] SILVEIRA, Daniela M.; NICOLAU, André M. *O impacto da previsão de demanda nas operações de campo dos vendedores em empresas de venda direta*. ABEVD, Edição 2002, p. 01-23, 2002. Disponível em: < <http://www.abevd.org.br/htdoc> >. Acesso em: 14 julho 2006.
- [SIL00] SILVERMAN, D. *Doing qualitative research: a practical handbook*. London: Sage, 2000.
- [SIM00] SIMCHI-LEVI, D.; KAMINSKY, P.; SIMCHI-LEVI, E. *Designing and managing the supply chain: concepts, strategies and case studies*. Boston: McGraw-Hill, 2000.
- [SIM02] SIMCHI-LEVI, D.; SIMCHI-LEVI, L.; WATSON, M. *Tactical planning for reinventing the supply chain*. University of Cambridge; Massachusetts Institute of Technology, USA, 2002.
- [SIM03] SIMCHI-LEVI, David; KAMINSKY, Philip; SIMCHI-LEVI, Edith. *Cadeia de suprimentos: projeto e gestão*. Porto Alegre: Bookman, 2003.
- [SLA02] SLACK, Nigel; CHAMBERS, Stuart; JOHNSTON, Robert. *Administração da produção*. 2. ed. São Paulo: Atlas, 2002.
- [SOU05] SOUZA, Gueibi P. *Previsão do consumo industrial de energia elétrica no estado de Santa Catarina: uma aplicação da combinação de previsões entre modelos univariados e de regressão dinâmica*. Dissertação de Mestrado em Engenharia de Produção – Faculdade de Engenharia de Produção, Universidade Federal de Santa Catarina, Florianópolis, 2005.

- [TAY06] TAYLOR, J.; MENEZES, L.; MCSHARRY, P. *A comparison of univariate methods for forecasting electricity demand up to a day ahead*. Amsterdam: International Journal of Forecasting. v. 22, n. 2, p. 01-16, jan./mar. 2006.
- [THI98] THIOLLENT, M. *Metodologia da pesquisa-ação*. 8. ed. São Paulo: Cortez, 1998.
- [THI03] THIOLLENT, Michel. *Metodologia da pesquisa-ação*. 12. ed. São Paulo: Cortez, 2003.
- [TRA04] TRAUTWEIN JR., Breno. *Avaliação de métodos para previsão de consumo de água para curtíssimo prazo: um estudo de caso em empresa de saneamento*. Dissertação de Mestrado em Engenharia de Produção e Sistemas – Faculdade de Engenharia de Produção e Sistemas, Pontifícia Universidade Católica do Paraná, Curitiba, 2004.
- [TRA05] TRAUTWEIN JR., Breno; VIEIRA, Guilherme E. *Análise de modelos de ajuste exponencial para a previsão de consumo de curtíssimo prazo como apoio no planejamento da operação de um sistema de distribuição de água*. In: CONGRESSO BRASILEIRO DE ENGENHARIA SANITÁRIA E AMBIENTAL, 23., Campo Grande, 2005. **Anais...** Campo Grande: ABES, 2005.
- [UNI96] UNIVERSIDADE FEDERAL DO PARANÁ. Biblioteca Central. *Normas para apresentação de trabalhos: referências bibliográficas*. 6. ed. Curitiba, 1996, v.6.
- [WER03] WERNER, Liane; RIBEIRO, José L. *Previsão de demanda: uma aplicação dos modelos Box-Jenkins na área de assistência técnica de computadores pessoais*. Gestão & Produção, São Paulo, v. 10, n. 1, p. 47-67, abr. 2003.
- [YIN01] YIN, Robert K. *Estudo de caso: planejamento e métodos*. 2. ed. Porto Alegre: Bookman, 2001.

ANEXO A

Dados Históricos

Categoria 1 (Realizado)														
Período	Produtos													
	P1	P2	P3	P4	P5	P6	P7	P8	P9	P10	P11	P12	P13	P14
05/2004	30.278	39.341	80.326	60.282	23.261	47.681	33.354	82.256	23.200	33.789	40.735	39.136	5.783	33.091
06/2004	11.754	13.748	30.258	19.423	6.039	17.985	10.781	33.922	11.491	14.067	14.221	12.810	3.097	7.628
07/2004	11.107	16.734	32.151	18.751	5.508	18.419	11.312	42.010	13.837	11.047	14.108	12.151	3.585	6.682
08/2004	15.350	16.127	40.567	27.561	7.013	24.843	14.192	34.953	11.456	12.299	19.410	14.782	4.147	8.414
09/2004	17.225	22.822	56.299	34.405	9.475	29.269	19.131	46.581	13.841	11.751	24.988	19.608	4.583	10.567
10/2004	26.288	35.404	82.658	54.357	17.811	41.242	29.757	87.574	22.503	21.503	39.455	32.322	7.167	26.655
11/2004	45.833	59.492	133.127	91.358	40.349	66.925	50.111	173.751	42.183	45.886	57.446	66.696	13.598	62.324
12/2004	14.202	18.191	46.338	34.108	11.772	26.071	15.652	40.530	10.943	13.424	20.961	18.534	6.067	17.677
01/2005	9.562	10.364	31.656	26.159	6.527	17.529	10.415	15.843	6.369	8.581	15.113	9.980	4.733	6.126
02/2005	9.097	11.021	29.777	20.002	5.528	15.963	9.755	16.531	6.235	7.750	15.271	9.038	4.640	6.153
03/2005	16.181	18.575	51.934	36.357	7.876	26.651	17.805	28.671	9.329	10.865	25.561	13.926	6.538	8.808
04/2005	28.325	29.486	92.774	61.868	17.723	47.271	32.217	67.917	20.094	27.438	43.561	27.327	8.764	22.214
05/2005	21.111	20.608	71.381	46.231	17.422	37.382	20.944	67.104	19.358	13.262	35.019	20.512	5.344	14.775
06/2005	15.486	15.833	49.253	37.004	11.993	27.238	16.500	38.146	14.844	8.904	26.813	13.356	3.109	9.716
07/2005	12.884	15.324	36.827	29.604	8.252	22.420	13.405	31.121	7.582	7.042	20.016	12.170	2.692	6.635
08/2005	14.162	15.315	41.680	31.547	7.623	24.044	14.482	27.336	8.893	10.214	19.899	12.603	2.780	8.664
09/2005	18.447	16.176	49.943	37.257	8.471	26.434	17.801	34.847	9.860	10.508	23.672	16.033	3.288	8.946
10/2005	21.748	24.860	74.772	47.211	14.730	35.132	25.150	74.249	18.375	18.143	36.846	25.836	6.000	16.165
11/2005	45.136	56.959	132.027	101.959	37.600	66.247	50.922	156.827	38.501	44.262	65.036	61.029	13.770	57.536
12/2005	12.155	13.791	30.188	33.152	9.006	20.163	13.652	33.008	8.653	9.412	18.317	12.183	5.853	11.486
01/2006	6.522	5.990	18.676	18.006	4.339	8.946	7.902	19.146	4.626	5.576	10.192	5.545	2.933	3.972
02/2006	8.478	9.323	26.995	20.310	3.825	12.953	9.525	18.542	5.101	5.842	14.335	6.773	2.418	3.542
03/2006	12.525	11.081	39.996	25.445	6.726	18.314	13.687	28.394	7.757	7.186	20.220	10.899	2.697	5.960
04/2006	23.406	20.620	86.924	57.314	15.030	41.123	27.098	68.526	17.418	16.613	43.066	24.920	6.126	20.742
05/2006	19.250	16.949	69.371	45.527	16.936	35.906	20.829	72.634	19.324	17.380	33.384	21.829	5.736	19.235
06/2006	12.946	9.187	29.573	22.350	5.952	17.640	11.095	22.815	6.515	5.209	16.335	11.593	3.545	7.957
07/2006	15.022	14.759	39.544	28.821	6.458	24.007	13.853	33.358	9.072	6.765	22.610	14.917	4.314	8.403
08/2006	17.926	17.110	48.791	37.994	8.587	28.390	17.152	45.193	13.317	10.696	22.736	19.916	4.839	12.023
09/2006	15.288	13.679	43.782	31.377	8.299	24.993	15.219	41.084	15.050	8.481	24.193	18.829	3.931	10.045
10/2006	25.011	25.247	84.076	58.033	14.879	41.794	26.497	65.801	15.810	12.671	41.114	25.784	6.178	18.554
11/2006	45.189	50.420	141.307	109.773	32.099	72.025	50.048	139.504	28.180	30.147	65.745	51.678	13.600	53.432
12/2006	12.974	15.602	47.669	32.199	10.740	26.372	15.109	40.905	10.680	9.691	23.969	17.311	5.445	17.190
01/2007	10.029	10.767	41.425	17.952	8.426	16.505	9.162	36.711	8.958	8.512	18.313	12.680	3.261	14.101
02/2007	9.774	10.457	37.880	17.129	6.207	17.402	9.536	27.064	8.711	6.299	17.898	10.118	2.081	9.471
03/2007	14.832	15.566	45.998	32.842	8.712	26.170	16.206	56.073	12.339	8.969	28.919	15.070	3.530	13.566
04/2007	29.800	26.793	90.070	60.987	17.645	47.469	30.100	71.763	20.253	17.802	52.768	29.774	5.680	25.284
05/2007	23.081	23.291	73.341	49.856	16.149	38.122	23.842	59.938	16	14.456	38.229	23.144	4.693	23.847
06/2007	13.140	12.781	47.266	31.134	7.981	21.973	13.804	36.240	1718	9.757	27.720	13.313	2.037	12.440
07/2007	14	16.788	39.135	23.470	7.920	19.028	13.699	15.902	0	1.456	21.607	13.428	2.720	9.368

Categoria 1 (Previsão)														
Período	Produtos													
	P1	P2	P3	P4	P5	P6	P7	P8	P9	P10	P11	P12	P13	P14
05/2007	21.967	20.242	65.511	51.246	16.278	39.651	23.882	60.738	0	16.077	39.323	29.403	5.600	27.662
06/2007	13.548	12.187	40.587	30.410	7.526	20.318	13.562	40.385	0	7.377	22.051	14.970	3.081	13.389
07/2007	0	19.578	50.959	33.200	0	29.166	15.834	0	0	0	29.683	0	3.245	0

Categoria 1 (Realizado)														
Período	Produtos													
	P15	P16	P17	P18	P19	P20	P21	P22	P23	P24	P25	P26	P27	P28
05/2004	35.678	88.389	41.363	34.257	47.336	61.679	37.321	29.840	50.457	29.216	9.152	37.385	40.283	7.768
06/2004	10.704	42.572	12.341	10.993	14.944	22.718	15.382	8.720	21.209	6.653	5.371	23.676	18.671	4.766
07/2004	10.925	46.807	14.133	10.819	11.614	23.029	13.622	7.493	18.593	5.246	5.093	21.909	32.011	5.122
08/2004	12.809	47.526	12.743	13.770	11.139	30.005	17.879	9.946	23.411	6.419	5.468	20.626	17.283	6.338
09/2004	16.905	51.709	19.312	19.917	16.428	38.441	23.154	15.519	31.072	11.008	5.787	25.226	18.500	7.730
10/2004	27.863	70.745	37.378	31.375	31.548	58.085	32.907	25.887	48.579	19.807	8.896	36.883	32.990	10.499
11/2004	53.554	138.591	75.389	53.888	59.659	98.639	58.866	43.120	81.406	39.237	18.848	61.058	60.617	19.333
12/2004	17.565	40.726	20.434	16.887	14.468	31.291	20.631	15.439	30.555	12.186	7.285	21.031	22.703	7.197
01/2005	11.470	32.583	14.944	12.493	6.740	24.302	16.947	10.037	32.601	6.608	6.491	14.791	13.912	7.118
02/2005	10.852	32.653	12.368	10.420	7.225	21.990	13.172	10.199	24.459	5.837	4.139	16.126	13.097	5.175
03/2005	18.437	54.989	20.648	17.293	13.222	32.608	22.313	14.817	35.685	9.375	6.002	14.490	20.116	7.669
04/2005	35.158	76.861	38.589	31.160	29.607	60.179	35.855	29.169	50.072	19.816	10.365	33.602	36.084	10.667
05/2005	24.415	63.519	35.827	18.899	20.004	42.555	25.975	21.109	38.368	10.387	6.578	18.470	32.049	7.755
06/2005	15.271	45.291	19.880	14.083	14.060	29.952	20.249	19.456	22.466	6.091	4.436	9.143	23.358	4.701
07/2005	12.240	41.658	13.047	12.526	12.163	24.947	17.667	11.110	19.542	4.586	4.237	6.774	18.367	4.937
08/2005	14.086	44.525	14.426	12.404	12.892	26.063	19.260	11.614	21.330	8.554	4.481	9.333	16.956	5.282
09/2005	18.859	62.007	21.679	14.031	16.913	34.830	25.695	15.012	30.647	7.420	5.521	8.611	21.290	5.357
10/2005	27.635	75.814	36.675	23.286	28.040	49.842	30.468	22.760	43.093	12.553	8.340	19.601	30.007	6.827
11/2005	57.526	141.662	75.187	51.531	57.188	100.220	60.817	45.229	80.880	34.437	16.670	47.431	60.937	17.569
12/2005	15.882	39.380	19.735	11.948	14.642	23.999	16.892	12.247	33.495	12.773	8.008	9.910	16.499	6.829
01/2006	12.214	28.244	15.649	4.967	7.877	12.782	13.931	6.890	22.640	4.594	3.743	2.820	11.835	2.296
02/2006	11.850	26.232	10.869	6.726	9.083	16.034	13.625	8.143	17.009	4.272	3.221	3.815	13.677	2.437
03/2006	14.196	50.308	14.253	9.324	12.545	21.482	15.986	12.145	19.473	5.130	4.434	4.131	18.007	2.660
04/2006	29.256	71.659	34.900	24.188	24.245	45.265	30.494	25.583	38.348	11.788	7.727	15.585	31.084	8.316
05/2006	21.494	60.298	26.184	14.656	19.225	41.903	26.341	20.449	30.196	7.901	7.781	12.363	30.893	6.440
06/2006	7.757	27.575	12.643	6.879	11.071	14.278	11.968	11.065	16.041	3.628	4.852	4.810	15.035	4.203
07/2006	8.930	32.170	18.621	8.851	12.917	18.754	14.821	14.791	17.555	4.219	5.926	7.251	21.348	5.886
08/2006	14.648	44.849	21.700	14.047	17.598	28.636	20.422	18.448	25.588	6.947	6.257	11.070	27.771	6.686
09/2006	11.571	34.403	19.490	10.811	15.021	20.826	16.174	16.369	18.175	5.779	5.703	8.643	26.097	6.389
10/2006	24.499	67.558	33.156	20.315	17.836	37.921	31.984	27.591	42.090	9.941	8.986	15.172	34.827	8.396
11/2006	56.893	131.782	78.476	45.993	45.023	88.787	60.764	45.447	83.355	20.407	16.992	26.232	61.296	16.572
12/2006	14.914	30.151	20.681	11.683	14.808	28.451	18.001	16.472	24.801	7.951	6.094	9.136	23.337	6.075
01/2007	7.270	21.014	13.342	4.694	11.021	14.193	11.852	11.078	16.591	4.289	3.827	5.479	16.137	3.777
02/2007	6.456	14.912	9.266	5.515	10.604	12.659	10.606	10.757	12.366	3.944	2.783	5.592	16.437	2.185
03/2007	12.225	53.267	14.948	10.149	13.456	21.022	18.196	16.724	22.039	5.608	4.999	7.955	24.147	3.880
04/2007	30.066	72.357	35.154	20.083	24.895	43.681	35.839	32.787	39.512	13.451	7.539	17.492	36.360	7.148
05/2007	22.665	46.000	26.140	14.929	20.771	36.842	24.629	25.269	32.807	9.307	6.812	15.001	31.547	5.743
06/2007	11.824	28.819	13.578	9.426	12.372	24.826	15.549	17.079	16.936	5.474	2.932	9.712	23.000	2.262
07/2007	11.124	32.062	11.389	11.967	14.289	22.243	3.140	13.674	14.671	3.485	4.203	7.177	21.770	2.738

Categoria 1 (Previsão)														
Período	Produtos													
	P15	P16	P17	P18	P19	P20	P21	P22	P23	P24	P25	P26	P27	P28
05/2007	23.812	50.841	31.084	14.374	23.942	35.330	26.029	24.053	32.027	15.443	6.790	11.027	34.458	6.667
06/2007	11.373	25.806	14.181	12.309	13.455	16.324	13.818	20.012	21.548	6.558	4.217	5.968	19.757	4.043
07/2007	0	0	0	14.546	15.132	19.788	0	15.337	19.231	3.950	5.359	6.363	26.126	4.693

Categoria 2 (Realizado)																
Período	Produtos															
	P1	P2	P3	P4	P5	P6	P7	P8	P9	P10	P11	P12	P13	P14	P15	P16
05/2004	42.897	55.706	23.304	55.151	34.336	68.277	30.272	9.124	39.799	29.230	22.027	33.818	37.001	9.903	61.264	45.680
06/2004	30.926	36.245	19.864	50.485	21.496	43.171	21.018	4.870	23.817	23.289	13.241	25.386	33.961	5.530	43.084	29.134
07/2004	42.473	54.625	36.216	54.569	36.961	60.006	28.099	7.927	44.590	38.481	22.630	32.252	39.936	11.400	60.176	47.847
08/2004	34.794	35.287	21.231	39.237	26.251	35.546	18.446	4.281	29.352	19.590	13.424	25.029	28.908	7.655	46.629	32.885
09/2004	36.247	41.651	22.591	45.067	28.289	42.977	19.799	5.153	30.742	19.824	16.181	27.292	30.333	7.174	49.133	37.418
10/2004	48.362	55.675	31.441	61.202	40.797	63.269	28.369	8.321	45.555	28.931	23.151	36.454	37.748	9.941	65.385	48.903
11/2004	85.491	102.163	60.009	122.732	86.654	111.170	53.761	15.281	96.716	53.748	44.834	63.534	67.272	19.389	115.347	98.524
12/2004	23.038	26.207	17.095	36.013	18.504	29.833	14.427	5.182	24.441	13.934	10.244	19.924	20.553	4.973	34.392	23.885
01/2005	19.244	15.735	11.002	22.918	10.197	18.201	8.862	2.626	11.866	9.846	6.028	17.221	15.729	1.689	28.368	14.634
02/2005	28.679	22.409	12.788	26.642	22.675	19.881	10.956	3.549	22.030	10.556	13.422	21.276	18.127	3.499	32.956	30.775
03/2005	28.154	29.391	16.290	38.579	27.098	35.019	15.381	4.335	27.035	15.562	16.775	23.943	24.309	2.066	38.446	39.560
04/2005	28.167	46.356	23.896	61.023	17.469	49.394	22.862	8.696	24.729	20.514	13.155	31.657	28.384	5.023	55.067	33.820
05/2005	33.209	47.714	25.797	53.074	19.831	53.947	23.693	8.537	29.692	28.022	13.511	33.854	31.947	5.755	57.390	39.661
06/2005	24.431	40.408	23.628	45.465	19.242	43.911	20.939	5.509	21.187	25.060	10.737	27.320	24.755	5.699	53.377	31.068
07/2005	31.387	51.314	27.704	60.714	23.473	51.854	21.759	4.635	29.538	18.326	13.675	33.806	26.431	5.683	48.064	39.919
08/2005	27.595	39.982	19.945	57.132	22.603	39.718	18.285	3.976	32.334	13.737	12.556	29.055	27.221	6.205	42.764	31.493
09/2005	26.614	36.795	18.245	47.526	22.440	38.649	18.148	2.985	26.583	14.867	13.229	29.077	22.952	5.650	46.390	33.350
10/2005	39.644	51.663	27.865	63.646	33.338	55.761	25.522	6.118	40.136	23.266	19.016	35.908	30.078	8.671	62.354	44.957
11/2005	79.283	101.735	58.439	120.495	79.211	111.896	52.548	14.392	90.138	49.505	42.249	65.126	61.118	21.464	120.221	96.109
12/2005	18.335	21.881	12.640	27.193	18.276	28.622	13.467	3.443	18.570	11.306	10.741	18.800	17.601	5.646	32.346	24.526
01/2006	6.728	12.080	5.493	14.531	11.548	15.278	8.008	1.244	6.875	5.860	5.339	9.919	7.274	2.065	20.479	14.619
02/2006	10.704	17.024	7.752	16.619	10.631	19.260	10.435	1.711	9.147	7.474	6.699	13.671	11.797	2.847	26.909	17.221
03/2006	15.741	21.634	10.318	22.862	15.488	25.949	14.211	2.155	12.654	11.594	7.821	21.239	16.761	4.203	35.632	23.537
04/2006	21.535	32.578	15.557	33.264	18.732	35.269	21.881	3.627	17.549	15.296	10.708	28.551	22.113	5.946	45.896	27.505
05/2006	25.822	43.791	23.994	46.575	22.316	48.943	23.952	5.686	24.164	22.235	15.057	32.293	27.514	6.214	55.306	37.117
06/2006	22.315	28.409	15.591	30.751	13.402	29.040	15.994	2.262	15.116	17.452	9.744	24.636	21.051	4.043	39.202	24.551
07/2006	24.992	39.057	18.884	43.780	24.055	41.635	20.491	3.660	25.022	20.845	11.364	28.848	25.571	5.365	46.124	34.581
08/2006	32.145	33.464	18.718	48.885	26.339	39.342	18.924	4.078	26.722	21.037	13.619	34.254	30.470	6.761	51.015	34.526
09/2006	20.378	24.094	11.977	25.912	19.438	29.378	15.522	2.247	15.199	20.063	7.148	23.781	20.406	4.422	38.881	25.377
10/2006	34.104	47.366	23.296	50.857	30.420	51.184	28.128	4.436	27.395	22.471	13.311	38.011	32.370	7.250	73.017	41.015
11/2006	68.246	86.928	47.520	106.790	68.404	91.620	49.832	9.692	67.554	42.695	34.175	67.562	60.736	14.483	106.972	87.201
12/2006	22.968	32.252	18.161	36.289	20.177	34.371	18.423	4.064	21.692	15.354	11.278	22.665	19.429	5.451	47.987	26.712
01/2007	14.128	14.646	9.809	18.102	13.841	14.116	9.469	1.649	10.416	9.642	4.295	17.768	13.277	2.316	21.412	12.971
02/2007	14.975	18.293	10.721	21.040	12.938	19.830	11.128	1.822	10.096	9.820	5.489	20.421	15.837	2.681	22.721	15.047
03/2007	21.862	28.937	16.568	31.847	16.888	33.071	18.828	2.778	15.137	15.856	7.258	27.696	22.803	4.353	32.113	24.892
04/2007	30.118	42.301	23.383	46.208	17.125	51.086	26.691	3.994	19.091	20.164	12.359	34.034	26.960	6.729	52.942	35.589
05/2007	30.327	35.659	29.108	45.495	19.841	51.959	23.148	2.105	19021	23	12.611	32.254	29.442	5.045	57.357	33.300
06/2007	22.301	20.683	19.773	41.001	15.852	41.239	22.733	3.790	17314	0	10.282	25.567	23.112	5.371	42.324	25.128
07/2007	7226	41.617	24.962	57.665	13.015	50.003	27.754	4.239	11785	0	2.047	35.181	33.175	7.565	51.652	2.709

Categoria 2 (Previsão)																
Período	Produtos															
	P1	P2	P3	P4	P5	P6	P7	P8	P9	P10	P11	P12	P13	P14	P15	P16
05/2007	36.730	44.091	30.115	49.497	24.231	51.362	27.104	6.084	22.724	0	10.108	34.004	31.341	4.982	56.171	0
06/2007	22.101	31.009	22.813	31.798	7.509	32.225	17.695	2.309	11.717	0	4.453	26.759	23.288	4.280	43.066	33.733
07/2007	0	48.195	28.981	54.658	0	52.268	22.545	3.528	0	0	0	38.932	30.545	8.912	52.958	20.887

Livros Grátis

(<http://www.livrosgratis.com.br>)

Milhares de Livros para Download:

[Baixar livros de Administração](#)

[Baixar livros de Agronomia](#)

[Baixar livros de Arquitetura](#)

[Baixar livros de Artes](#)

[Baixar livros de Astronomia](#)

[Baixar livros de Biologia Geral](#)

[Baixar livros de Ciência da Computação](#)

[Baixar livros de Ciência da Informação](#)

[Baixar livros de Ciência Política](#)

[Baixar livros de Ciências da Saúde](#)

[Baixar livros de Comunicação](#)

[Baixar livros do Conselho Nacional de Educação - CNE](#)

[Baixar livros de Defesa civil](#)

[Baixar livros de Direito](#)

[Baixar livros de Direitos humanos](#)

[Baixar livros de Economia](#)

[Baixar livros de Economia Doméstica](#)

[Baixar livros de Educação](#)

[Baixar livros de Educação - Trânsito](#)

[Baixar livros de Educação Física](#)

[Baixar livros de Engenharia Aeroespacial](#)

[Baixar livros de Farmácia](#)

[Baixar livros de Filosofia](#)

[Baixar livros de Física](#)

[Baixar livros de Geociências](#)

[Baixar livros de Geografia](#)

[Baixar livros de História](#)

[Baixar livros de Línguas](#)

[Baixar livros de Literatura](#)
[Baixar livros de Literatura de Cordel](#)
[Baixar livros de Literatura Infantil](#)
[Baixar livros de Matemática](#)
[Baixar livros de Medicina](#)
[Baixar livros de Medicina Veterinária](#)
[Baixar livros de Meio Ambiente](#)
[Baixar livros de Meteorologia](#)
[Baixar Monografias e TCC](#)
[Baixar livros Multidisciplinar](#)
[Baixar livros de Música](#)
[Baixar livros de Psicologia](#)
[Baixar livros de Química](#)
[Baixar livros de Saúde Coletiva](#)
[Baixar livros de Serviço Social](#)
[Baixar livros de Sociologia](#)
[Baixar livros de Teologia](#)
[Baixar livros de Trabalho](#)
[Baixar livros de Turismo](#)