



Douglas Diniz Landim

ANÁLISE DE DEMANDA VIA INTELIGÊNCIA ARTIFICIAL NO RESTAURANTE UNIVERSITÁRIO DO INSTITUTO CENTRAL DE TECNOLOGIA DA UNIFESP

São José dos Campos, SP

Douglas Diniz Landim

ANÁLISE DE DEMANDA VIA INTELIGÊNCIA ARTIFICIAL NO RESTAURANTE UNIVERSITÁRIO DO INSTITUTO CENTRAL DE TECNOLOGIA DA UNIFESP

Trabalho de conclusão de curso apresentado ao
Instituto de Ciência e Tecnologia – UNIFESP,
como parte das atividades para obtenção do tí-
tulo de Bacharel em Ciência da Computação.

Universidade Federal de São Paulo – UNIFESP

Instituto de Ciência e Tecnologia

Bacharelado em Ciência da Computação

Orientador: Prof. Dr. Vinicius Veloso

São José dos Campos, SP

Março de 2018

Douglas Diniz Landim

ANÁLISE DE DEMANDA VIA INTELIGÊNCIA ARTIFICIAL NO RESTAURANTE UNIVERSITÁRIO DO INSTITUTO CENTRAL DE TECNOLOGIA DA UNIFESP

Trabalho de conclusão de curso apresentado ao
Instituto de Ciência e Tecnologia – UNIFESP,
como parte das atividades para obtenção do tí-
tulo de Bacharel em Ciência da Computação.

Trabalho para apresentar em NOVEMBRO/2018:

Prof. Dr. Vinicius Veloso
Orientador

Professor
Convidado 1

Professor
Convidado 2

Professor
Convidado 3

São José dos Campos, SP
Março de 2018

Este trabalho é dedicado aos meus pais que apoiaram e sacrificaram esforços para me manter ativo nessa jornada, a todos os professores que me somaram conhecimentos, oportunidades e esperanças indo além de suas rotinas e agendas em prol do ensino, e principalmente à todos que me motivaram me oferecendo desafios para que eu pudesse enfrentá-los superando meus próprios limites

Agradecimentos

Minha jornada pela graduação foi marcada por muita persistência, dificuldades e fracassos. Agradeço primeiramente a Deus por me dar fé e alimentar minha persistência e esperança. Apesar de todo o conteúdo técnico das mais de 40 disciplinas do meu curso, o que mais me agregou evolução foi o ambiente extremamente desafiador desta universidade; que somado à muitas dificuldades pessoais, acidentes, contra-tempos de saúde, profissão e família; constituiu a soma perfeita de desafios que me derrubaram muitas e muitas vezes e me fizeram ser uma pessoa melhor, mais convicta e mais perseverante a cada nova tentativa de conquistar minhas aprovações. Agradeço à minha família por sempre me apoiar dando tudo de si, a meu professor por me aceitar orientar, e me motivar sempre me dando atenção como um amigo nas conversas no fim da aula durante o caminho até o estacionamento da faculdade, nas reuniões e chats online até nos finais de semana, aos amigos universitários, e a todos os professores que me acompanharam e ofereceram desafios em todos esses anos na UNIFESP.

*Mesmo desacreditado e ignorado por todos, não posso desistir, pois para mim, vencer é nunca
desistir.*
(Albert Einstein)

Resumo

O presente trabalho tem como objetivo a comparação com o método de análise da previsão de vendas do restaurante universitário da Unifesp, previamente feita pelo autor deste projeto com aplicação de métodos estatísticos, e atualmente com métodos de aprendizado de máquina. Tal análise por aprendizado de máquina foi apontado como relevante solução no fim da análise estatística do trabalho anterior. A temperatura da região onde se localiza o campus do restaurante foi analisada por recorrência via bootstrap como um fator que exerce impacto sobre as vendas do restaurante em certos períodos do semestre, e neste trabalho de conclusão de curso serão obtidas novas variáveis e um intervalo maior de amostragem na análise da previsão de demanda de refeições do restaurante em um novo modelo com aprendizado de máquina a fim de que seja obtido um modelo de previsão viável para evitar super-projeção de demanda com consequência de desperdício de alimentos, ou subprojeção com consequência de docentes ou discentes sem refeições.

Palavras-chaves: Redes Neurais Artificiais. Previsão de demanda. Aprendizado de Máquina. Inteligência Artificial. Perceptron Múltiplas camadas.

Abstract

The present work has the objective of comparison with the static method of analysis of the demand prediction in UNIFESP university restaurant, previously done by the author of this project, and currently with machine learning methods. Such analysis by machine learning was pointed out as a relevant solution at the end of the statistical analysis of the previous work. The temperature of the region where the restaurant campus is located was analyzed by bootstrap recurrence as a factor impacting the restaurant sales in certain periods of the semester, and in this work of completion of the course will be obtained new variables and a greater range of sampling in the analysis of the forecast of restaurant meal demand in a new model with machine learning in order to obtain a viable prediction model to avoid overprojection of demand as a result of food waste or subprojection with the consequence of teachers or students without meals.

Key-words: Artificial Neural Networks. Demand Prediction. Machine Learning. Artificial intelligence. Perceptron Multiple layers.

Lista de ilustrações

Figura 1 – Tipos de métodos quantitativos Retirado de (JUNIOR, 2007).	30
Figura 2 – Métodos de previsão de demanda (JUNIOR, 2007).	31
Figura 3 – DADOS DE DEMANDA DE SAZONALIDADE DIÁRIA, EM FUNÇÃO DO HORÁRIO. Retirado de (RUAS, 2012).	32
Figura 4 – Entradas de dia da semana em cofatores. Retirado de (LOPES, 2008).	34
Figura 5 – Neuronio Biológico, retirado de https://pt.khanacademy.org/science/biology/human-biology/neuron-nervous-system/v/anatomy-of-a-neuron	38
Figura 6 – Neuronio Artificial	39
Figura 7 – Neuronio Artificial - Operação AND	39
Figura 8 – Neuronio Artificial Perceptron	41
Figura 9 – Funções de Ativação retirado de (MARIANO, 2014)	41
Figura 10 – Rede Neural Perceptron de Múltiplas Camadas. Retirado de (LOPES, 2008).	43
Figura 11 – Rede Neural Perceptron de Múltiplas Camadas. Retirado de (ROCHA JOSÉ CELSON; MATOS, 2011)	43

Lista de tabelas

Tabela 1 – Tabela de dados para regressão múltipla.	35
Tabela 2 – Operação Lógica AND	39
Tabela 3 – Plano de atividades para o TCC II	47

Lista de abreviaturas e siglas

ICT	Instituto Central de Tecnologia
R.U	Restaurante Universitário
UNIFESP	Universidade Federal de São Paulo
BDMEP	Banco de Dados Meteorológicos para Ensino e Pesquisa

Sumário

1	Introdução	21
1.1	Contextualização e Motivação	21
1.2	Definição do problema	22
1.3	Justificativas	22
1.4	Objetivos	22
1.4.1	Objetivo geral	22
1.4.2	Objetivos específicos	23
1.5	Metodologia	23
1.6	Organização do documento	24
2	Fundamentação Teórica	25
2.1	Introdução	25
2.2	Dados	26
2.2.1	Dados de Consumo e de Data.	26
2.2.2	Dados Climáticos	28
2.3	Análises Estatísticas	29
2.3.1	Análise Exploratória dos Dados	29
2.3.2	Métodos de Previsão	29
2.3.3	Métodos de previsão de Demanda	30
2.3.4	Meta-análise	30
2.3.5	Séries Temporais	31
2.3.6	Componentes Temporais	32
2.3.7	Previsão com Regressão Linear Múltipla	32
2.3.8	N CONCLUIDO - Algoritmo de Regressão Linear Multipla	36
2.4	Inteligencia Artificial	37
2.4.1	Neuronio Artificial	37
2.4.2	Redes Neurais Artificiais	40
2.4.3	Previsão de demanda de R.U com rede perceptron múltiplas camadas com back-propagation	42
3	Trabalhos relacionados	45
4	Plano de atividades para o TCC II	47
5	Conclusão	49
	Referências	51

1 Introdução

1.1 Contextualização e Motivação

A previsão de demanda é um ponto de extrema importância para qualquer empresa, uma previsão adequada permite o ajuste de todo o seu mecanismo de operações para atender tal demanda com a melhor eficiência possível, maximizando lucros, minimizando perdas, e principalmente atendendo todas as necessidades do cliente.

Todo restaurante universitário enfrenta problemas de previsão de demanda de refeições e prejuízos com a falta de vendas e ou o descarte de refeições não vendidas. Um dos grandes problemas enfrentados hoje no mundo é a elevação dos preços dos alimentos, o valor além de monetário é moral, a alimentação é o recurso primitivo de base da humanidade que hoje ainda enfrenta um mal acesso a este em muitas regiões carentes. O descarte indevido de alimentos, provocado por suas limitações e durabilidade não gera somente prejuízos monetários e sim prejuízos ambientais e morais. Isso tem causado preocupações para a população em geral e também para empresas como restaurantes que sofrem diretamente os reflexos da variação no preço dos alimentos e na demanda. Atualmente o restaurante universitário do ICT - UNIFESP não possui um sistema que ajude na gestão de compras dos alimentos.

No restaurante universitário do ICT UNIFESP as refeições são fornecidas de segunda a sexta feira. O caso particular de restaurantes universitários envolve um fluxo de demanda influenciado por dia da semana, visto que a demanda é influenciada pela quantia de alunos presentes na universidade, que por sua vez é influenciada pela grade de aulas determinada semestralmente por dia da semana. O caso de análise para este projeto foi motivado após informações de relevantes desperdícios.

Devido às condições burocráticas no ambiente do restaurante que compreendem fidelidade de contrato, exclusividade na região pois o restaurante se encontra em localização que o faça ser o único provedor de alimentos ao público do campus estando isolado fisicamente de qualquer região comercial, e acessibilidade do público à aquisição de refeições que em sua maior parte adquirem refeições pelo valor de 2,50 sendo o restante do custo da refeição subsidiada pela instituição através de verbas federais, a escolha dos parâmetros não será influenciada por muitos fatores externos como concorrência, acessibilidade do ponto, entre outros.

Outro ponto importante é a obtenção dos valores de venda; não foram escolhidas as vendas diretas do ponto de venda de tickets de refeição, e sim os dados de coleta da entrada do

restaurante, que demonstram a real movimentação de público no restaurante em determinado dia.

O estudo da relação de vendas, temperatura, outras variáveis climáticas e do ambiente, já é comum em outros cenários, entre eles o de maior destaque é na demanda de energia elétrica. Os cenários de vendas de alimentos perecíveis ganha também destaque apesar de se encontrar investimentos maiores na indústria de produção de energia elétrica. O objetivo tanto no cenário deste trabalho, o restaurante universitário, como em outros cenários é o mesmo, atender toda a demanda de consumo e evitar transtorno à qualquer consumidor pela falta da mesma, e evitar prejuízos de produção não consumida. Tais prejuízos impactam não só ao fornecedor, mas também ao consumidor, um fornecimento de produto e serviço com um bom planejamento de demanda, poupa recursos ao produtor que podem ser investidos em melhor qualidade de produto, e menor preço ao consumidor a fim de que seja obtido um modelo de previsão viável para evitar sobrestimação de demanda com consequência de desperdício de alimentos, ou subestimação com consequência de docentes ou discentes sem refeições.

Tal problema tem sido impactante e frequente para o restaurante que informa que em alguns dias no mês passa por sobrestimação e desperdício superior a 100 refeições.

1.2 Definição do problema

O problema a definir neste trabalho é encontrar um modelo de previsão de demanda através de algoritmos de regressão por aprendizado de máquina.

1.3 Justificativas

As atuais abordagens de previsão do restaurante universitário, que envolvem média aritmética simples e dedução subjetiva são falhos por não serem calculados tendo uma visão ampla de todo um histórico de dados de grande amostragem, e também não cruzam informações diversas como dados climáticos, dados de calendário anual, feriados próximos, entre outros.

1.4 Objetivos

1.4.1 Objetivo geral

Construir um modelo utilizando uma Rede Neural Artificial para a previsão da demanda de refeições do restaurante universitário do ICT-UNIFESP com menos de 10% de erro.

1.4.2 Objetivos específicos

- Construir modelos utilizando três algoritmos de regressão;
- Realizar análise estatística da qualidade dos modelos;

1.5 Metodologia

Análise de regressão Por se tratar de um trabalho de previsão de demanda, este trabalho irá realizar a coleta e tratamento dos dados de consumo do restaurante universitário da Unifesp, a coleta de dados climáticos que influenciam em tal demanda, calcular os dados de calendário derivados das datas de coleta, como por exemplo obter o dia da semana de acordo com a data, estação do ano, número do semestre (se par ou ímpar), entre outros.

Após a estruturação dos dados é realizado uma análise exploratória fundamentada por (JUNIOR, 2007) no capítulo 3.3, para previsões de demanda em geral. O modelo de dados de venda estruturados receberá o acréscimo de dados de variáveis climáticas, como possíveis fatores de influencia no consumo, conforme ocorre no trabalho de previsão de demanda de energia elétrica fundamentado por (ALMEIDA, 2013) (??) e (SILVA, 2010)

Os trabalhos de (JUNIOR, 2007) e (SILVA, 2010) fundamentam também uma classificação de análises dos dados estruturados indicando os métodos de previsão de demanda para este modelo quantitativo que são a Regressão Linear Múltipla e Redes Neurais por Inteligência Artificial.

O trabalho se inicia com sua primeira análise estatística de regressão linear múltipla fundamentadas por (CLARICE G.B. DEMÉTRIO; ZOCCHI, 2011) para se obter um modelo de previsão de demanda do R.U do ICT-UNIFESP.

Estudo de Aprendizado de máquina As análises de inteligência artificial, fundamentadas por trabalhos de previsão de demanda em R.U na Universidade Federal de Viçosa, de acordo (LOPES, 2008) e na Universidade Estadual Paulista Júlio de Mesquita por (ROCHA JOSÉ CELSO; MATOS, 2011), concluem a segunda aplicação da técnica de redes neurais artificiais com o método de perceptron de múltiplas de backpropagation fundamentado em (HAYKIN, 1994), incrementando-se na técnica a inclusão de variáveis climáticas utilizadas nos trabalhos de previsão de (ALMEIDA, 2013) (??) e (SILVA, 2010), modificando a topologia vista em (LOPES, 2008) para receber tais dados.

Após a modificação da topologia, os dados serão estruturados com a retirada de amostras aleatórias de validação, e será realizado um comitê de 3 redes neurais, usando a média aritmética como combinador estimador.

Meta-análise De acordo com ([MARIANO, 2014](#)) que realiza um trabalho de previsão de consumo em aves, a técnica de meta-análise, a análise das análises, será ideal para a comparação e discussão dos resultados, com medidas de avaliação de erro absoluto médio (EAM), erro quadrado médio (EQM) e raiz do erro quadrado médio (REQM). Usando a verificação estatística das diferenças nas medidas obtidas com as técnicas por meio do teste de hipótese de Wilcoxon Rank Sum.

1.6 Organização do documento

Este trabalho está organizado da seguinte forma: o capítulo 2 apresenta os conceitos básicos para o entendimento do trabalho. O capítulo 3 apresenta trabalhos relacionados. O capítulo 4 demonstra o plano de atividades para o TCC II. O capítulo 5 conclui este trabalho.

2 Fundamentação Teórica

2.1 Introdução

A previsão da demanda é o fator principal da eficiência de qualquer modelo de processamento do tipo entrada-saída, onde a sua saída deve atender uma demanda não determinística. É necessário prever a demanda para projetar e aperfeiçoar o processamento e a entrada deste modelo.

O modelo a ser analisado neste trabalho é o comportamento dos consumidores de um restaurante universitário, onde o mesmo precisa projetar sua compra de insumos e alocação de recursos na entrada de seu modelo de negócio, e projetar sua saída, que é a produção de refeições em quantidade numérica e inteira distribuída em função do tempo em dias, para atender um consumo feito por alunos, que não se comporta de maneira determinística, já que este consumo é facultativo aos alunos.

De acordo com o contrato presente entre o restaurante e a universidade, o mesmo deve atender totalmente à demanda do público, sendo multado se caso algum consumidor fique sem alimentação, porém este mesmo contrato não trata refeições que não são consumidas, logo o restaurante deve lidar integralmente o prejuízo de refeições produzidas acima da demanda de consumo.

Tais refeições fornecidas à alunos também são em parte subsidiadas pela universidade. O período que se compreende à agosto de 2018 segue um modelo de contrato antigo no qual o restaurante recebe R\$2,50 do aluno e R\$9,14 da universidade compreendendo o total de R\$11,64 por refeição.

De agosto em diante, iniciando no segundo semestre de 2018, a universidade subsidia R\$5,44 da refeição do aluno e o mesmo R\$2,50, o restaurante recebe o total de R\$7,94. Logo esta previsão de demanda corresponde também aos interesses da administração do campus local, que periodicamente deve realizar uma alocação de recursos financeiros para subsidiar todas estas refeições consumidas.

É necessário então entender e descobrir quais elementos influenciam este consumo humano, de que forma estes elementos exercem tal influência e em qual intensidade ela ocorre.

E para explorar tais elementos, é necessário explorar como este consumo ocorreu historicamente a fim de se encontrar padrões de comportamento, que no cenário deste trabalho acontece com informações distribuídas através do tempo.

Neste capítulo o principal objetivo é definir todos os conceitos que serão necessários para o entendimento total deste trabalho, analisando a forma que os dados são entendidos, e as

ferramentas com os quais possam ser trabalhados.

2.2 Dados

Abstraindo o histórico de vendas do restaurante, temos 2 tipos de dados principais. A venda podendo ser uma observação Y , e a data da venda sendo uma observação X . Se comportando de modo que a função de X implica em Y .

$$X, Y \rightarrow Y \simeq f(X)$$

A observação principal a ser analisada neste trabalho é o numero de vendas do R.U do ICT - UNIFESP, em valor inteiro, obtido de um dia letivo, em um determinado período sendo este o almoço ou jantar.

O tempo, onde a informação principal se distribui, é em formato de data, e contém apenas 1 valor da venda total de almoços nesta data, e da venda total de jantas nesta data.

2.2.1 Dados de Consumo e de Data.

Os dados históricos de consumo no restaurante foram retirados do atual sistema banco de dados de refeições subsidiadas do Hospital São Paulo, que gerencia os dados dos refeitórios de todas as unidades da Unifesp. É importante ressaltar que tais dados são apenas de funcionários, docentes e discentes da instituição. Eventuais compras de refeições realizadas por visitantes que não possuem vínculo com a instituição não são registradas pelo sistema.

Outro fato importante é que estes dados registrados no banco, são registrados no momento em que a refeição é realizada, pelos terminal da entrada do refeitório e não no momento que é vendida pelo caixa do refeitório. Caso fossem registrados no momento da venda no caixa, a análise estatística do consumo poderia sofrer um viés errôneo em relação à frequência de pessoas no refeitório.

Os alunos são os que realizam o maior volume de consumo, e são os que tem um padrão de frequência à universidade de modo estocástico, que tende a ter uma sazonalidade anual de frequência na universidade desde 2017, quando a instituição padronizou a grade horária de disciplinas. Além de ser o objetivo principal da previsão por serem os únicos que têm as refeições subsidiadas, pagando um custo de apenas R\$2,50 por refeição, onde entende-se que este custo pode ter mais forte influência na decisão do aluno realizar uma refeição em comparação à outro discente ou pessoa com vínculo na instituição. Por isso os dados que serão analisados neste trabalho, serão somente da frequência de alunos, e terão como início o ano de 2017.

Apenas alguns funcionários autorizados tem acesso ao banco de dados do sistema de refeições da instituição, entre eles o fiscal de contrato do restaurante universitário. Para obter tais dados neste trabalho, foi necessário obter uma autorização com a direção do campus ICT - UNIFESP e em seguida solicitar a exportação dos dados ao fiscal. Os parâmetros dos quais o

mesmo consegue realizar a exportação de dados são diversos, porém foi solicitado o formato de valores separados por vírgula que compreendem o ano de 2017 a 2018.

O modelo exportado segue o seguinte da seguinte forma abaixo, contendo o exemplo de

1	"CONSULTA POR PERÍODO " ,,,,,,, "CAMPUS: SÃO JOSÉ DOS CAMPOS " ,,, "RU: TODOS " ,,, "VINCULO: ALUNO " ,,, "PERÍODO DE: 01/01/2017 A 31/10/2018 " ,,,
2 datas:	DATA,VENDAS CAFÉ,VENDAS ALMOÇO,VENDAS JANTAR,VENDAS REFEIÇÃO*,TOTAL VENDAS,ENTR. CAFÉ,ENTR. ALMOÇO,ENTR. JANTAR,TOTAL ENTR. REFEIÇÃO*,TOTAL ENTRADA
	(31/10/2018),0,395,0,395,395,0,362,0,362,362
	(30/10/2018),0,667,0,667,667,0,437,256,693,693

Logo, no exemplo da segunda linha deste modelo de dados, serão analisados o primeiro valor "(30/10/2018)" como a primeira variável de entrada que corresponde à data, o oitavo valor "437" que corresponde à variável de saída do total de almoço, e ao nono valor "256" que corresponde à variável de saída do total de janta.

Em todo os bancos de dados gerenciados pelo setor de tecnologia da informação da Unifesp, do campus ICT, o mesmo informou que foi constam 428620 refeições subsidiadas no banco de dados do sistema antigo, no período de 2011 à 2016, e 111454 refeições no período de 2017 a 01/08/2018 que fecham o modelo de contrato antigo. O calculo do custos médios cobrados pelo restaurante de R\$9,14 e R\$2,50 pelo aluno, estima que ambos gastaram respectivamente R\$4.936.276,36 e R\$1.350.185,00 enquanto os restaurantes que estiverem em contrato nesse período com a universidade, tiveram um faturamento bruto acumulado de R\$6286461,36

Já neste atual 2º semestre de 2018, iniciando em 01/08/2018 à 31/10/2018, o valor total subsidiado pela universidade é de R\$179019,52, R\$82270,00 pelos alunos e o faturamento bruto acumulado pelo restaurante é de R\$261289,52

É importante observar que na implementação computacional das análises de predição, o campo de data é utilizado para o controle da informação e união dos registros climáticos e de consumo, além ser utilizado para obtenção de dados derivados do tempo como o dia da semana, o período do semestre e a estação do ano. Já os campos de número total de refeições consumidas, devem constar como formatos quantitativos nas estruturas de dados dos algoritmos a serem implementados.

Informações derivadas da data não necessitam de coleta, como por exemplo dia da semana, pois podem ser obtidas por métodos de cálculos, sabendo-se apenas um dia da semana correspondente à um dia do ano, ou utilizando bibliotecas computacionais, no caso a biblioteca `datetime` para a linguagem python.

Para a obtenção de feriados e recessos do calendário acadêmico de um ano determinado, a informação deve ser obtida através do link oficial da instituição, <http://www.unifesp.br/reitoria/prograd/pro-reitoria-de-graduacao/informacoes-institucionais/calendario-academico>. A única forma de ex-

portação desta informação é em pdf e em formato não tratável facilmente por algoritmos. Então os dias de recesso respectivos ao campus ICT-UNIFESP devem ser carregados manualmente nos códigos a serem implementados.

2.2.2 Dados Climáticos

Também serão analisadas variáveis climáticas juntos com os dados de consumo, de forma a analisar a influência de fatores externos como temperatura média ambiente e precipitação. Tais dados podem ser obtidos de forma gratuita pelo BDMEP - Banco de Dados Meteorológicos para Ensino e Pesquisa, pertencente à instituição pública INMET - Instituto Nacional de Meteorologia, pertencente ao MINISTÉRIO DA AGRICULTURA, PECUÁRIA E ABASTECIMENTO do Governo Brasileiro.

É necessário um cadastro no site <http://www.inmet.gov.br/portal/index.php?r=bdmep/bdmep> para a obtenção dos dados.

A instituição contém dados registrados de forma digital desde 1961 no país inteiro, os dados históricos referentes a períodos anteriores a 1961 ainda não estão em forma digital e, portanto, estão indisponíveis no BDMEP.

O BDMEP pode fornecer os registros de Precipitação(mm), Temp Máxima(°C), Temp Mínima(°C), Insolação(horas) Evaporação do Piche(mm), Temperatura Compensada Média(°C), Umidade Relativa Média(%), Velocidade Vento Média(mps).

Importante ressaltar que o BDMEP leva 90 dias para registrar cada nova data. Os dados utilizados para este trabalho foram da estação 83781 - São Paulo MIR de Santa - SP. Observa-se que para futuros trabalhos no atual campus ICT-UNIFESP, a estação TAUBATE - SP 83794, que no momento tem o banco de dados vazio, poderá ser utilizada.

Serão analisadas a temperatura máxima do dia que tem registro em momento próximo à frequência de refeições no horário de almoço, a temperatura mínima do dia que está próxima à janta, e a umidade relativa média que pode indicar presença de chuva no dia, que por sua vez causa diversos impactos ao público da região como a própria frequência do mesmo na instituição, principalmente no fator logístico.

Os dados se apresentam da seguinte forma:

1	Estacao;Data;Hora;Precipitacao;TempMaxima;TempMinima;Piche;Temp Comp Media;Umidade Relativa Media;Velocidade Vento Media
	83781;01/01/2017;0000;;31.7;;8.5;6.1;25.2;66;3.466667;
	83781;01/01/2017;1200;0;;18.1;,,,,;
	83781;02/01/2017;0000;;31.3;;5.6;6.3;23.96;83;2.9;
	83781;02/01/2017;1200;16;;18.1;,,,,; 83781;03/01/2017;0000;;31.7;;8.5;6.1;25.2;66;3.466667;
	83781;03/01/2017;1200;3.7;;19.2;,,,,;

Observa-se que cada data contém 2 linhas, sendo a primeira linha com o terceiro campo

de valor "0000" apresentando a temperatura máxima do dia no quinto campo, e a segunda linha com o terceiro campo de valor "1200" contendo a temperatura mínima do dia no sexto campo. A umidade relativa média se encontra no décimo campo da primeira linha de cada data. Todas as datas apresentam sempre o mesmo padrão de 2 linhas.

2.3 Análises Estatísticas

2.3.1 Análise Exploratória dos Dados

(JUNIOR, 2007) Cita que dados coletados em modelos de previsão possuem informações que quando são projetadas graficamente evidenciam comportamentos que em alguns casos podem ser visualizados e generalizados de forma subjetiva pelos gestores dos dados. Em todos os casos, a análise exploratória é necessária para selecionar o melhor método de análise que se enquadra neste comportamento.

COLOCAR AQUI O GRÁFICO DAS VENDAS DE 2017 / 2018 E AS TEMPERATURAS MEDIDAS.

Somente a análise exploratória não é o suficiente e realizada nos intervalos ou critérios incorretos pode comprometer seriamente as conclusões do comportamento dos dados, e que por sua vez pode comprometer seriamente a decisão dos gestores responsáveis por estes dados, no cenário de uma previsão de demanda. Isto ocorre atualmente no cenário de previsão da demanda de refeições do ICT-UNIFESP, onde a universidade e o estabelecimento que fornece as refeições não tem nenhum modelo de previsão de demanda.

De acordo com o gestor da atual empresa que fornece refeições no ICT, a análise utilizada para se prever as refeições é observar dentro da semana o dia anterior de consumo. Em variações de 300 para 450 refeições aproximadamente, isso tem provocado um desperdício médio de 150 refeições diárias. Em geral, de acordo com o restaurante, todos os dias o mesmo trabalha com um erro e um descarte de 30% das refeições que são trazidas e consumidas ao campus. Estima-se então que no período de 2011 - 01/08/2018 os estabelecimentos tenham tido um prejuízo de R\$1.885.938,40, e de 30% de R\$78.386,85 no atual período de 01/08/2018 - 31/10/2018 totalizando o montante R\$1.964.325,25. Aproximadamente 2 milhões de reais em prejuízo acumulado desde 2011.

2.3.2 Métodos de Previsão

(JUNIOR, 2007) Realiza uma revisão bibliográfica extensa abordando principais métodos de previsão de consumo sazonais, no cenário de uma indústria cosmética. Tais métodos estatísticos de previsão se dividem em 2 ramificações, sendo quantitativos ou qualitativos. Métodos qualitativos fazem um julgamento dos dados expostos sem um sistema de processamento analítico para se produzir novos modelos ou dados, eles são úteis para sistemas de agrupamento,

clusterização ou classificação de dados, sem fornecer novas informações numéricas ou modelos preditivos.

Métodos quantitativos que é o foco deste trabalho, são analíticos e se baseiam em um modelo matemático para realizar previsões.

Para realizar tais previsões os métodos quantitativos necessitam de um histórico de dados, para analisar padrões em seu comportamento e predizer o futuro que irá agir dentro deste padrão.

Estes métodos se ramificam em 2 tipos, as séries temporais e os modelos causais.

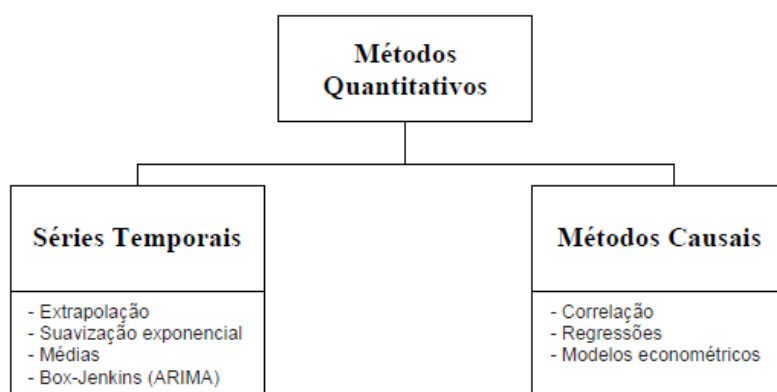


Figura 1 – Tipos de métodos quantitativos Retirado de (JUNIOR, 2007).

2.3.3 Métodos de previsão de Demanda

O autor supracitado também referencia métodos estatísticos especialmente selecionados para uma previsão de demanda, com a atenção de que alguns métodos qualitativos foram criteriosamente selecionados para prever uma demanda industrial, onde geralmente são previstas pelos métodos quantitativos.

O comportamento dos dados deste trabalho, apesar de ter uma distribuição de datas, que são em função do tempo e se classificando em um modelo de série temporal, tem tal comportamento impactado por relações causais com outras variáveis como recesso acadêmico, feriados, eventos, precipitações intensas que causam trânsito local e impactam na logística e frequência do público, entre outras variáveis de causas menos aparentes.

2.3.4 Meta-análise

(MARIANO, 2014) cita em sua tese, que resultados e modelos obtidos a partir de análises experimentais em determinado trabalho científico tem a expectativa de confirmação em um padrão de repetição futura, mas que nem sempre tal expectativa é cumprida. Logo é interessante que seja realizado uma análise das análises, ou seja, a comparação de resultados de diferentes métodos obtendo conclusões mais confiáveis e informativas do que o uso único de uma análise.




Figura 2 – Métodos de previsão de demanda (JUNIOR, 2007).

Portanto a distribuição de observações de vendas do restaurante universitário, em função do tempo, será tratada como um modelo de relação causal e quantitativo, e conforme a figura 2 será implementado o método estatístico de regressão linear, e os métodos de inteligência artificial de redes neurais, que obtem sucesso nos trabalhos relacionados desta pesquisa, após isso o resultado de ambos serão submetidos à uma meta-análise, e tais métodos serão explicados nos capítulos a se seguir.

2.3.5 Séries Temporais

De acordo com (MORETTIN, 1987) uma série temporal é um conjunto de observações ordenadas em função do tempo, comumente iguais, apresentando uma dependência serial entre elas, sendo um dos objetivos do estudo de séries temporais, analisar e modelar essa dependência. Além disso, séries temporais são analisadas pelos seus principais movimentos, como tendência, sazonalidade e a componente aleatória, sendo a tendência e sazonalidade as propriedades que mais ganham destaque em pesquisas de previsão de demanda de carga elétrica. Os meios mais comuns de se analisar a componente sazonal são o Método de Regressão (paramétrico), Método de Médias Móveis (não paramétrico), e Método de Diferença Sazonal (sazonalidade determinística). Neste trabalho, a distribuição dos dados do Restaurante se dá de forma paramétrica, ou seja, as vendas do restaurante se distribuem em função do tempo e com influências de parâmetros como o dia da semana por exemplo, sendo ideal as análises de regressão.

(ALMEIDA, 2013) também cita que para realizar a previsão de uma determinada série temporal é possível utilizar diferentes métodos. Pode-se classificá-los basicamente entre métodos estatísticos e baseados em inteligência artificial. Dentre os métodos estatísticos destacam-se:

- Regressão Linear Múltipla;
- Alisamento Exponencial;

- Média Móvel Integrada Auto-Regressiva (ARIMA)

Entre os métodos baseados em inteligência artificial tem-se:

- Redes Neurais Artificiais;
- Lógica Fuzzy.

2.3.6 Componentes Temporais

É importante observar que os métodos de previsão em séries temporais buscam uma redução da série temporal à um modelo estacionário e à decomposição da série em componentes de tendência, ciclo, sazonalidade e termo aleatório. A tendência se entende pelo movimento persistente dos dados em uma direção, o ciclo indica o movimento oscilatório desta tendência, sazonalidade indica comportamento regular assumido de forma repetitiva e o termo aleatório se dá por movimentos irregulares presentes na série.

As técnicas de previsão para evidências sazonais, conforme usam métodos de regressão, que pode ser observados nos trabalhos de previsão de consumo de energia elétrica realizados por (ALMEIDA, 2013), (??), (SILVA, 2010) e de previsão de demanda de produtos cosméticos em (JUNIOR, 2007)

O cenário deste estudo analisa a frequência de alunos dentro do ICT - UNIFESP e consequentemente dentro do R.U tem sazonalidade anual a partir do momento em que a grade de disciplinas tender a ter sazonalidade anual.

Através da Figura percebe-se a sazonalidade diária, com picos de consumo próximo às 09:00, 14:00 e 20:00 horas, e baixo consumo durante a madrugada, entre 00:00 e 06:00 horas.




Figura 3 – DADOS DE DEMANDA DE SAZONALIDADE DIÁRIA, EM FUNÇÃO DO HORÁRIO. Retirado de (RUAS, 2012).

2.3.7 Previsão com Regressão Linear Múltipla

A teoria da regressão se iniciou no século XIX com Galton, que analisou a altura dos pais e dos filhos (X_i e Y_i) e buscou a influencia da altura do pai no filho, notando que a altura

do filho tendia à media da altura do pai, e chamou esta técnica de regressão pois existe uma tendência dos dados regredirem à média.

(CLARICE G.B. DEMÉTRIO; ZOCCHI, 2011) Informa que em estudos de regressão aplica-se o método relacionar uma variável aleatória Y com uma variável X , e no caso da regressão múltipla com múltiplas variáveis X , representando causas diferentes que se combinam para a ocorrência de um valor Y .

No exemplo abaixo de regressão linear simples, podemos analisar o total de venda Y de um dia X , sendo relacionado nas variações $(\beta_0, \beta_1, \dots, \beta_k)$ de datas de X .

Ou seja, $X, Y \rightarrow Y \simeq f(X)$ Na regressão simples Y depende apenas de uma variável X , isto é, $Y \simeq f(\beta_0, \beta_1, \dots, \beta_k) + Ey$, Sendo Ey um erro aplicado à esta função para se chegar no valor Y . Logo a função $f(\cdot)$ pode ser linear nos parâmetros $(\beta_0, \beta_1, \dots, \beta_k)$, se a derivada da função em relação às derivadas dos parâmetros, corresponderem à $h(X)$, i , para i variando de 0 à k . Sendo $h(X)$, dependente apenas de X . $\frac{\partial f}{\partial \beta_i} = h(X)$, $i = 0, 1, \dots, k$

Na regressão múltipla, onde temos múltiplas relações causais X_1 à X_k , em ocorrências β_0 à β_k , temos a função: $Y \simeq f(X_1, X_2, \dots, X_k, \beta_0, \beta_1, \dots, \beta_k) + Ey$. Também sendo linear nos parâmetros se a derivada da função em relação às múltiplas derivadas dos parâmetros, corresponderem à $h(X_1, X_2, \dots, X_k)$, tendo $h(\cdot)$, dependente apenas de X_1, X_2, \dots, X_k . Em caso contrário, $f(\cdot)$ é uma função não linear dos parâmetros.

Logo, $Y = f(X_1, X_2, \dots, X_k, \beta_0, \beta_1, \dots, \beta_k) + Ey$ é linear nos parâmetros se: $\frac{\partial f}{\partial \beta_i} = h(X_1, X_2, \dots, X_k)$

Neste trabalho temos múltiplas relações causais, como dados climáticos e dados derivados da data. Logo será usado um algoritmo de regressão linear múltipla, transportando o valor de cada parâmetro causal para cada X_i . O objetivo é encontrar a linearidade dessas relações, para que seja possível prever um valor de venda futura, dado os valores de observações futuras.

A primeira etapa, será realizar o teste de linearidade dos parâmetros. Em caso de testes falhos, o modelo de parâmetros deverá ser reduzido ou adaptado, para a aprovação novamente no algoritmo, até a obtenção de um modelo final para validação.

O modelo inicial de dados, para o exemplo das 2 primeiras datas letivas de 2018, seguem com os dados de entrada de consumo e em seguida os dados de entrada de clima:

1 DATA,VENDAS CAFÉ,VENDAS ALMOÇO,VENDAS JANTAR,VENDAS REFEIÇÃO*,TOTAL VENDAS,ENTR. CAFÉ,ENTR. ALMOÇO,ENTR. JANTAR,TOTAL ENTR. REFEIÇÃO*,TOTAL ENTRADA;
(26/02/2018),0,930,10,940,940,0,446,190,636,636;
(27/02/2018),0,640,13,653,653,0,470,237,707,707;

Os dados de consumo no modelo reduzido de previsão de almoço, fica somente com a

```

1 83781;26/02/2018;0000;;27.2;;1.1;2.9;22.2;88;1.6; 83781;26/02/2018;1200;0;;19.6;;;;;
   83781;27/02/2018;0000;;28.5;;3.6;1.1;22.92;84;2.5;
   83781;27/02/2018;1200;73.1;;19;;;;;

```

data da venda, e o total de refeições realizadas no almoço.

```

1 DATA,ENTR. ALMOÇO; (26/02/2018),446; (27/02/2018),470;

```

Na tabela de dados climáticos, a redução ocorre para o valor da data, na linha 0000, contendo o valor de temperatura máxima, e precipitação.

```

1 26/02/2018;27.2;88; 27/02/2018;28.5;84;

```

A informação de data, irá gerar informações derivadas como o valor em forma de fator do dia da semana (obtido através de métodos que retornam o dia da semana, dado uma data, numero do semestre sendo 1 para o primeiro, e 2 para o segundo).

O dia da semana seguirá o modelo binário de acordo com os trabalho de previsão de demanda em R.U realizados por (LOPES, 2008) e (ROCHA JOSÉ CELSO; MATOS, 2011).

Dia da semana	Valor				
Segunda-feira	1	0	0	0	0
Terça-feira	0	1	0	0	0
Quarta-feira	0	0	1	0	0
Quinta-feira	0	0	0	1	0
Sexta-feira	0	0	0	0	1

Figura 4 – Entradas de dia da semana em cofatores. Retirado de (LOPES, 2008).

A informação de data constará no primeiro campo da estrutura mas será ignorada pelo código, que iniciará a leitura da primeira variável X_i no campo de Vendas almoço neste exemplo.

Os dados estruturados ficarão de acordo com a Tabela 1, onde o vetor X_i receberá os dados da coluna $i + 1$ 3ª linha até a 2ª até a 15ª linha, e o valor Y_i receberá o dado da coluna $i + 1$ na 1ª linha:

Tabela 1 – Tabela de dados para regressão múltipla.

VENDAS - Y_i	446	470
PARÂMETROS X_i	26/02/2018	27/02/2018
Temperatura(C)	27.2	28.5
Precipitação(%)	88	84
Segunda	1	0
Terça	0	1
Quarta	0	0
Quinta	0	0
Sexta	0	0
Primavera	0	0
Verão	1	1
Outono	0	0
Inverno	0	0
1o Semestre	1	0
2o Semestre	1	0

2.3.8 N CONCLUIDO - Algoritmo de Regressão Linear Multipla

Algoritmo 1: REGRESSÃO LINEAR MULTIPLA

Entrada: Dataset, VetorPesos

Saída: Vetor de coeficientes da função $h(x)$

```

1  início
2       $S \leftarrow newStops()$ 
3       $M \leftarrow newMoves()$ 
4      para cada trajetria  $t \in T$  faça
5           $i \leftarrow 0$ 
6           $previousStop \leftarrow null$ 
7          enquanto  $i \leq size(t)$  faça
8              se  $\exists (Rc, \Delta c) \in A \mid geometria(t[i]) \cap Rc$  então
9                   $enterTime \leftarrow time(t[i])$ 
10                  $i++$ 
11                 enquanto  $geometria(t[i]) \cap Rc$  faça
12                      $i++$ 
13                 fim
14                  $i--$ ,  $leaveTime \leftarrow time(t[i])$ 
15                 se  $leaveTime - enterTime \geq \Delta c$  então
16                      $stop \leftarrow (t, Rc, enterTime, leaveTime)$ 
17                      $S.add(stop)$ 
18                      $move \leftarrow$ 
19                          $(t, previousStop, stop, previousStop.leaveTime, enterTime)$ 
20                      $M.add(move)$ 
21                      $previousStop \leftarrow stop$ 
22                 fim
23                  $i++$ ,  $j \leftarrow 1$ 
24                 enquanto  $(i + j \leq size(t))$  and  $(t[i + j] - t[i] < \min \Delta c(A))$  faça
25                      $j++$ 
26                 fim
27                 se  $\nexists (Rc, \Delta c) \in A \mid geometria(t[i + j - 1]) \cap Rc$  então
28                      $i \leftarrow i + j$ 
29                 fim
30             fim
31             se  $t[i - 1] not \in previousStop$  então
32                  $move \leftarrow (t, previousStop, null, previousStop.leaveTime, time(t[i - 1]))$ 
33                  $M.add(move)$ 
34             fim
35         fim
36 fim

```

2.4 Inteligencia Artificial

A Inteligência artificial "A inteligência artificial é o ramo da ciência da computação que se ocupa do comportamento inteligente."(?). O termo "Inteligencia Artificial" surgiu em meados de 1956 em uma conferência, chamada Dartmouth Summer Research Project on Artificial Intelligence, sediada nos Estados Unidos em Dartmouth College, Hanover, New Hampshire, a conferência foi organizada por John McCarthy e teve como proposta reunir matemáticos, cientistas da computação e pesquisadores buscando descobrir como fazer com que as máquinas usem linguagem, abstrações de formulários e conceitos, para resolver problemas que eram reservados aos humanos, e que consigam melhorar o seu próprio desempenho.

Sistemas de inteligência artificial buscam então resolver funções e problemas que seres humanos conseguem resolver melhor do que máquinas convencionais, usando sua capacidade de abstração e aprendizagem com o erro.

2.4.1 Neurônio Artificial

História e inspiração da Inteligência Artificial Redes Neurais Artificiais são elementos de inteligência artificial da ciência da computação, inspirados no funcionamento do cérebro humano. São formadas por neurônios artificiais interconectados que são capazes de processar múltiplos valores de entradas, e reagir produzindo uma resposta relacionada à essas entradas. Como qualquer outro método de aprendizado de máquina, este modelo busca obter um aprendizado a partir dos dados de entrada recebidos, criando uma capacidade de generalização de problemas e assim buscam o objetivo principal de resolver novos problemas com este aprendizado.

Uma rede neural pode não produzir uma resposta esperada, resolvendo erroneamente um problema, assim como o cérebro humano tem limitações de aprendizado, que levam o homem a cometer falhas de decisões ou ações por um aprendizado mal treinado. Por isso as características fundamentais que tornam uma rede neural artificial em uma boa solução, é um bom planejamento de sua topologia, e método de treinamento, que serão explicados a seguir.

(?) Demonstra em sua pesquisa que a propriedade fundamental do cérebro é a sua capacidade de mudar com uma grande variedade de experiências, inclusive lesões que provocam perdas de neurônios, abordando princípios de plasticidade cerebral, mostra também que a capacidade de aprendizado de mamíferos que sofreram uma redução de neurônios causada por lesões, pode ser restaurada não somente pela recuperação desses neurônios perdidos, mas sim por novas conexões e sinapses entre outros neurônios. Ou seja, a rede sofre uma mudança de topologia.

(?) Mostra em um experimento recente que o cérebro humano possui atualmente 86 bilhões de neurônios interconectados, e que sua capacidade de aprendizado e habilidades evolutivas também vêm aumentando em conjunto com seu número de neurônios e topologia de rede

neural, que há 30 milhões de anos atrás tinha apenas 2,5 bilhões de neurônios e era apenas um animal arborícola quadrúpede.

Neurônio Biológico O modelo de neurônio artificial surge então, com a busca da inteligência artificial de reproduzir o comportamento de aprendizado humano, reproduzindo computacionalmente seu elemento biológico principal de aprendizagem: O neurônio biológico. Um neurônio




Figura 5 – Neurônio Biológico, retirado de <https://pt.khanacademy.org/science/biology/human-biology/neuron-nervous-system/v/anatomy-of-a-neuron>.

biológico (Figura 05) processa informações recebidas por meio de seus dendritos e processa-as em seu corpo celular, tal reação à esses estímulos recebidos gera um sinal de saída como resposta aos estímulos, enviado através do axônio. Esse estímulo é repassado como sinal de entrada, através de outros neurônios por meio de seus dendritos, e o ciclo se repete em uma vasta rede. Controlando essas conexões, pontos de contato entre a resposta de um neurônio e a entrada de outro, existem as sinapses. Elas funcionam como agentes que permitem a interação acontecer ou inibem, e são acionadas por um conjunto somatório de estímulos. Se tal somatório de estímulos for satisfatório, elas permite a transmissão de sinal elétrico pelo axônio até o dendrito de um neurônio vizinho, formando um ciclo de aprendizado em uma rede neural biológica.

Neurônio Artificial Warren McCulloch e Walter Pitts em 1942 observando o neurônio biológico iniciam a busca de um modelo computacional do mesmo. McCulloch era psiquiatra e neuroanatomista e passou cerca de 20 anos refletindo e estudando sobre a representação do sistema nervoso, em 1942 ele convidou Pitts, que era matemático, para fazer parte das suas pesquisas. Em 1943 lançaram o artigo "A Logical Calculus of the Ideas Immanent in Nervous Activity," chegando em um modelo matemático do neurônio artificial:

Assim como no neurônio biológico, este modelo reage à um vetor de entradas X_0, X_1, \dots, X_n onde tem suas sinapses representadas por pesos numéricos, existe uma soma ponderada dessas entradas que é controlada por uma função de transferência ou função de ativação, determinando se essa soma é maior que um valor numérico. Se essa soma for satisfatória o neurônio é ativado emitindo um valor de saída 1, caso contrário se emite um valor de saída 0. Todo o funciona-




Figura 6 – Neurônio Artificial

mento deste modelo então é reduzido a responder se a soma recebida é maior que um valor numérico esperado.

Neste modelo simplista o neurônio consegue realizar operações lógicas. Na figura 07 os pesos w_1 e w_2 e o limiar T estão ajustados para responder à operação AND que resumidamente é uma operação lógica que somente produz um valor positivo 1 na resposta de saída se ambos os valores de entrada forem 1.




Figura 7 – Neurônio Artificial - Operação AND

Neste modelo o neurônio irá comparar se a soma das entradas X multiplicadas pelos seus devidos pesos W , será menor que o limiar T . Ele somente irá produzir uma resposta positiva (1) se essa soma for maior. É fácil verificar então na imagem, que o resultado dessa soma só será positivo, se ambas as entradas forem 1, onde a soma será $2 > 1,5$.

Tabela 2 – Operação Lógica AND

A	B	Saída
0	0	0
0	1	0
1	0	0
1	1	1

2.4.2 Redes Neurais Artificiais

Perceptron O modelo de Warren McCulloch e Walter Pitts, apesar de conseguir simular o modelo de neurônio biológico e resolver algumas tarefas lógicas e matemáticas não atendia o objetivo principal da Inteligência Artificial: A capacidade de aprendizado. Para utilizar um modelo de neurônio artificial a fim da solução de um problema era necessário conhecer o ajuste dos pesos das entradas, e em uma tarefa de um cenário complexo e com muitas variáveis, ou pesos não perceptíveis ao valor esperado de saída, este ajuste não é trivial.

Em 1958, o cientista da computação Frank Rosenblatt desenvolveu o modelo de neurônio artificial Perceptron para solucionar este problema de ajuste de pesos. Basicamente neste novo modelo, os pesos das conexões são ajustados de forma autônoma com a introdução de pessoas associadas e uma valor bias, a fim de buscar um reconhecimento autônomo de padrões. Tarefas de reconhecimento de padrões simples com separações lineares os seres humanos conseguem realizar de forma trivial mas ainda era um desafio para tal problema se resolvido por uma máquina.

O perceptron (MARIANO, 2014) possui apenas uma camada de entrada e saída, a saída utiliza como função de ativação a função degrau u que define quando o neurônio emitirá o sinal lógico 1 ou quando emitirá o sinal lógico 0.

O sinal de saída do perceptron entende-se então por: $y = \delta(\sum_{i=1}^n X_i W_i + b)$

- X_i - sinais de entrada do neurônio;
- W_i - pesos sinápticos do neurônio;
- b - bias ou limiar de ativação;
- $\delta(\cdot)$ - função de ativação;
- y - sinal de saída do neurônio.

Em algumas literaturas o bias pode ser reduzido a um peso W_0 com entrada X_0 fixo em 1 no neurônio, a representação gráfica da topologia pode mudar, mas no somatório de saída, o cálculo continua o mesmo.

A função de ativação δ se apresenta de forma linear ou não linear, determinando a saída de um neurônio a partir do seu potencial de ativação. As funções de ativação podem ser observadas na figura 09, sendo a de maior popularidade de utilização, a sigmoide.

As funções de ativação dá a capacidade do perceptron quando conectado em rede (explicado no próximo capítulo) de resolver problemas lineares e não lineares, agregando adaptação e improvisado ao resolver programas que não estão contidos em seus dados de alimentação.

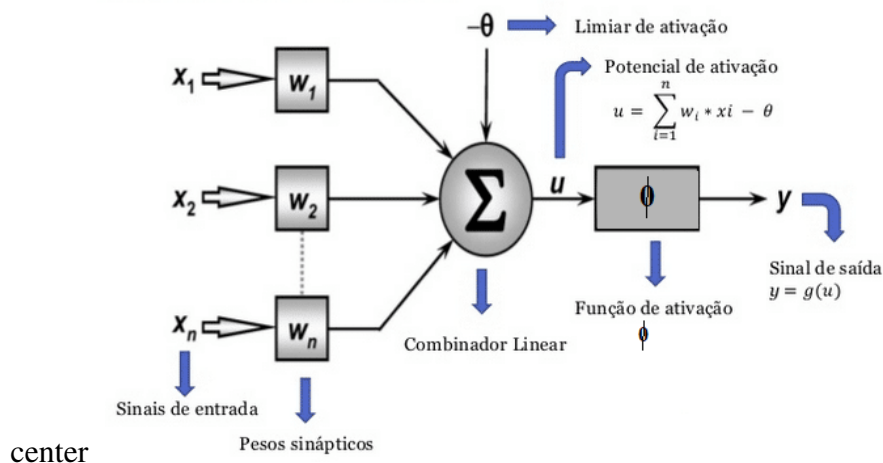



Figura 8 – Neurônio Artificial Perceptron



Tipos de função de ativação: (a) função degrau, (b) função linear, (c) função sigmoide, (d) função tangente hiperbólica

Figura 9 – Funções de Ativação retirado de (MARIANO, 2014)

Perceptron - Treino Supervisionado (??) cita que o processo de aprendizado do perceptron pode ocorrer de forma supervisionada quando o neurônio deve aprender a relacionar um conjunto observado de variáveis à um valor observado de saída deste mesmo conjunto. O neurônio recebe os sinais de entrada X_i e produz uma saída Y_i através do combinador linear e função δ de ativação; compara essa saída Y_i com a observação i obtida do conjunto de dados (ponto chave do processo de treino supervisionado) e por fim essa comparação irá gerar um erro e .

Critério de parada De acordo com algum critério adotado em cada contexto de aplicação do perceptron, este erro pode ser aceitado e o neurônio mantém o valor de seus pesos W_i que impactam na saída Y_i desejada. Se o erro não for aceitado, uma nova época (ou repetição) de interação dos mesmos valores X_i passados é reiniciada, com valores de pesos W_i reajustados com o objetivo de se obter um erro menor.

Esse reajuste de pesos W_i denomina-se taxa de aprendizagem, α que pode ter critérios de escolha livre ao contexto de aplicação do perceptron, para reajustar estes pesos W_i .

A decisão pela repetição, que denomina-se critério de parada do treinamento, também

pode adotar diversos critérios de aplicação, sendo eles baseados em uma aceitação do erro, em um número limite de treinamento, ou na combinação desses 2 critérios.

De forma procedural, o processo do treino supervisionado do perceptron, para j entradas, em uma interação de aprendizado n ocorre da seguinte maneira:

1. Coleta do valor supervisionado Y_i , que é a observação histórica do conjunto de dados.
2. Coleta do vetor de variáveis $(X_i, X_i + 1, \dots, X_j)$ relacionados à saída supervisionada Y_i .
3. Inicialização de todos os pesos sinápticos $(W_i, W_i + 1, \dots, W_j)$ com valores aleatoriamente pequenos.
4. Definição de um valor real entre 0 e 1 para a taxa de aprendizado α .
5. Definição do valor de bias b .
6. Definição da função de ativação δ
7. Cálculo do sinal $U_n = \delta(\sum_{i=1}^j X_i * W_i + b)$
8. Aplicação de valor de U_n na função de ativação δ obtendo $Y_n, Y_n = \delta(U_n)$
9. Obtenção do erro $e_n = Y_i - Y_n$
10. Avaliação do critério de parada

2.4.3 Previsão de demanda de R.U com rede perceptron múltiplas camadas com back-propagation

* As RNA de múltiplas camadas resolve o problema de linearidade que o perceptron de única camada e a regressão linear de múltiplas variáveis não consegue realizar. *Mais detalhes sobre multiplas camadas.

Em (LOPES, 2008) a rede neural perceptron de múltiplas camadas é utilizada para tratar a previsão de demanda do R.U da UFV, utilizando apenas como variáveis quantitativas as 5 ultimas observações anteriores ao dia a se analisar, e como variáveis de qualitativas o dia da semana variando de segunda a sexta, conforme modelo já detalhado no método de regressão múltipla.

Em (ROCHA JOSÉ CELSO; MATOS, 2011) o trabalho realizado com neurônios artificiais para prever a demanda do R.U da Unesp, envolve apenas uma única camada de entrada e uma segunda camada para saída. Algoritmo método deste trabalho




Figura 10 – Rede Neural Perceptron de Múltiplas Camadas. Retirado de (LOPES, 2008).

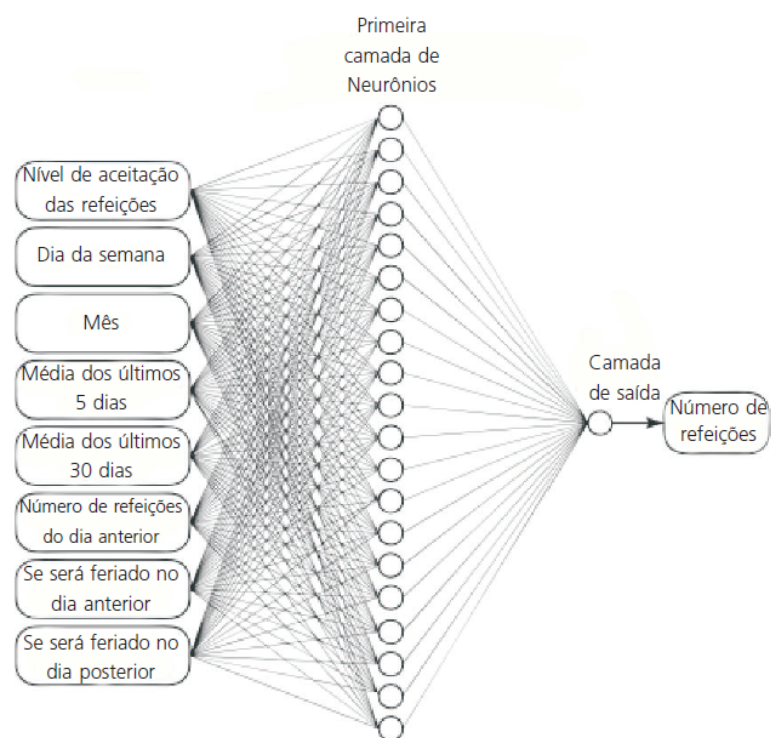


Figura 11 – Rede Neural Perceptron de Múltiplas Camadas. Retirado de (ROCHA JOSÉ CELSO; MATOS, 2011)

3 Trabalhos relacionados

Entre os últimos artigos publicados em 2015 sobre enriquecimento de trajetórias está o trabalho de (SUBLIME et al., 2015), que tem características específicas que permitem a extração de informações semântica sobre dados geográficos de imagens de alta resolução, esse tipo de extração de semântica é muito usado quando os dados não são obtidos via objetos móveis, já que se obtêm a semântica a partir de dados. Porém com estes dados, são gerados mapas atualizados que são proveitosos para aplicar semântica em trajetórias brutas de objetos móveis. Os estudos em torno de trajetórias semânticas e enriquecimento semântico têm tido um grande avanço nos últimos anos.

No trabalho de (ALVARES et al., 2007), o enriquecimento de trajetórias é feito com informações geográficas para simplificar consultas que são complexas, então é proposto um pré-processamento de modelo de dados para adicionar informações semânticas as trajetórias.

Em (LAUBE; KREVELD; IMFELD, 2005), é introduzido o estudo de comportamento de movimentos de trajetórias, onde o autor explica como se obtêm cada tipo de movimento o que vem a ser proveitoso para este trabalho, o padrão de encontro que é exemplificado no livro é o mais complexo de se calcular, por que temos que medir o intervalo de tempo de todas as trajetórias que passam em um determinado raio R .

Em (??) uma trajetória bruta pode ser enriquecida com diferentes informações semânticas de acordo com o contexto da aplicação e o problema que o usuário pretende resolver.

Neste trabalho é utilizado o método de enriquecimento de trajetórias onde usaremos informações geográficas para conflitar com as trajetórias e dizer se são pontos de *stops* através do algoritmo de *stops and moves*, tendo esses dados enriquecidos semanticamente vai ser implementado um algoritmo que detecta encontros em trajetórias a partir de um raio dado e um tempo de permanência mínimo em cada *stop*.

4 Plano de atividades para o TCC II

Para a continuação deste trabalho o cronograma abaixo deve ser seguido.

Tabela 3 – Plano de atividades para o TCC II

Atividades	Março	Abril	Maiο	Junho	Julho
1	✓				
2	✓				
3		✓	✓		
4		✓	✓	✓	
5		✓	✓	✓	
6					✓

1. Busca de uma base de dados correta para a aplicação.
2. Evidenciar o contexto semântico a ser aplicado.
3. Implementar o algoritmo SMoT.
4. Implementar o algoritmo que detecta encontros.
5. Análise e comparação dos resultados.
6. Documentação total do trabalho.
7. Apresentação do trabalho.

5 Conclusão

A forma de enriquecer semânticas de objetos móveis, é uma área de pesquisa que cresce cada vez mais, e a produção de dispositivos móveis cresce de uma forma muito agressiva no mercado resultando em grandes volumes de dados geográficos, porém aonde aplicar todos os métodos que vimos neste trabalho e obter resultados significativos, isso ainda está em sua infância.

Em aplicações onde se usam dados gerados por dispositivos móveis, deve ser feito um estudo muito bem-feito para enriquecer suas trajetórias, onde o contexto da aplicação depende muito na execução do algoritmo para obter excelentes resultados.

A proposta deste trabalho é trabalhar com dados fornecidos de trajetórias brutas e aplicar o método SMoT para enriquecê-las semanticamente e posteriormente analisar essas rotas e indicar em quais pontos houve encontros, independente de qual objeto gerou tais rotas.

Referências

- ALMEIDA, V. A. d. *Previsão De Carga Através De Modelos Neuro-fuzzy*. 91 p. Tese (Doutorado) — Universidade Federal do Rio de Janeiro, 2013. Disponível em: <<http://monografias.poli.ufrj.br/monografias/monopoli10007620.pdf>>. Citado 3 vezes nas páginas 23, 31 e 32.
- ALVARES, L. O. et al. A model for enriching trajectories with semantic geographical information. In: *Proceedings of the 15th Annual ACM International Symposium on Advances in Geographic Information Systems*. New York, NY, USA: ACM, 2007. (GIS '07), p. 22:1–22:8. ISBN 978-1-59593-914-2. Disponível em: <<http://doi.acm.org/10.1145/1341012.1341041>>. Citado na página 45.
- CLARICE G.B. DEMÉTRIO; ZOCCHI, S. S. *Modelos de Regressão*. [S.l.]: Departamento de Ciências Exatas, ESALQ, USP, 2011. Citado 2 vezes nas páginas 23 e 33.
- GIANNOTTI, F.; PEDRESCHI, D. *Mobility, data mining and privacy: Geographic knowledge discovery*. [S.l.]: Springer Science & Business Media, 2008. Nenhuma citação no texto.
- HAYKIN, S. *Neural networks, a comprehensive foundation*. [S.l.]: Macmilan, 1994. Citado na página 23.
- JUNIOR, A. M. *Análise de métodos de previsão de demanda baseados em séries temporais em uma empresa do setor de perfumes e cosméticos*. Dissertação (Mestrado) — Pontifícia Universidade do Paraná. Curitiba, 2007. Citado 6 vezes nas páginas 13, 23, 29, 30, 31 e 32.
- LAUBE, P.; KREVELD, M. van; IMFELD, S. Finding remo—detecting relative motion patterns in geospatial lifelines. In: *Developments in spatial data handling*. [S.l.]: Springer Berlin Heidelberg, 2005. p. 201–215. Citado na página 45.
- LOPES, L. Modelos para previsão de demanda no restaurante universitário utilizando técnicas de redes neurais. *Congresso Nacional De Excelência Em Gestão*. Universidade Federal De Viçosa., Universidade Federal De Viçosa, IV, n. 1, p. 14, 2008. Disponível em: <<http://www.novoscursos.ufv.br/projetos/ufv/gesep/www/wp-content/uploads/5>> Citado 5 vezes nas páginas 13, 23, 34, 42 e 43.
- MARIANO, F. C. M. Q. *REdes Neurais na predição de valores energéticos de alimentos para aves*. 130 p. Tese (Doutorado) — Universidade Federal de Lavras, 2014. Citado 5 vezes nas páginas 13, 24, 30, 40 e 41.
- MORETTIN, P. A. *Análise de séries temporais*. [S.l.]: Editora Blucher, 1987. Citado na página 31.
- REZENDE, S. O. *Sistemas inteligentes: fundamentos e aplicações*. [S.l.]: Editora Manole Ltda, 2003. Nenhuma citação no texto.
- ROCHA JOSÉ CELSO; MATOS, F. D. F. Utilização de redes neurais artificiais para a determinação do números de refeições diárias de um restaurante universitário. *Rev. Nutr., Campinas*, Universidade Estadual Paulista Júlio de Mesquita Filho., n. 1, p. 8, 2011. Disponvel em: <http://www.scielo.br/scielo.php?pid=S1415-52732011000500007script=sci_arttextlng=pt>. Citado 5 vezes nas páginas 13, 23, 34, 42 e 43.

RUAS, G. I. e. S. Previsão de demanda de energia elétrica utilizando redes neurais artificiais e support vector regression. *Copel Distribuição S/A (COPEL)*, Universidade Federal do Paraná(UFPR), v. 1, n. 1, p. 10, 2012. Disponível em: <http://www.dcc.fc.up.pt/~ines/enia07_html/pdf/27927.pdf>. Citado 2 vezes nas páginas 13 e 32.

SILVA, C. e. a. Metodologia para previsão de demanda de energia elétrica em curtíssimo prazo baseada em um modelo probabilístico discreto. *Desenvolvimento de Algoritmos e Software para Previsão de Carga na Área de Concessão da MuxEnergia - Horizonte de Curtíssimo Prazo*, Universidade Federal do Pampa - UNIPAMPA, v. 1, n. 1, p. 4, 2010. Disponível em: <http://alegrete.unipampa.edu.br/gesep/wp-content/uploads/2010/05/Previs%C3%A3o-dedemanda-utiilizando-m%C3%A9todo-de-Markov_Final.pdf>. Citado 2 vezes nas páginas 23 e 32.

SUBLIME, J. et al. Semantic rich icm algorithm for vhr satellite images segmentation. In: *Machine Vision Applications (MVA), 2015 14th IAPR International Conference on*. [S.l.: s.n.], 2015. p. 45–48. Citado na página 45.