

MODELOS PARA PREVISÃO DE DEMANDA NO RESTAURANTE UNIVERSITÁRIO UTILIZANDO TÉCNICAS DE REDES NEURAIS

Liliane Lopes Cordeiro (DMA - UFV)

lililopescordeiro@yahoo.com.br

Heverton Augusto Pereira (Unicamp)

hevertonaugusto@yahoo.com.br

Resumo

Um dos grandes problemas enfrentados hoje no mundo é a elevação dos preços dos alimentos. Isto tem causado preocupações para a população em geral e também para as empresas como restaurantes que sofrem diretamente os reflexos da variação no preço dos alimentos. Atualmente o Restaurante Universitário (R.U.) da Universidade Federal de Viçosa não possui um sistema que ajude na gestão de compras dos alimentos. O objetivo deste trabalho é utilizar a técnica de Redes Neurais Artificiais do tipo MLP (Perceptron Múltiplas Camadas) para fazer a predição do número de usuários que irão fazer suas refeições no R.U. em uma, duas e três semanas para a administração poder determinar a política de compras de alimentos. As redes desenvolvidas utilizam o dia da semana e os cinco dias anteriores ao que se deseja prever. Para validar os modelos propostos foram separados conjuntos de dados para realização de comparações e análises da eficácia da nova forma de gestão das compras.

Abstract

Nowadays, one of the major problems in the world is the rising of food prices. The problem concerns general population and also businesses such as restaurants that suffer directly the consequences of changes in the food prices. Currently thhe University Restaurant (R.U.), at Federal University of Viçosa does not have a system that helps in the management to buy food. This work uses the technique of Artificial Neural Networks MLP type (Multiple Layers Perceptron) to predict the number of users who will have their meals in the R.U. in one, two and three weeks to support the administration's decision of food storing. The developed networks have as input variables: day of the week and the previous five days until the day that want to predict. Different data were used to validate the models through comparisons and analysis of the new management food buying benefits.

Palavras-chaves: Redes Neurais Artificiais, Previsão, Gestão

1. INTRODUÇÃO

O Restaurante Universitário da Universidade Federal de Viçosa tem como objetivo principal atender a demanda por alimentação dos estudantes de graduação e pós-graduação, não possuindo como objetivo obter lucro pelo seu funcionamento, mas tendo que se gerir pelos recursos arrecadados com a venda do ticket de alimentação.

Em 1992, o Ministério da Educação e Cultura extinguiu as verbas destinadas aos restaurantes universitários – RU's, repassando para as Instituições de Ensino Superior a responsabilidade do incentivo e da manutenção desses estabelecimentos. A partir de então, os subsídios para os RU's se escassearam, repercutindo na conservação dos utensílios, equipamentos e edificações; na qualificação do quadro funcional e na qualidade dos serviços oferecidos.

O mundo atual tem enfrentado uma grave crise devido a grande elevação dos preços dos alimentos, sendo que esta elevação tem um impacto direto no valor das compras realizadas pelo R.U., de maneira que evitar o desperdício é de vital importância para utilizar os recursos de maneira eficiente. Uma vez que é muito complexo ficar repassando os aumentos para os estudantes, pois esta questão costuma causar grande repercussão na comunidade estudantil.

Para utilizar os recursos de maneira eficiente é de vital importância um sistema de previsão, para auxiliar os coordenadores na tomada de decisões a respeito da quantidade de alimentos a serem compradas, para um determinado período de tempo.

A previsão é um fenômeno universal utilizado em atividades cognitivas de baixo nível como visão e percepção, mas também em outras de alto nível como planejamento e inferência, bastante utilizadas na área de Economia e Finanças (SATYADAS, 1994).

Para auxiliar os coordenadores na tomada de decisão de compras foi desenvolvido um modelo baseado na técnica de Redes Neurais Artificiais (RNAs), capaz de prever para uma, duas ou três semanas quantas pessoas irão se alimentar no R.U. durante os dias da semana.

A solução de diversos problemas de engenharia através de RNAs é bastante interessante, tanto pela forma como são representados internamente pela rede, como também

pelos resultados que gera, pois podem chegar a apresentar um desempenho superior ao dos modelos tradicionais, por exemplo, as análises de regressão (BOCANEGRA, 2002).

Entre as diversas arquiteturas de RNAs, foram escolhidas as redes Perceptron Múltiplas Camadas (MLP).

Elas constituem os modelos de RNAs mais utilizados e conhecidos atualmente. Tipicamente, esta arquitetura consiste de um conjunto de unidades sensoriais que formam uma camada de entrada, uma ou mais camadas intermediárias (ou ocultas) de unidades computacionais e uma camada de saída (HAYKIN, 1994).

A figura 1 representa um esquema típico de uma rede neural artificial com múltiplas camadas. As entradas são conectadas aos elementos processadores básicos, que são por sua vez interconectados com elementos de outras camadas e/ou saída da rede.




Figura 1 – Exemplo de Rede MLP

Com os dados obtidos da coordenação do R.U. foi modelado o problema, definindo as entradas para a rede. Com o vetor de dados foi realizado o treinamento, sendo que diversas topologias de redes foram utilizadas variando o número de neurônios e também a quantidade de camadas intermediárias. O resultado final foi o desenvolvimento de 3 modelos uma para prever o número de refeições para uma semana, outro para prever 2 semanas e o terceiro para fazer a previsão de 3 semanas. Mais de um modelo foi desenvolvido pelo fato de que os modelos utilizarem a própria previsão, o que pode acarretar em uma propagação do erro das previsões. Este assunto será tratado em detalhes no decorrer do artigo.

2. METODOLOGIA

Para entender a dinâmica de funcionamento do R.U. foram coletados os dados referentes ao período de 17 de janeiro de 2007 a 14 de julho do mesmo ano. Neste período ocorreram feriados e recessos escolares, em que o R.U. não funcionou. O conjunto de dados formou um vetor com 155 dias.

Como pode ser observado na figura 2, o sistema de previsão do R.U. nem sempre consegue predizer de maneira eficiente o número de refeições a serem servidas.




Figura 2 – Gráfico das refeições servidas e previstas

Na figura 3 é exibido o erro entre a previsão do R.U. e o número de refeições servidas. Observa-se, pela figura 3 a importância de um sistema de predição eficiente, para evitar que problemas como o excesso ou a falta de comida ocorra. Esses erros causam respectivamente, desperdício de alimentos que não podem ser armazenados ou demora no atendimento, que tem como consequência grandes filas e insatisfação dos usuários.




Figura 3 – Gráfico do erro entre o número de refeições servidas e previstas

Os dois pontos críticos observados são:

- Previsão de 1337 refeições acima do servido.
- Previsão de 477 refeições a menos do que foi servido.

Dos 155 dias, os finais de semana foram eliminados pelo fato de ocorrer uma redução muito grande no número de refeições servidas, e nas simulações iniciais esse padrão era difícil de ser captado pelo modelo. Semanas atípicas no funcionamento do R.U. onde haviam grandes feriados foram retiradas, pelo mesmo motivo anterior, sendo que restaram 102 dias para construção do modelo.

As variáveis que foram analisadas para prever o número de usuários foram o dia da semana e os cinco dias anteriores ao dia que se deseja prever, estas variáveis formam o vetor de entrada da rede neural.

A primeira entrada que influencia o número de usuários do R.U. é o dia da semana. Dias de quarta e quinta, geralmente apresentam maior demanda de refeições, e sextas apresentam menor procura. Assim, foram definidos para os dias da semana valores binários, os quais são indicados abaixo na tabela 1. Esses valores servirão de entrada para o modelo.

Tabela 1. Dias da semana com respectivos valores.

Tabela 1 – Dias da semana com respectivos valores.

Dia da semana	Valor
---------------	-------

Segunda-feira	1	0	0	0	0
Terça-feira	0	1	0	0	0
Quarta-feira	0	0	1	0	0
Quinta-feira	0	0	0	1	0
Sexta-feira	0	0	0	0	1

Considerando também, o fato de que existe uma tendência de aumento ou diminuição do número de usuários, devido a fatores como feriados, datas especiais, final de período, foi definido como mais 5 entradas para a rede o número de usuários que se alimentaram durante os cinco últimos dias, antes do dia em que se deseja prever.

Na figura 4 temos o mesmo modelo exibido na figura 1, mas com as entradas já definidas para obter na saída o número de refeições a serem servidas.




Figura 4 – Entradas e saída da rede proposta

Com as entradas definidas para rede, começa a etapa de treinamento. Vários algoritmos de treinamento foram testados, mas o que proporcionou melhor resultado foi o *traincgp* (Conjugate gradient backpropagation with Polak-Ribiere updates). Ressalta-se que todo o treinamento foi realizado com o software Matlab.

Este algoritmo não envolve o cálculo das derivadas segundas das variáveis e converge ao mínimo da função quadrática em um número finito de iterações. O algoritmo do gradiente

conjugado, sem ainda assim aplicar ao algoritmo de propagação backward consiste em:

1. Selecionar a direção de p_0 , a condição inicial, no sentido negativo do gradiente.

$$p_0 = -g_0$$

$$g(k) = \nabla e(x) |_{x=xk}$$

2. Selecionar a taxa de aprendizagem α_k para minimizar a função ao longo da direção.

$$x_{k+1} = x_k + \alpha_k p_k$$

3. Selecionar a direção seguinte de acordo com a equação:

$$p_k = -g_k + \beta_k p_{k-1}$$

Onde:

$$\beta_k = \frac{\Delta g_{k-1}^T g_k}{g_{k-1}^T g_{k-1}}$$

4. Se o algoritmo neste ponto ainda não convergiu, regressamos a etapa número 2.

Embora seja complexa esta forma modificada do algoritmo backpropagation converge em poucas iterações, e é inclusive um dos algoritmos mais rápidos para redes multicamadas.

3. DESENVOLVIMENTO

Como mencionado anteriormente os modelos foram desenvolvidos para prever 1, 2 e 3 semanas. Os gráficos são sempre analisados em duas etapas. Primeiro a parte do treinamento da rede e sua comparação com os valores esperados juntamente com o gráfico do erro. Na segunda etapa ocorre a validação da rede desenvolvida onde são apresentados os gráficos dos resultados alcançados pela rede e os reais, além do gráfico do erro.

Após os gráficos é exibida uma tabela que mostra a média do erro no treinamento e na validação além do valor total esperado de usuários e o previsto pela rede.

Todas as redes desenvolvidas apresentam a mesma topologia nas camadas intermediárias: 30, 25, 25 com as seguintes funções de ativação: logsig, tansig, logsig.

3.1. PARA 1 SEMANA

A figura 5 exibe a previsão da rede (Saída Calculada) e o real (Saída Desejada). E o figura 6 o erro que mede a diferença entre os valores reais e os valores calculados.




Figura 5 – Treinamento




Figura 6 – Erro treinamento

Nos gráficos 7 e 8 são exibidos a saída da validação e o erro para 1 semana. Observa-se que como para previsão é necessário os cinco dias anteriores o resultado da própria previsão é utilizado na medida que os dias avançam.




Figura 7 – Validação




Figura 8 – Erro da validação

Com os resultados da previsão é feita a soma do total de refeições e comparado o valor com a soma dos valores reais. A tabela 2 exibe os resultados além da média do erro durante o treinamento e a validação.

Tabela 2 – Resultados para previsão de 1 semana.

Média do erro (Refeições)		Total (5 dias)			
Treinamento	Validação	Previsto	Esperado	Erro (Refeições)	% erro
-4,3	-44,9	17124	16900	224	1,32

A previsão para uma semana indicou que 17124 pessoas iriam se alimentar no R.U., mas o verdadeiro valor era de 16900 pessoas, representando um erro de 1,32%.

3.2. PARA 2 SEMANAS

A figura 9 e 10 exibem o mesmo propósito das figuras 5 e 6. Analisar o comportamento do modelo durante o treinamento




Figura 9 – Treinamento




Figura 10 – Erro treinamento

Enquanto nos gráficos 11 e 12 são exibidos a saída da validação e o erro para 2 semanas.




Figura 11 – Validação

Na tabela 3 são exibidos os resultados.

Tabela 3 – Resultados para previsão de 2 semanas.

Média do erro (Refeições)		Total (10 dias)			
Treinamento	Validação	Previsto	Esperado	Erro (Refeições)	% erro
0,92	-107,2	36534	35462	1072	3,0

A previsão para duas semanas indicou que 36534 pessoas iriam se alimentar no R.U., mas o verdadeiro valor era de 36534 pessoas, representando um erro de 3,0%.

3.3. PARA 3 SEMANAS

O modelo mais difícil de ser encontrado foi para previsão de 3 semanas, o principal problema é o fato de o modelo utilizar a previsão de cinco dias anteriores o que acarreta propagação de erros, o que muitas vezes dificulta a convergência. As figuras 13 e 14 exibem os resultados do treinamento.




Figura 12 – Treinamento




Figura 13 – Erro treinamento

Nos gráficos 15 e 16 são exibidos a saída da validação e o erro para 3 semanas.




Figura 15 – Validação




Figura 16 – Erro da validação

A tabela 4 exibe os resultados encontrados para previsão de 3 semanas. Apesar das dificuldades os resultados encontrados a análise do erro mostram que o valor é próximo ao encontrado na rede que prevê uma semana.

Tabela 4 – Resultados para previsão de 3 semanas.

Media do erro (Refeições)		Total (15 dias)			
Treinamento	Validação	Previsto	Esperado	Erro (Refeições)	% erro
1,7	46,8	51785	52488	703	1,34

A previsão para duas semanas indicou que 51785 pessoas iriam se alimentar no R.U., mas o verdadeiro valor era de 52488 pessoas, representando um erro de 1,34%.

Diversas topologias foram testadas variando número de neurônios nas camadas e funções de ativação e apesar desta ter alcançado melhor resultado muitas outras simulações podem ser feitas para aumentar a eficiência da previsão.

4. DISCUSSÃO E CONCLUSÃO

Como o objetivo do trabalho é a previsão em um intervalo de tempo e não em cada dia deste intervalo, os resultados já se mostram satisfatórios para ajudar o R.U. na tomada de decisões para a compra de estoques.

A previsão no intervalo possui como característica importante o fato de que em um dia pode-se errar para mais em outro para menos, o que provoca uma minimização do erro na realização da soma.

O erro máximo na previsão ocorreu em 2 semanas e foi de 3,0%. Para previsões para um período maior de 3 semanas os resultados não foram satisfatórios. Um fator influencia a previsão para períodos maiores é falta de dados, pois o vetor de dados possuía apenas 102 observações. Sendo que deste uma parte é retirada para validar o modelo.

Com os resultados obtidos o modelo será entregue para a coordenação do R.U. para auxiliar na tomada de decisões de compras de estoque de maneira a minimizar a quantidade de alimentos comprados e conseqüentemente o desperdício de alimentos e de energia gasto na armazenagem.

5. REFERÊNCIAS

BRAGA, A. de P.; T.B Ludermir; A. C. P Carvalho. de L. F. *Redes neurais: teoria e aplicações*. São Paulo: Livros Técnicos e Científicos, 2001.

BOCANEGRA, C. W. E. *Procedimento para tornar mais efetivo o uso das redes neurais artificiais em planejamento de transportes*. Tese de mestrado apresentada a Escola de Engenharia de São Carlos.

COUTINHO, Edilma Pinto, MOREIRA, Ricardo Targino, DE SOUZA, Dayane Muniz, *Aplicação do ciclo de serviços na análise da gestão da qualidade de um restaurante universitário*, XXV Encontro Nacional de Engenharia de Produção, Porto Alegre, 2005.

FREIMAN, J. P. e PAMPLONA, E. de O., (2005). *Redes Neurais Artificiais na Previsão do Valor de Commodity do Agronegócio*. V Encuentro Internacional de Finanzas. Santiago, Chile.

HAYKIN, S., (1994). *Neural networks: a comprehensive foundation*. New York, Macmillan College Publishing Company.

MACIEL, J, (2005). *Análise de um sistema de crédito cooperativo através de redes neurais (MLP) com a utilização do algoritmo Levenberg Marquardt*. Tese de mestrado apresentada a UFPR

SATYADAS, A. ; CHEN, H. C., (1994). *An application of intelligent neural network to time series business fluctuation prediction*. IEEE, pp. 3640-3645,.

THE MATHWORKS, Inc (2000). *Neural Network Toolbox*, User's Guide for Use with Matlab.