

# METODOLOGIA PARA PREVISÃO DE DEMANDA DE ENERGIA ELÉTRICA EM CURTÍSSIMO PRAZO BASEADA EM UM MODELO PROBABILÍSTICO DISCRETO

Carlos Vinicius M. Silva<sup>1\*</sup>; William F. Marx<sup>1</sup>; Maurício Sperandio<sup>1</sup>; Daniel P. Bernardon<sup>1</sup>; Gladis Bordin<sup>2</sup>; Sérgio Bordignon<sup>3</sup>

<sup>1</sup> Universidade Federal do Pampa - UNIPAMPA

<sup>2</sup> Universidade Federal do Rio Grande do Sul – UFRGS

<sup>3</sup> Muxfeldt, Marin & Cia. Ltda – MuxEnergia

## 1. Introdução

Conforme [3] existem diversas metodologias para realizar a previsão de demanda de energia elétrica variando-se o intervalo de projeção. Porém, a maioria dessas metodologias aplica-se a sistemas elétricos de médio e grande porte considerando intervalos maiores (dias, semanas, etc.). É evidente que as variáveis climáticas (temperatura, umidade relativa do ar e velocidade do vento) têm influência significativa quanto se considera o curtíssimo prazo como horizonte de projeção, fato que justifica sua incorporação ao modelo previsor.

Um modelo de projeção de curtíssimo prazo que contemple as variáveis climáticas pode ser um modelo probabilístico discreto (cadeia de Markov), porém é necessário se definir os estados e calcular a taxa de transição entre eles. Nesse sentido, a aplicação de um método de classificação aos dados históricos de demanda e variáveis climáticas pode agrupar características similares em um mesmo estado. Como as medidas são observadas em um intervalo definido de tempo, pode-se verificar a transição de um estado para outro a cada intervalo. O Mapa Auto-Organizável ou SOM (Self-Organizing Map) é um método de classificação muito eficiente e robusto que serve perfeitamente para a criação do modelo de Markov desejado.

A metodologia apresentada será aplicada a empresa MUX Energia, distribuidora de energia elétrica com concessão das cidades de Tapejara e Ibiaçá (RS). Essa empresa dispõe da geração de uma pequena central hidroelétrica (PCH) a fio d'água, cujo regime de operação é limitado à pequena capacidade de armazenamento de água do reservatório.

## 2. Projeção de demanda de energia elétrica

No que diz respeito ao planejamento da operação e expansão de sistemas elétricos, a projeção de demanda é realizada nos horizontes de curtíssimo, curto, médio e longo prazo, de acordo com o objetivo do estudo em análise. Assim, projeção de curtíssimo prazo são aquelas projeções com periodicidade de poucos minutos a horas à frente.

### 2.1. Métodos de projeção de curto e curtíssimo prazo

Independente da metodologia e do horizonte de projeção que se pretende realizar o estudo, alguns fatores possuem influência significativa devendo ser incorporados ao modelo de forma a melhorar a precisão da projeção. Os fatores climáticos são de especial interesse, pois a climatização de ambientes e iluminação são diretamente influenciadas por condições de temperatura, umidade e vento, refletindo no comportamento da demanda de energia elétrica.

O conhecimento da tendência de comportamento da carga em um horizonte de curtíssimo prazo pode ser considerado como uma previsão de tempo-real e é utilizada para detectar condições perigosas de operação, além de auxiliar no desenvolvimento de estratégias de oferta de energia por fontes alternativas [4].

Quanto mais curto o horizonte de projeção, maior é a necessidade de precisão e detalhe. Outro requisito, neste horizonte, é a robustez do modelo adotado para a projeção, uma vez que, o modelo deve se adequar rapidamente em situações não usuais.

## 3. A influência das variáveis climáticas sobre o padrão de demanda de energia elétrica

As variáveis climáticas apresentam grande relevância em termos de seus efeitos sobre a demanda de energia elétrica a curtíssimo prazo. Nesse sentido, foi realizado um estudo conjunto dos dados de demanda de energia elétrica e meteorológicos considerando valores reais de carga elétrica, temperatura e umidade, obtidas da base de dados da empresa durante aproximadamente dois anos consecutivos (2008-2009).

---


\* Autor Correspondente: carlosvinicius.ee@gmail.com

Após a consolidação da base de dados, é importante obter e avaliar os perfis de demanda diários. Esta análise auxilia a compreensão do comportamento da demanda de energia elétrica ao longo do tempo. A Fig. 1 ilustra a potência elétrica demandada em uma semana completa, onde não houve nenhum feriado.

Observa-se que nos dias úteis (de segunda a sexta) o perfil da demanda é de certa forma semelhante, e que nos finais de semana esta demanda diminui consideravelmente. Pode-se também observar que a demanda ultrapassou os 8 MW várias vezes ao longo dos dias úteis, com exceção da sexta-feira, e por pouco na terça. Mesmo conhecendo-se o comportamento típico da carga, é difícil prever se a demanda irá atingir um determinado valor. No entanto, é notável a influência das variáveis climáticas, já que a climatização de ambientes é uma carga significativa em praticamente todos os ramos de consumo.

Para verificar a influência das variáveis climáticas em estudo (temperatura, umidade e velocidade do vento) e a demanda de energia elétrica calculou-se a correlação entre elas na base de dados, conforme Tab. 1.

Constata-se que a temperatura é a variável com maior influência na variação da demanda. Também, através da mesma tabela, é notável a relação inversa entre a velocidade do vento e o consumo de energia, explicitada pelo sinal negativo.



**Fig. 1** Padrões de demanda semanal e diária.

	Demanda	Temperat.	Umidade	Vento
Demanda	1,0000	-	-	-
Temperat.	0,2483	1,0000	-	-
Umidade	0,1107	0,1930	1,0000	-
Vento	-0,1602	-0,1062	0,0347	1,0000

**Tab. 1** Correlação entre variáveis climáticas e demanda.

#### 4. Mapas Auto-organizáveis


O Mapa Auto-Organizável ou SOM (Self-Organizing Map) é um tipo de rede neural desenvolvido para reconhecimento de padrões. O algoritmo SOM é definido como uma transformação  $\Phi$  não-linear, que mapeia um espaço de entrada  $E$  contínuo, cuja topologia é definida pela relação métrica dos vetores de dados  $D \in E$ , para um espaço de saída  $S$  discreto, cuja topologia é definida por um conjunto de modelos  $M$  dispostos em uma grade bidimensional, como mostra a Fig. 2 [5]. Normalmente essa rede de neurônios é interligada por conexões sinápticas (pesos) hexagonais.

O algoritmo realiza um processo de ordenação que acontece em três etapas e consiste em encontrar o modelo que melhor represente um dado de entrada na rede (vencedor). As ligações servem para ajustar modelos de neurônios próximos ao vencedor (vizinhos) ao padrão de entrada. Assim, ao final de várias iterações o mapa apresenta os dados associados aos seus neurônios, de forma que padrões similares encontram-se em neurônios contíguos, tendo uma organização topológica. Deste modo é possível se extrair relações abstratas entre as variáveis do vetor de dados através da sua posição nos mapas componentes, que por meio de uma escala de cores mostram a quantidade de uma variável específica em cada neurônio do mapa.

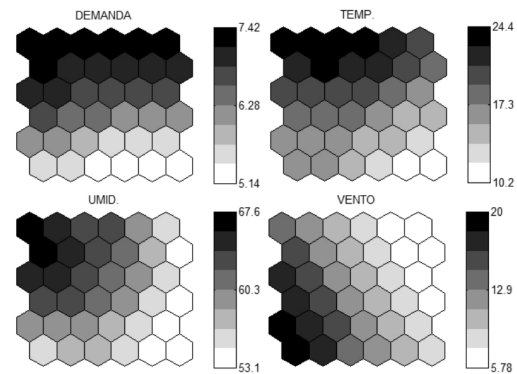
Cada mapa componente é uma representação do mapa treinado com referência a apenas uma das variáveis envolvidas, sendo assim, a posição dos neurônios é a mesma em todos os mapas componentes, o que permite a identificação de correlações entre variáveis. Mapas componentes similares indicam variáveis com correlação forte.

Mapas pequenos, com menos de um neurônio para cada dez dados de entrada, possuem pouco espaço para revelar relações topológicas. Todavia formam grupos bem definidos, apesar da distância entre os dados contidos em cada neurônio ser um tanto significativa. A Fig. 3 apresenta os mapas componentes para a classificação de 3.290 medidas horárias de demanda, temperatura, umidade do ar e velocidade do vento em uma rede com 36 neurônios (6x6). A cor preta indica os maiores valores, enquanto o branco os menores. A escala ao lado do mapa indica o valor médio das variáveis, demanda em MW, temperatura em °C, umidade em % e velocidade do vento em m/s.

Na Fig. 3 é possível se identificar algumas relações entre as variáveis, como por exemplo, no canto superior esquerdo, tem-se alta demanda, alta temperatura, alta umidade e vento intermediário. Já no canto inferior esquerdo, onde predominam as velocidades de vento maiores, verifica-se uma baixa demanda. No caso de mapas maiores, com uma maior relação de neurônios por dado de entrada, se obtém uma maior dispersão topológica capaz de revelar relações entre variáveis que não aparecem em dimensões menores.



**Fig. 2** Uma transformação  $\Phi : E \rightarrow S$  em uma mapa 4x4 com conexões hexagonais.



**Fig. 3** Mapas componentes 6x6 para as quatro variáveis estudadas.

## 5. Modelo de Markov

Um modelo de Markov representa um processo estocástico, geralmente com estados discretos e contínuos no tempo, em que o sistema é modelado a partir de parâmetros observáveis. A proposta então é que este modelo possa ser usado para realizar análises da evolução dos estados ao longo do tempo. Parte-se do princípio de que os estados anteriores são irrelevantes para a predição dos estados seguintes, desde que o estado atual seja conhecido [1].

Uma cadeia de Markov é uma sequência  $X_1, X_2, X_3, \dots$  de variáveis aleatórias. O escopo destas variáveis, isto é, o conjunto de valores que elas podem assumir, é chamado de espaço de estados, onde  $X_n$  denota o estado do processo no tempo  $n$ . Se a distribuição de probabilidade condicional de  $X_{n+1}$  nos estados passados é uma função apenas de  $X_n$ , então:

$$P_r(X_{n+1} = x | X_0, X_1, X_2, \dots, X_n) = P_r(X_{n+1} = x | X_n) \quad (1)$$

Se o modelo está em um estado  $y$  no tempo  $n$ , então a probabilidade de que se mova para o estado  $X$  no tempo  $n+1$  não depende de  $n$ , e somente depende do estado atual  $y$  em que se está. Assim em qualquer tempo  $n$ , uma cadeia de Markov finita pode ser caracterizada por uma matriz de probabilidades cujo elemento  $(x, y)$  é dado por (2) e é independente do tempo  $n$ .

Um espaço de estados é representável por uma matriz de transição, com o  $(i, j)$ -ésimo elemento igual a (3).

$$P_r(X_{n+1} = x | X_n = y) \quad (2)$$

$$P_{ij} = P_r(X_{n+1} = j | X_n = i) \quad (3)$$

Para um espaço de estados discretos, as integrações na probabilidade de transição de  $k$  passos são somatórios, e podem ser calculados como a  $k$ -ésima potência da matriz de transição. Isto é, se  $P$  é a matriz de transição para um passo, então  $P_k$  é a matriz de transição para a transição de  $k$  passos.

Na medida em que o tempo avança, os valores de probabilidade de se encontrar cada um dos estados tendem a um valor limite constante. Portanto, esses valores de probabilidade limite são independentes do tempo, e a soma resulta em 1.

### 5.1. Exemplo de um modelo de previsão de demanda

Em um exemplo bem simples, se observado que a demanda é baixa em uma determinada hora, a probabilidade de que ela será alta na próxima hora é 0,5. Se a demanda é alta, de outra forma, a probabilidade dela ser baixa na hora seguinte é igual a 0,25.

As transições entre demandas alta e baixa podem ser modeladas como uma cadeia homogênea de Markov, e a matriz de transição de probabilidade é dada pela Tab. 3.

Quando o número de estados é pequeno, é conveniente representar um diagrama de transições como o da Fig. 4.

Carga	Baixa	Alta
Baixa	0,50	0,50
Alta	0,25	0,75

**Tab. 3** Exemplo de uma matriz de transição ( $P$ ) para dois estados de demanda.



**Fig. 4** Diagrama de estados de uma cadeia de Markov com a matriz de transição da Tab. 3.

Definido o modelo e a matriz de transições P, pode-se então calcular a probabilidade do sistema estar em um estado após um determinado número de intervalos de tempo com a seguinte equação:

$$P(n) = P(0) \cdot P^n \quad (4)$$

Assim, por exemplo, conhecendo-se o estado atual como de demanda baixa, as probabilidades do sistema estar em cada estado após quatro intervalos de tempo são definidas da seguinte forma:

$$P(4) = \begin{bmatrix} 1 & 0 \end{bmatrix} \cdot \begin{bmatrix} 0,5 & 0,5 \\ 0,25 & 0,75 \end{bmatrix}^4 = \begin{bmatrix} 0,334 & 0,666 \end{bmatrix}$$

Ou seja, dado que o sistema estava com demanda baixa, após quatro intervalos de tempo (horas), a probabilidade da demanda ser baixa é de 33,4% e de ser alta é de 66,6%.

## 7. Conclusão

O Mapa Auto-Organizável permite a criação de um modelo de Markov a partir da análise de um banco de dados com medidas sequenciais. Neste caso, foi desenvolvida uma ferramenta de suporte a decisão para o operador de uma PCH, que determina a probabilidade da demanda ultrapassar um determinado nível nas próximas horas em função de medidas de variáveis climáticas. Com isso, a concessionária evita o pagamento de multas por meio do despacho da PCH nos momentos críticos, já que o reservatório não é suficiente para sustentar a geração por muito tempo, e em épocas de seca pode ser preciso acumular água durante um período de várias horas.

## Referências

- [1] BILLINTON, R. and ALLAN, R. N. (1996). Reliability evaluation of power systems, New York, Plenum Press.
- [2] BOX, G. E. P., JENKIS, G. M. and REINCEL, G. (1994). Time Series Analysis: Forecasting and Control, Prentice Hall.
- [3] CAMPOS, R. J. (2008). Previsão de series temporais com previsão de séries de consumo de energia elétrica. Dissertação de Mestrado, UFMG.
- [4] DANESHI, H. and DANESHI, A. (2008). Real Time Load Forecast in Power System. The 3th Int. Conf. of Deregulation and Restructuring and Power Technology. Nanjing, China.
- [5] HAYKIN, S. S. (1999). Neural networks: a comprehensive foundation, Upper Saddle River, N.J., Prentice Hall.
- [6] NOSE FILHO, K. , LOTUFO, A. D. P. and LOPES, M. L. (2008). Utilização de Redes Neurais Artificiais e Redes Neuro-Fuzzy para previsão de cargas elétricas. 7º Brazilian Conference on Dynamics, Control and Applications. São Paulo, Brazil.
- [7] PAPALEXOPOULOS, D., HAO, S. and PENG, T. M. (1994). An Implementation of a Neural Network based load forecasting model for the EMS. IEEE Trans. on Power System, Vol.9, No.4, pp. 1956-1962.
- [8] SPERANDIO, M. and COELHO, J. (2006). Constructing Markov Models for Reliability Assessment with Self-Organizing Maps. Int. Conf. on Probabilistic Methods Applied to Power Systems. Stockholm, Sweden.

## Agradecimentos

Os autores agradecem o apoio técnico e financeiro da concessionária de energia elétrica MuxEnergia, por meio do projeto de Pesquisa & Desenvolvimento intitulado “Desenvolvimento de Algoritmos e Software para Previsão de Carga na Área de Concessão da MuxEnergia - Horizonte de Curtíssimo Prazo”.