



ANÁLISE DE DEMANDA VIA INTELIGÊNCIA ARTIFICIAL NO RESTAURANTE UNIVERSITÁRIO DO INSTITUTO DE CIÊNCIA E TECNOLOGIA DA UNIFESP

Douglas Diniz Landim, ddlandim@unifesp.br

RA 76681

Ciência da Computação.

Trabalho de Conclusão de Curso - Parte 1

Orientador: Prof. Dr. Vinicius Veloso

Agradecimentos

Minha jornada pela graduação foi marcada por muita persistência, dificuldades e fracassos. Agradeço primeiramente a Deus por me dar fé e alimentar minha persistência e esperança. Apesar de todo o conteúdo técnico das mais de 40 disciplinas do meu curso, o que mais me agregou aprendizado foi o ambiente desafiador desta universidade; que somado à muitas dificuldades pessoais, acidentes, contratempos de saúde, profissão e família; constituiu o conjunto perfeito de desafios que me derrubaram muitas vezes e me fizeram ser uma pessoa melhor ao me levantar, mais convicto e perseverante a cada nova tentativa de conquistar minhas aprovações. Agradeço à minha família por sempre me apoiar dando tudo de si, a meu professor por me aceitar orientar, e me motivar sempre me dando atenção como um amigo nas conversas no fim da aula durante o caminho até o estacionamento da faculdade, nas reuniões e chats online até nos finais de semana, aos amigos universitários, e a todos os professores que me acompanharam e ofereceram desafios em todos esses anos na UNIFESP.

Evolução do trabalho:

https://github.com/ddlandim/monografy-ann-demand-prediction/graphs/contributors



ssoal profissional Importado do Firefox monografy-ann-dem ScrumHalf - Painei Segredos Unifesp FINANÇAS REP POR / >> Outros f

Oct 21, 2018 – Dec 4, 2018

Contributions: Commits ▾

Contributions to master, excluding merge commits



ddlandim

#1

22 commits 447,892 ++ 4,121 --



Motivação

428.620 refeições subsidiadas no banco de dados do sistema antigo, no período de 2011 à 2016.

111.454 refeições no período de 2017 a 01/08/2018 que fecham o modelo de contrato antigo.

Valor pago em cada refeição pela UNIFESP: R\$9,14. Total investido: R\$4.936.276,36

Valor pago pelo aluno: R\$2,50 pelo aluno. Total investido R\$1.350.185,00.

Movimentação do restaurante: R\$6.286.461,36

Já neste atual 2o semestre de 2018, iniciando em 01/08/2018 à 31/10/2018, o valor total subsidiado pela universidade é de R\$179.019,52, R\$82.270,00 pelos alunos e o faturamento bruto acumulado pelo restaurante é de R\$261.289,52

Referencias:

Total de refeições: ti.sjc@unifesp.br (Francismar / Fiscal de Contrato do R.U)

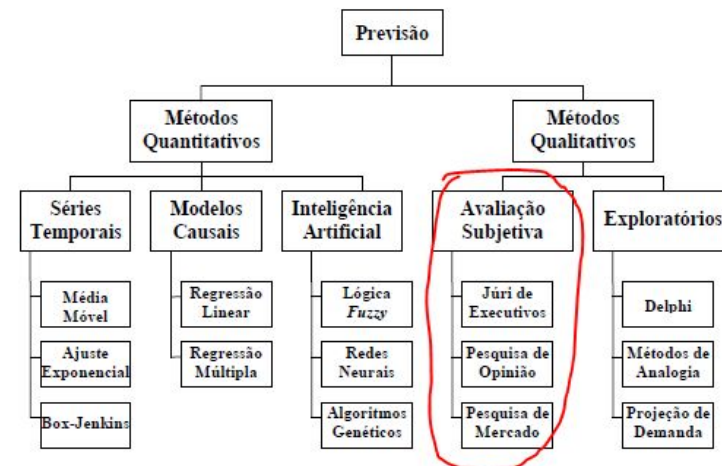
Valores por refeição: Ederson Barroso, ederbarroso@gmail.com , gerente nutrimenta.



Desperdício

ATUALMENTE O RESTAURANTE NÃO TEM NENHUM MODELO PREDITIVO.

- MÉTODOS SUBJETIVOS
- ANÁLISE DOS DIAS ANTERIORES



Fonte: Adaptado de [SIL03] e [SIL02]

Retirado de Junior, 2007. Análise de previsão de demanda baseado em séries temporais em uma empresa do setor de perfumes e cosméticos.

Trabalhos anteriores

DATA VENDAS TEMPERATURA

10/08/16	316	18
17/08/16	303	28
24/08/16	291	23
07/09/16	310	21
14/09/16	381	27.5
21/09/16	291	20
28/09/16	291	24

TABELA 1

Histogram of t







GRÁFICO 2

GRÁFICO 2: Cálculo bootstrap de 1000 reamostragens t da TABELA 1 em função da densidade. Intervalo de confiança obtido por Bca: 95% (-0.8666, 0.9290), outras estatísticas obtidas pela biblioteca: Original: 0.4040055, Biais: -0.148679, Erro padrão: 0.51477

DATA VENDAS TEMPERATURA

28/09/16	291	27
05/10/16	284	21
19/10/16	78	35
26/10/16	277	30
09/11/16	274	31

Histogram of t



SUMÁRIO

Sumário

1	Introdução	21
1.1	Contextualização e Motivação	21
1.2	Definição do problema	22
1.3	Justificativas	22
1.4	Objetivos	22
1.4.1	Objetivo geral	22
1.4.2	Objetivos específicos	23
1.5	Metodologia	23
1.6	Organização do documento	24
2	Fundamentação Teórica	25
2.1	Introdução	25
2.2	Análises Estatísticas	26
2.2.1	Análise Exploratória dos Dados	26
2.2.2	Métodos de Previsão	26
2.2.3	Métodos de previsão de Demanda	27
2.2.4	Séries Temporais	28
2.2.5	Componentes Temporais	28
2.2.6	Previsão com Regressão Linear Múltipla	29
2.2.7	Algoritmo de Regressão Linear Múltipla	31
2.3	Inteligência Artificial	31
2.3.1	Neurônio Artificial	31
2.3.2	Redes Neurais Artificiais	34
2.3.3	Funcionamento e treino do neurônio perceptron	36
2.3.4	Limite de um Perceptron	42
2.3.5	Rede Perceptrons Múltiplas Camadas - MLP	43
2.3.6	Perceptrons Múltiplas Camadas com Retro Propagação de Erro	46
2.3.7	Treino da MLP - BackPropagation para 1 sinal de saída	48
2.3.8	Algoritmo de treino e validação backpropagation	53
3	Trabalhos relacionados	55
3.0.1	ANÁLISES EM RESTAURANTES UNIVERSITÁRIOS	55
3.0.2	ANÁLISES EM OUTROS CENÁRIOS	56
3.0.3	TESES COMPARATIVAS DE DIVERSOS MÉTODOS DE PREVISÃO DE DEMANDA	56

4	Plano de atividades para o TCC II	59
4.1	Dados	60
4.1.1	Dados de Consumo e de Data	61
4.1.2	Dados Climáticos	63
4.1.3	Estruturação dos Dados	64
5	Conclusão	67
	Referências	69

Principais referências de heurísticas de previsão de demanda.

ALBINO MILESKI JUNIOR


ANÁLISE DE MÉTODOS DE PREVISÃO DE DEMANDA BASEADOS EM SÉRIES TEMPORAIS EM UMA EMPRESA DO SETOR DE PERFUMES E COSMÉTICOS

Dissertação apresentada ao Programa de Pós-Graduação em Engenharia de Produção e Sistemas da Pontifícia Universidade Católica do Paraná como requisito parcial para obtenção do título de Mestre em Engenharia de Produção e Sistemas.

CURITIBA
2007



Figura 2.3: Esquema do trabalho.



Fonte: Adaptado de [SIL03] e [SIL02]

Figura 3.4: Métodos para previsão da demanda.

Principais referências de modelos estatísticos.

Modelos de Regressão

Clarice Garcia Borges Demétrio

Departamento de Ciências Exatas, ESALQ, USP

Caixa Postal 9

13418-900 Piracicaba, SP

Email: Clarice@carpa.ciagri.usp.br

Fax: 019 34294346

Sílvio Sandoval Zocchi

Departamento de Ciências Exatas, ESALQ, USP

Caixa Postal 9

13418-900 Piracicaba, SP

Email: sszocchi@carpa.ciagri.usp.br

Fax: 019 34294346

29 de março de 2011

y	x_1	x_2	\dots	x_p
y_1	x_{11}	x_{12}	\dots	x_{1p}
y_2	x_{21}	x_{22}	\dots	x_{2p}
\vdots	\vdots	\vdots	\vdots	\vdots
y_n	x_{n1}	x_{n2}	\dots	x_{np}

Tabela 2.2.1: Representação dos dados.

$$\hat{\beta} = (X'X)^{-1}X'Y.$$

Notemos que os estimadores de mínimos quadrados dos parâmetros do "Modelo 2.2" podem ser facilmente encontrados considerando a notação matricial dos dados, que é de fácil manipulação. Desta forma, considerando a entrada de dados apresentada na Tabela 2.2.1, o modelo de Regressão Linear Múltipla pode ser escrito como

$$Y = X\beta + \varepsilon,$$

com

$$Y = \begin{bmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_n \end{bmatrix}, \quad X = \begin{bmatrix} 1 & x_{11} & x_{12} & \dots & x_{1p} \\ 1 & x_{21} & x_{22} & \dots & x_{2p} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & x_{n2} & \dots & x_{np} \end{bmatrix}, \quad \beta = \begin{bmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_p \end{bmatrix} \quad \text{e} \quad \varepsilon = \begin{bmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{bmatrix},$$

em que

- Y é um vetor $n \times 1$ cujos componentes corresponde às n respostas;
- X é uma matriz de dimensão $n \times (p + 1)$ denominada matriz do modelo;
- ε é um vetor de dimensão $n \times 1$ cujos componentes são os erros e
- β é um vetor $(p + 1) \times 1$ cujos elementos são os coeficientes de regressão.

O método de mínimos quadrados tem como objetivo encontrar o vetor $\hat{\beta}$ que minimiza

$$\begin{aligned} L &= \sum_{i=1}^n \varepsilon_i^2 = \varepsilon' \varepsilon = (Y - X\beta)'(Y - X\beta) = \\ &= Y'Y - Y'X\beta - \beta'X'Y + \beta'X'X\beta = Y'Y - 2\beta'X'Y + \beta'X'X\beta, \end{aligned}$$

sendo que $Y'X\beta = \beta'X'Y$ pois o produto resulta em um escalar. A notação X' representa o transposto da matriz X enquanto que Y' e β' representam os transpostos dos vetores Y e β , respectivamente. Usando a técnica de derivação (em termos matriciais) obtemos

$$\frac{\partial L}{\partial \beta} = -2X'Y + 2X'X\beta.$$

Principais referências de modelos de inteligência artificial em R.U.



MODELOS PARA PREVISÃO DE DEMANDA NO RESTAURANTE UNIVERSITÁRIO UTILIZANDO TÉCNICAS DE REDES NEURAIS

Liliane Lopes Cordeiro (DMA - UFV)
lililopescordeiro@yahoo.com.br
Heverton Augusto Pereira (Unicamp)
hevertonaugusto@yahoo.com.br

Resumo

Um dos grandes problemas enfrentados hoje no mundo é a elevação dos preços dos alimentos. Isto tem causado preocupações para a população em geral e também para as empresas como restaurantes que sofrem diretamente os reflexos da variação no preço dos alimentos. Atualmente o Restaurante Universitário (R.U.) da Universidade Federal de Viçosa não possui um sistema que ajude na gestão de compras dos alimentos. O objetivo deste trabalho é utilizar a técnica de Redes Neurais Artificiais do tipo MLP (Perceptron Múltiplas Camadas) para fazer a predição do número de usuários que irão fazer suas refeições no R.U. em uma, duas e três semanas para a administração poder determinar a política de compras de alimentos. As redes desenvolvidas utilizam o dia da semana e os cinco dias anteriores ao que se deseja prever. Para validar os modelos propostos foram separados conjuntos de dados para realização de comparações e análises da eficácia da nova forma de gestão das compras.

Abstract

Nowadays, one of the major problems in the world is the rising of food prices. The problem concerns general population and also businesses such as restaurants that suffer directly the consequences of changes in the food prices. Currently the University Restaurant (R.U.), at Federal University of Viçosa does not have a system that helps in the management to buy food. This work uses the technique of Artificial Neural Networks MLP type (Multiple Layers Perceptron) to predict the number of users who will have their meals in the R.U. in one, two and three weeks to support the administration's decision of food storing. The developed networks have as input variables: day of the week and the previous five days until the day that want to predict. Different data were used to validate the models through comparisons and analysis of the new management food buying benefits.

Palavras-chaves: Redes Neurais Artificiais, Previsão, Gestão




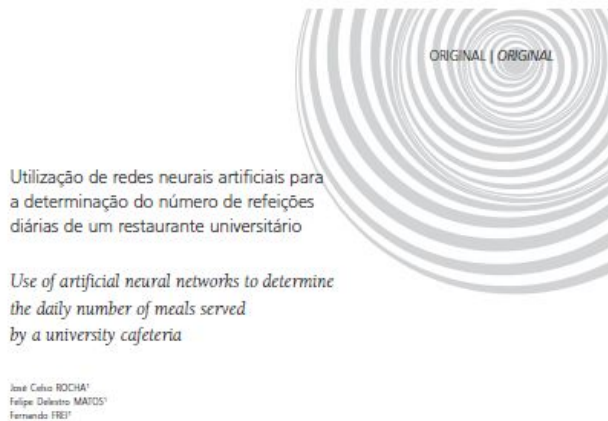
Figura 4 – Entradas e saída da rede proposta

Media do erro (Refeições)		Total (5 dias)			
Treinamento	Validação	Previsto	Esperado	Erro (Refeições)	% erro
-4,3	-44,9	17124	16900	224	1,32

Media do erro (Refeições)		Total (10 dias)			
Treinamento	Validação	Previsto	Esperado	Erro (Refeições)	% erro
0,92	-107,2	36534	35462	1072	3,0

Media do erro (Refeições)		Total (15 dias)			
Treinamento	Validação	Previsto	Esperado	Erro (Refeições)	% erro
1,7	46,8	51785	52488	703	1,34

Principais referências de modelos de inteligência artificial em R.U.



RESUMO

Objetivo

Construir uma rede neural artificial para auxiliar os gestores de restaurantes universitários na previsão de refeições diárias.

Métodos

O estudo foi desenvolvido a partir do levantamento de oito variáveis que influenciam o número de refeições diárias servidas no restaurante universitário. Utiliza-se o algoritmo de treinamento backpropagation. Os resultados por meio da rede são comparados com os da série estudada e com resultados da estimativa por média aritmética simples.

Resultados

A rede proposta acompanha as inúmeras alterações que ocorrem no número de refeições diárias do restaurante universitário. Em 73% dos dias analisados, o método das redes neurais artificiais apresenta uma taxa de acerto maior do que o método da média aritmética simples.

Conclusão

A rede neural artificial mostrou-se mais adequada para a previsão do número de refeições do que a metodologia de média simples ou quando a decisão do número de refeições é feita de forma subjetiva, sem critérios científicos.

Termos de Indexação: Desperdício de alimentos. Redes neurais artificiais. Serviços de alimentação.

¹ Universidade Estadual Paulista "Júlio de Mesquita Filho", Faculdade de Ciências e Letras, Curso de Engenharia Biotecnológica, Departamento de Ciências Biológicas, Av. Dom Antônio, 2.100, 14060-900, Araraquã, SP, Brasil. Correspondência para/Correspondence to: J.C. Rocha. E-mail: jcarocha@unesp.br

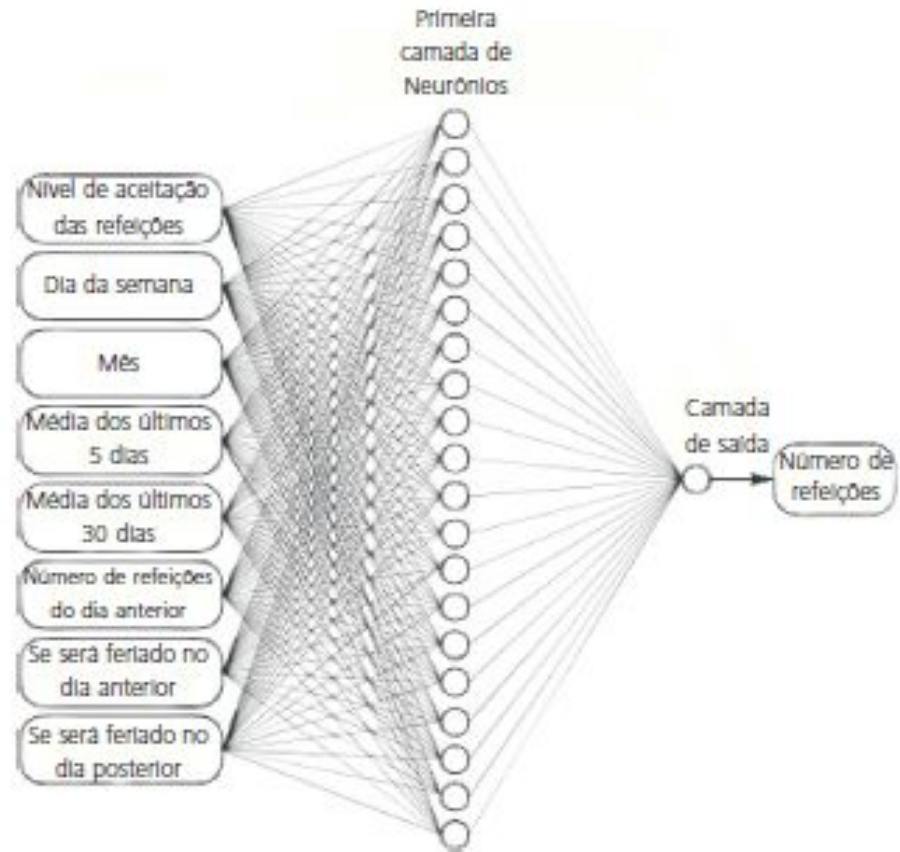



Figura 1. Arquitetura da rede neural artificial.

Principais referências de modelos de inteligência artificial em R.U.



RESUMO

Objetivo

Construir uma rede neural artificial para auxiliar os gestores de restaurantes universitários na previsão de refeições diárias.

Métodos

O estudo foi desenvolvido a partir do levantamento de oito variáveis que influenciam o número de refeições diárias servidas no restaurante universitário. Utiliza-se o algoritmo de treinamento backpropagation. Os resultados por meio da rede são comparados com os da série estudada e com resultados da estimativa por média aritmética simples.

Resultados

A rede proposta acompanha as inúmeras alterações que ocorrem no número de refeições diárias do restaurante universitário. Em 73% dos dias analisados, o método das redes neurais artificiais apresenta uma taxa de acerto maior do que o método da média aritmética simples.

Conclusão

A rede neural artificial mostrou-se mais adequada para a previsão do número de refeições do que a metodologia de média simples ou quando a decisão do número de refeições é feita de forma subjetiva, sem critérios científicos.

Termos de indexação: Desperdício de alimentos. Redes neurais artificiais. Serviços de alimentação.

¹ Universidade Estadual Paulista "Júlio de Mesquita Filho", Faculdade de Ciências e Letras, Curso de Engenharia Biotecnológica, Departamento de Ciências Biológicas, Av. Dom Antônio, 2.100, 14060-900, Avai, SP, Brasil. Correspondência para/Correspondence to: J.C. ROCHA. E-mail: gpedelencio@unesp.br




Figura 3. Desempenho da rede neural artificial em comparação ao número de refeições reais.

Para o estudo em pauta, o erro geral obtido pela metodologia da RNA foi de 9,5%.

Principais referências de previsão em outros cenários.

Previsão de Demanda de Energia Elétrica Utilizando Redes Neurais Artificiais e Support Vector Regression

Gabriel I. S. Ruas¹, Ticiano A. C. Bragatto¹, Marcus V. Lamar², Alexandre R. Aoki³, Silvio Michel de Rocco⁴

¹Departamento de Engenharia Elétrica – Universidade Federal do Paraná (UFPR)
Caixa Postal 19011 – 81531-990 – Curitiba – PR – Brazil

²Departamento de Ciências da Computação – Universidade de Brasília (UnB)
Caixa Postal 4466 – 70919-970 – Brasília – DF – Brazil.

³Instituto de Tecnologia para o Desenvolvimento (LACTEC)
Caixa Postal 19067 – 81531-980 – Curitiba – PR – Brazil.

⁴Copel Distribuição S/A (COPEL)
Rua José Izidoro Biazetto, 158 – Bloco C – 81200-240 – Curitiba – PR – Brazil.

{bragatto@ufpr.br, gabrielruas@gmail.com, lamar@unb.br,
aoki@lactec.org.br, rocco.silvio@copel.com}

Abstract. This paper describes a short time electrical energy demand forecast system using two different techniques of Artificial Intelligence: Recurrent Artificial Neural Networks and Support Vector Regression. A brief analysis of the demand over the electrical energy network connection points is also done.

Resumo. Este artigo descreve um sistema de previsão da demanda de energia a curto prazo utilizando duas técnicas diferentes de inteligência artificial: Redes neurais artificiais recorrentes e support vector regression. Também foi feita uma breve análise do perfil de demanda dos pontos de conexão da rede de energia elétrica.




Figura 2-Demanda em duas semanas consecutivas




Figura 6 – Estrutura geral da rede Elman

Principais referências de previsão em outros cenários.

METODOLOGIA PARA PREVISÃO DE DEMANDA DE ENERGIA ELÉTRICA EM CURTISSIMO PRAZO BASEADA EM UM MODELO PROBABILÍSTICO DISCRETO

Carlos Vinicius M. Silva^{1*}; William F. Marx¹; Mauricio Sperandio¹; Daniel P. Bernardon¹; Gladis Bordin²; Sérgio Bordignon³

¹ Universidade Federal do Pampa - UNIPAMPA

² Universidade Federal do Rio Grande do Sul – UFRGS

³ Muxfeldt, Marin & Cia. Ltda – MuxEnergia




Fig. 1 Padrões de demanda semanal e diária.

	Demanda	Temperat.	Umidade	Vento
Demanda	1,0000	-	-	-
Temperat.	0,2483	1,0000	-	-
Umidade	0,1107	0,1930	1,0000	-
Vento	-0,1602	-0,1062	0,0347	1,0000

Tab. 1 Correlação entre variáveis climáticas e demanda.




Fig. 2 Uma transformação $\Phi: E \rightarrow S$ em uma mapa 4x4 com conexões hexagonais.




Fig. 3 Mapas componentes 6x6 para as quatro variáveis estudadas.

Principais referenciais teóricos.

ALBINO MILESKI JUNIOR

ANÁLISE DE MÉTODOS DE PREVISÃO DE
DEMANDA BASEADOS EM SÉRIES
TEMPORAIS EM UMA EMPRESA DO SETOR
DE PERFUMES E COSMÉTICOS

Dissertação apresentada ao Programa de Pós-
Graduação em Engenharia de Produção e Sistemas
da Pontifícia Universidade Católica do Paraná como
requisito parcial para obtenção do título de Mestre
em Engenharia de Produção e Sistemas.


CURITIBA
2007



FLÁVIA CRISTINA MARTINS QUEIROZ MARIANO

REDES NEURAIS NA PREDIÇÃO DE
VALORES ENERGÉTICOS DE
ALIMENTOS PARA AVES

LAVRAS - MG
2014



Dados extraídos, T.I.

RU_CONSULTA_POR PERÍODO_31.10.2018 - Copia.xls - LibreOffice Calc

Arquivo Editar Exibir Inserir Formatar Estilos Planilha Dados Ferramentas Janela Ajuda



A1 DATA

	A	B	C	D	E	F	G
1	DATA	TODOS ALMOÇO	TODOS JANTAR	TODOS REFEIÇÃO*	ALUNOS ALMOÇO	ALUNOS JANTAR	TOTAL ALUNOS
2	(31/10/2018)	395	0	395	362	0	362
3	(30/10/2018)	667	0	667	437	256	693
4	(29/10/2018)	511	0	511	293	185	478
5	(26/10/2018)	241	4	245	263	63	326
6	(25/10/2018)	458	0	458	402	0	402
7	(24/10/2018)	508	0	508	382	228	610
8	(23/10/2018)	557	0	557	203	272	475
9	(22/10/2018)	620	0	620	323	201	524
10	(19/10/2018)	38	0	38	49	1	50
11	(18/10/2018)	143	0	143	138	3	141
12	(17/10/2018)	253	2	255	188	72	260
13	(16/10/2018)	195	4	199	165	45	210
14	(15/10/2018)	172	0	172	110	28	138
15	(11/10/2018)	443	3	446	355	152	507
16	(10/10/2018)	501	3	504	387	196	583
17	(09/10/2018)	707	0	707	411	270	681
18	(08/10/2018)	581	0	581	287	221	508
19	(05/10/2018)	233	18	251	216	80	296

Dados extraídos, T.I.

BDMEP - Série Histórica - Dados Diários

Período - Data início (dd/mm/aaaa) : 01/01/2017

fim : 31/10/2018

Região : Todas (OU) Estado : Todos

Selecionar Variáveis :

☒ Precipitação(mm)

☒ Temp Máxima(°C)

☒ Insolação(horas)

☒ Evaporação do Piche(mm)

☒ Umidade Relativa Média(%)

☒ Temp Mínima(°C)

☒ Temperatura Compensada Média(°C)

☒ Velocidade Vento Média(mps)

Pesquisa

Umididade Relativa Media											
	A	B	C	D	E	F	G	H	I	J	K
1	Estacao	Data	Hora	Precipitacao	TempMaxima	TempMinima	Insolacao	Evaporacao Piche	Temp Comp Media	Umidade Relativa Media	Velocidade do Vento Media
1076		83781 22/06/2018	0		24.6		5.1	5.3	19.12	59.75	1.733333
1077		83781 22/06/2018	1200	0		15					
1078		83781 23/06/2018	0		26.4		6.8		4 20.28	60.25	1.866667
1079		83781 23/06/2018	1200	0		14.6					
1080		83781 24/06/2018	0		28.5		7.4	4.4	20.72		67 2.1
1081		83781 24/06/2018	1200	0		17.5					
1082		83781 25/06/2018	0		27.2		8.4	3.1	21.14	51.25	1.9
1083		83781 25/06/2018	1200	0		15.9					
1084		83781 26/06/2018	0		26.5		2.5		8 21.46		45 1.633333
1085		83781 26/06/2018	1200	0		16.6					
1086		83781 27/06/2018	0		23.4		7.3		6 18.62	70.75	1.9
1087		83781 27/06/2018	1200	0		15.5					
1088		83781 28/06/2018	0			26	5.2		3 19.58		70 1.6
1089		83781 28/06/2018	1200	0		15.2					
1090		83781 29/06/2018	0		26.4		8.5	3.5	20.06	57.5	1.966667
1091		83781 29/06/2018	1200	0		14.7					
1092		83781 30/06/2018	0		26.8		6.6	4.7	20.18		72 0.666667
1093		83781 30/06/2018	1200	0		15.1					
1094		83781 01/07/2018	0		27.4		7.9		20.56	61.5	0.51444
1095		83781 01/07/2018	1200	0		15					
1096		83781 02/07/2018	0		27.3		7.9		20.9	50.5	1.37184
1097		83781 02/07/2018	1200	0		15					
1098		83781 03/07/2018	0		24.7		5.9		18.72		78 2.5722
1099		83781 03/07/2018	1200	0		16.2					
1100		83781 04/07/2018	0		23.7		5.7		17.96	83.75	2.5722
1101		83781 04/07/2018	1200	0		15.6					
1102		83781 05/07/2018	0		26.5		6.2		18.76		67 1.37184

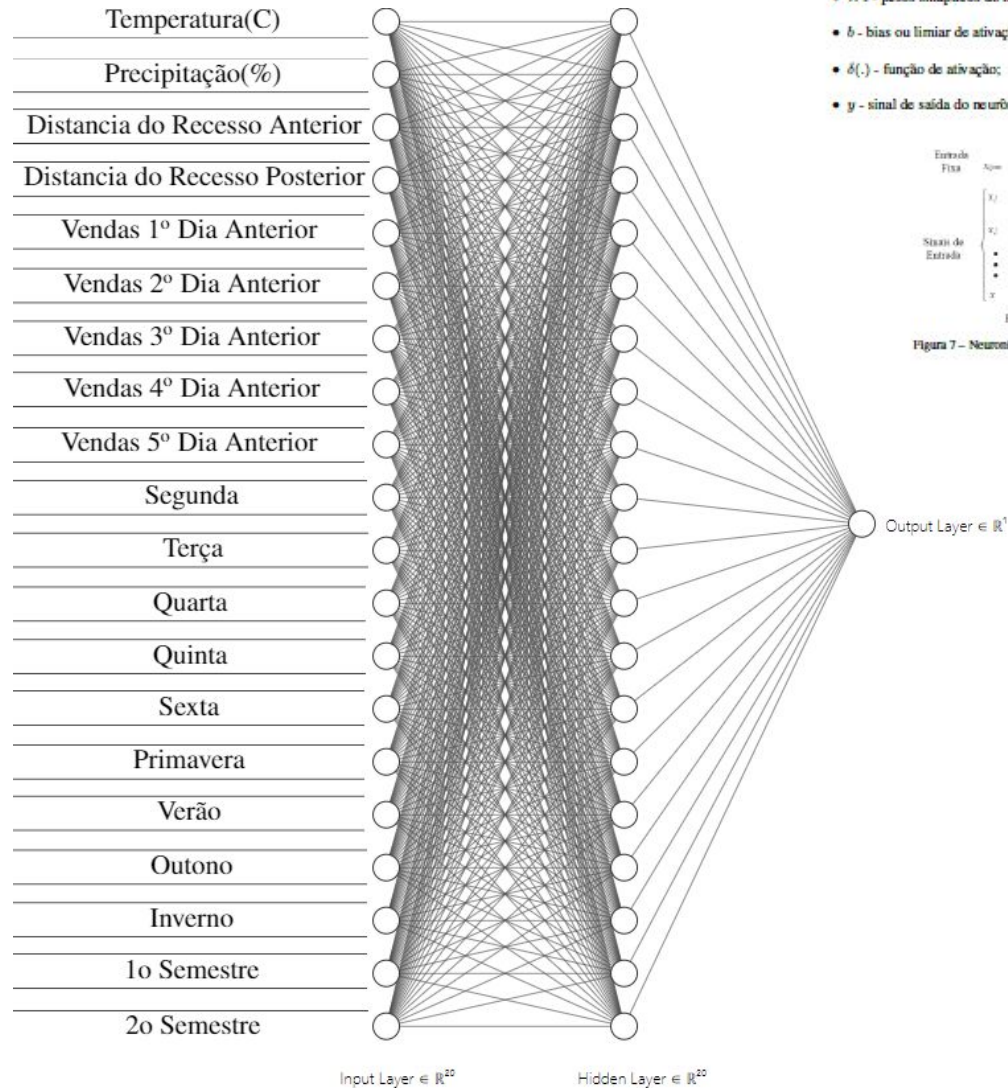
Dados estruturados.

Tabela 4 – Tabela de dados do R.U.

	26/02/2018	27/02/2018
VENDAS - Y_i	446	470
PARAMETROS X_i		
Temperatura(C)	27.2	28.5
Precipitação(%)	88	84
Distancia do Recesso Anterior	1	2
Distancia do Recesso Posterior	4	3
Vendas 1º Dia Anterior	0	446
Vendas 2º Dia Anterior	0	0
Vendas 3º Dia Anterior	0	0
Vendas 4º Dia Anterior	0	0
Vendas 5º Dia Anterior	0	0
Segunda	1	0
Terça	0	1
Quarta	0	0
Quinta	0	0
Sexta	0	0
Primavera	0	0
Verão	1	1
Outono	0	0
Inverno	0	0
1o Semestre	1	0
2o Semestre	1	0

$$Y = \begin{bmatrix} 446 \\ 470 \end{bmatrix} \quad X = \begin{bmatrix} 27.2 & 88 & 1 & 4 & 0 & 0 & 0 & 0 & 1 & 0 & 0 & 0 & 0 & 1 & 0 & 0 & 1 & 1 \\ 28.5 & 84 & 1 & 4 & 446 & 0 & 0 & 0 & 0 & 0 & 1 & 0 & 0 & 0 & 0 & 1 & 0 & 0 & 1 & 1 \end{bmatrix}$$

Modelo proposto.



O sinal de saída do perceptron entende-se então por: $y = \delta(\sum_{i=1}^n X_i W_i + b)$

- X_i - sinais de entrada do neurônio;
- W_i - pesos sinápticos do neurônio;
- b - bias ou limiar de ativação;
- $\delta(\cdot)$ - função de ativação;
- y - sinal de saída do neurônio.



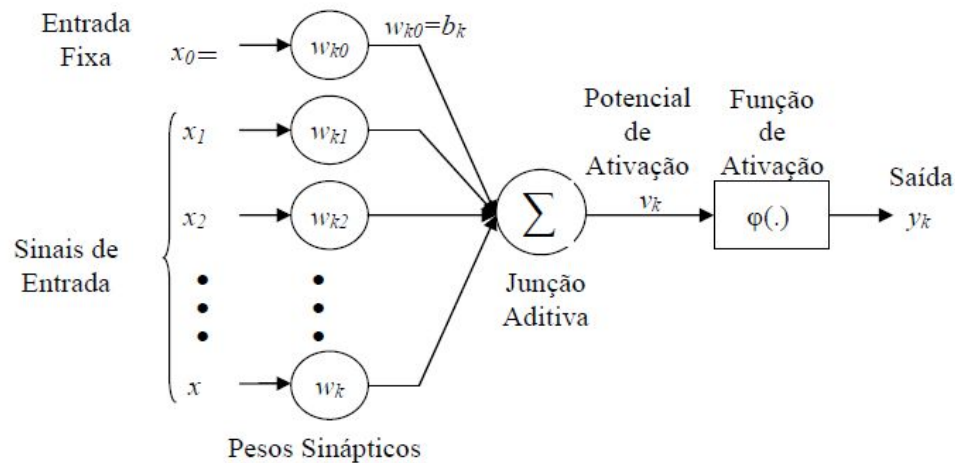


Figura 7 – Neurônio Artificial Perceptron, retirado de (JUNIOR, 2007) ()

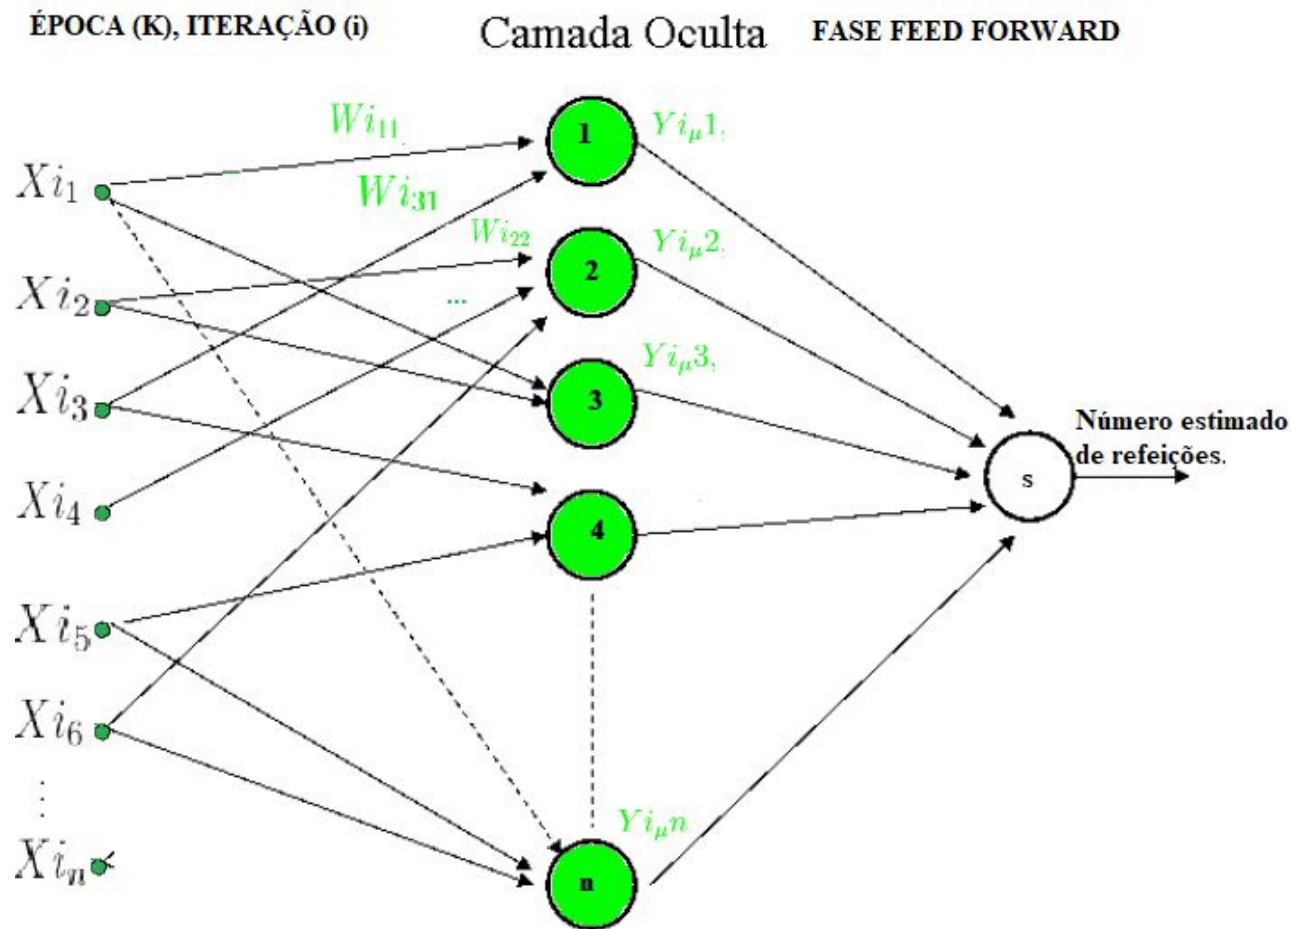
Técnica do modelo : Treino

Backpropagation

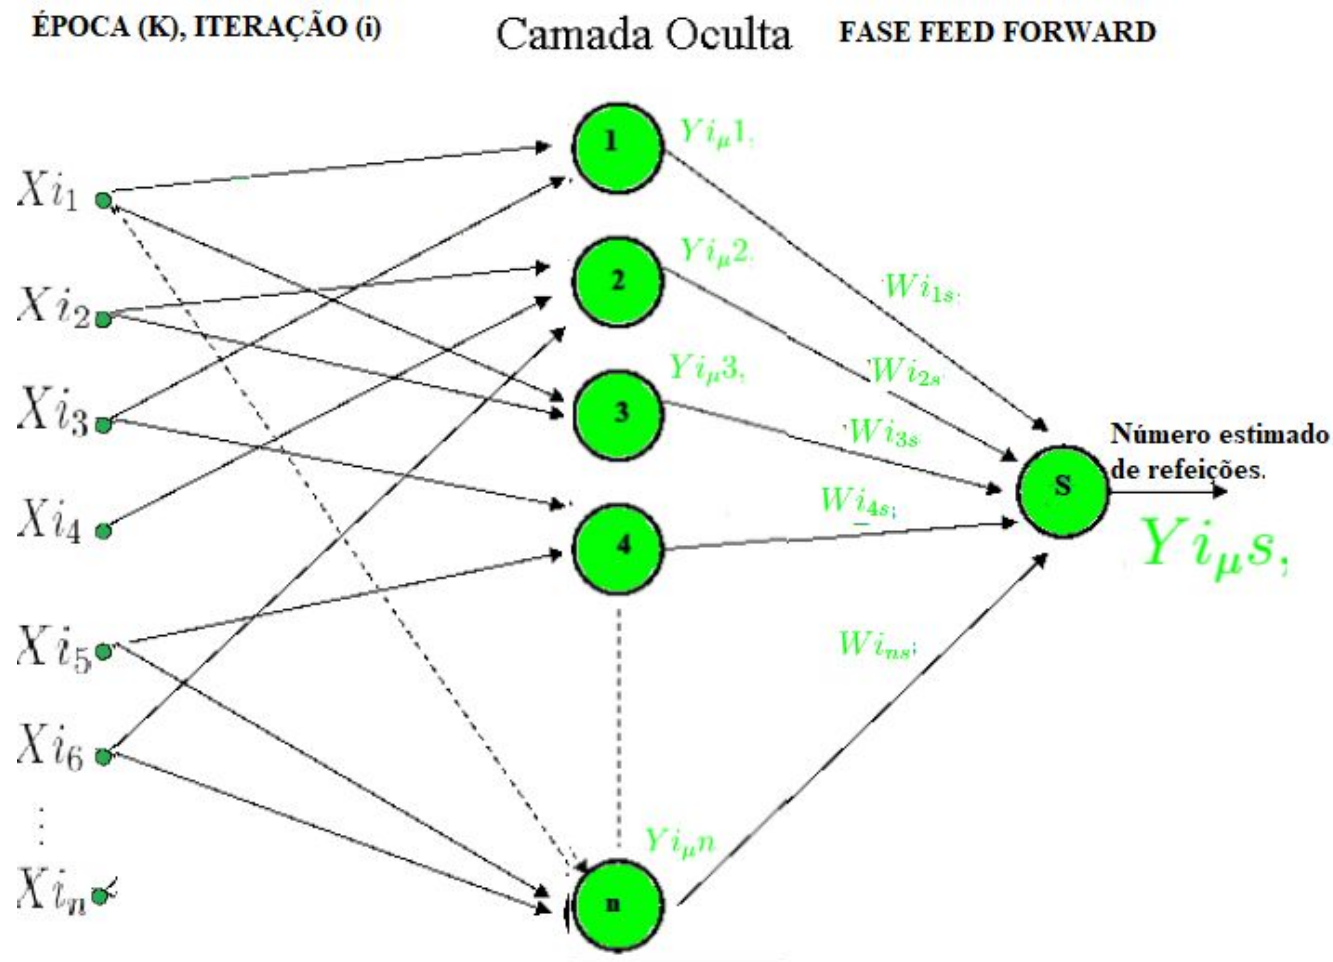


Tipos de função de ativação: (a) função degrau, (b) função linear, (c) função sigmoide, (d) função tangente hiperbólica


Técnica do modelo : Treino Backpropagation




Técnica do modelo : Treino Backpropagation




Técnica do modelo : Treino Backpropagation




Técnica do modelo : Treino Backpropagation



Técnica do modelo : Treino Backpropagation



Média com resultados de rnas com validações diferentes:



Cronograma

Para a continuação deste trabalho o cronograma abaixo deve ser seguido.

Tabela 3 – Plano de atividades para o TCC II

Atividades	Março	Abril	Mai	Junho	Julho
1	✓				
2	✓				
3		✓			
4		✓	✓		
5		✓	✓	✓	
6				✓	
7				✓	
8					✓

1. Estruturação do conjunto de dados do R.U do ano de 2017 conforme Tabela 4. O carregamento dos dados será realizado no Matlab, que já tem bibliotecas prontas que retornam o dia da semana baseado em uma data de entrada. Será realizado a predição de regressão com dados de 2017, e a medição de qualidade do modelo será feita com dados de 2018. Anotando-se o Erro Absoluto Médio (EAM), Erro Quadrado Médio (EQM) e Raiz do Erro Quadrado Médio (REQM).
2. Implementação do grafo de rede neural com nós perceptrons. A topologia seguirá conforme dados já estruturados na seção 2.2.3, será criado uma primeira camada oculta com o número de neurônios igual ao número de entradas, e 1 camada de saída, com 1 neurônio. Cada nó deve conter métodos de inicialização do número de entradas, inicialização dos pesos, inicialização de função de ativação, inicialização de bias e cálculo de saída. O grafo deve conter métodos de criar camadas, nós em cada camada, criar arestas orientadas das conexões dos nós.
3. Implementação do método feedforward que deve ser capaz de percorrer as camadas do grafo, e calcular o sinal de saída.
4. Implementação do método feedbackward que deve ser capaz de percorrer inversamente as camadas do grafo, e registrar os pesos sinápticos de cada nó.
5. Implementação do Algoritmo de treino e validação backpropagation, com $\eta = 0,5$ e função de ativação sigmóide para todos os neurônios.
6. O conjunto de dados original e estruturado na etapa anterior com regressão, estruturado conforme tabela 1, com todos os dados de 2017, terá um conjunto de 20% de observações

retiradas aleatoriamente de cada estação do ano de 2017, e será formado um par 80% de treino e 20% validação. Este processo de formação de pares será repetido 3x, obtendo 3 pares. Os 3 pares farão 3 treinos backpropagation, obtendo-se 3 modelos, será feito um método comiteRna, com combinador de média das saídas, onde o conjunto de dados de teste de 2018 será apresentado ao método, que replicará os dados aos 3 modelos de ma, e apresentará um valor mediano da saída dos 3 modelos.

7. Meta-análise dos resultados da regressão, e do comiteRna, com os avaliadores de qualidade dos modelos, Erro Absoluto Médio (EAM), Erro Quadrado Médio (EQM) e Raiz do Erro Quadrado Médio (REQM).
8. Escrita do TCC2